Cursurile 5-6 Introducere în prelucrarea limbajului natural

Domeniul

- Lingvistica computaţională (LC) osatura teoretică
 - computational linguistics
- Prelucrarea limbajului natural zona aplicativă
 - natural language processing
 - tehnologia limbajului natural, natural language technology
 - tehnologia limbajului uman, human language technology

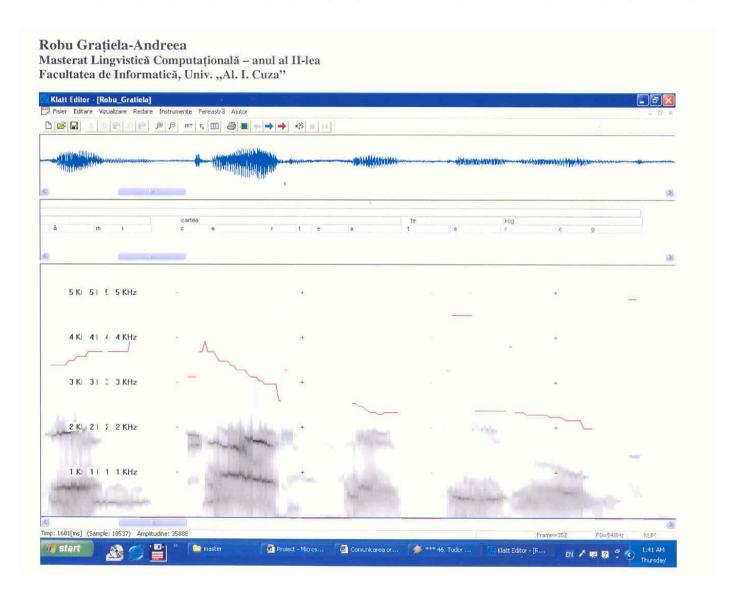
Tehnologia limbajului natural

- Limbajul vorbit
- Limbajul scris
- Limbajul în corelaţie cu alte modalităţi de expresie (multimodalitate)

Tehnologiile limbajului vorbit

- Interpretarea vocii
 - reprezentarea semnalelor vocale
 - recunoaşterea vorbirii
 - analiza prozodiei
 - recunoaşterea vorbitorului
- Sinteza vocală

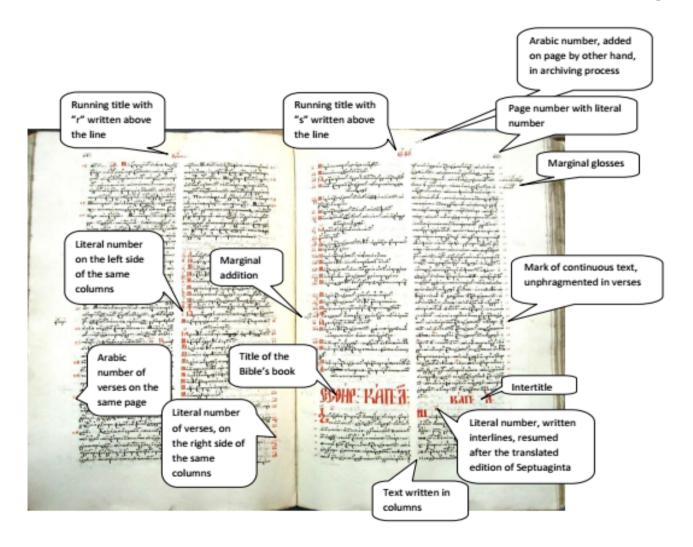
Prelucrarea semnalului sonor



Tehnologiile limbajului scris

- Tehnologii primare
 - Analiza imaginii documentelor
 - Recunoaşterea caracterelor de tipar
 - Recunoașterea caracterelor de mână
 - Optical Character Recognition (OCR)

Ms. 45 BAR Cluj-Napoca, second half of 17th century



Different types of writing in the revised copy of Nicolae Milescu's translation of *Septuaginta*, p. 412-413

Tehnologiile limbajului scris

- Analiza şi înţelegerea limbajului
 - prelucrări sub-sintactice
 - unitățile lexicale
 - graniţele de frază
 - granițele de propoziții
 - partea de vorbire şi marca morfologică
 - lema
 - numele de entităţi
 - grupurile (nominale, verbale, prepoziţionale etc.) şi atracţiile lexicale (colocaţii)

Fraze

Comisia juridică a Camerei Deputaților a votat luni împotriva începerii urmăririi penale a ministrului demisionar al Fondurilor Europene, Rovana Plumb, după ce aceasta a fost audiată, alături de avocat, aproximativ o oră de către deputații juriști. | Rovana Plumb s-a declarat, din nou, la ieşirea de la audierile din comisia juridică, nevinovată de acuzațiile aduse de procurorii anticorupție.

Propoziții

Pe 22 septembrie, DNA a anunțat că | vicepremierul Sevil Shhaideh este suspectă de | <u>săvârşirea</u> infracțiunii de abuz în serviciu | când era secretar de stat la MDRAP, într-un dosar conform căruia, în 2013, prin acțiunea concertată a unor persoane cu funcții publice, părți din Insula Belina și Brațul Pavel au trecut ilegal din proprietatea statului în proprietatea județului Teleorman și în administrarea CJ Teleorman, pentru ca, doar la câteva zile, să fie închiriate tot ilegal unei firme private.

Unități lexicale

Pe 22 septembrie, DNA a anunțat că vicepremierul Sevil Shhaideh este suspectă de săvârșirea infracțiunii de abuz în serviciu când era secretar de stat la MDRAP, într-un dosar conform căruia, în 2013, prin acțiunea concertată a unor persoane cu funcții publice, părți din Insula Belina și Brațul Pavel au trecut ilegal din proprietatea statului în proprietatea județului Teleorman și în administrarea CJ Teleorman, pentru ca, doar la câteva zile, să fie închiriate tot ilegal unei firme private.

persoană

Entități cu nume

Pe 27 septembrie, DNA a anunţat că vicepremierul Sevil Shhaideh este suspectă de săvârşirea infracțiunii de abuz în serviciu când era secretar de stat la MDRAP, într-un dosar conform căruia, în 2013, prin acțiunea concertată a unor persoane cu funcții publice, părți din Insula Belina și Brațul Pavel au trecut ilegal din proprietatea statului în proprietatea județului Teleorman și în administrarea CJ Teleorman, pentru ca, doar la câteva zile, să fie închiriate tot ilegal unei firme private.

dată

Entități cu nume

Pe 22 septembrie, DNA a anunțat că vicepremierul Se vil Shhaideh este suspectă de săvârșirea infracțiunii de abuz în serviciu când era secretar de stat la MDRAP, într-un dosar conform căruia, în 2013, prin acțiunea concertată a unor persoane cu funcții publice, părți din Insula Belina și Brațul Pavel au trecut ilegal din proprietatea statului în proprietatea județului Teleorman și în administrarea CJ Teleorman, pentru ca, doar la câteva zile, să fie închiriate tot ilegal unei firme private.

> reper temporal

instituție

Entități cu nume

Pe 22 septembrie, DNA a anunțat că vicepremierul Sevil Shhaideh este suspectă de săvârşirea infracțiunii de abuz în serviciu când era secretar de stat la MDRAP, într-un dosar conform căruia, în 2013, prin acțiunea concertată a unor persoane cu funcții publice, părți din Insula Belina și Brațul Pavel au trecut ilegal din proprietatea statului în proprietatea județului Teleorman și în administrarea CJ Teleorman, pentru ca, doar la câteva zile, să fie închiriate tot ilegal unei firme private.

locații geografice

Entități cu nume

Pe 21 septembrie, NA a anunțat că vicepremierul Sevil Shhaideh este suspertă de săvârșirea infracțiunii de abuz în serviciu când era secretar de stat la MDRAP, într-un dosar conform căruia, în 2013, prin acțiunea concertată a unor persoane cu funcții publice, părți din Insula Belina și Brațul Pavel au trecut ilegal din proprietatea statului în proprietatea județului Teleorman și în administrarea CJ Teleorman, pentru ca, doar la câteva zile, să fie închiriate tot ilegal unei firme private.

Lema și partea de vorbire

```
Solicitat – solicita – vb
să – să – conj
comenteze – comenta – vb
un – un – art.nehot.
editorial – editorial – sb
recent – recent – adj
```

Adnotarea morfologică

English

```
0
             subj:>2
1
    He
         he
                        @SUBJ PRON
    did
             v-ch:>4
         do
                        @+FAUXV V
    not not neg:>2
                        @ADVL NEG-PART
    know know main:>0
                        @-FMAINV V
         she subj:>6
                        @OBJ PRON
    her
    name name obj:>4@-FMAINV V
```

Romanian

```
<TOK ID="TOK478" root="Nu" pv="Particle" Type="negation">Nu</TOK>
<TOK ID="TOK479" root="şti" pv="Verb" Type="main" Mood="indic."

Tense="imperfect" Person="third" Number="singular">ştia</TOK>
<TOK ID="TOK480" root="cum" pv="Adverb" type="int_rel">cum</TOK>
<TOK ID="TOK481" root="el" pv="Pronoun" Type="pers" Person="third"

Gender="feminine" Number="singular" Case="accusative">o</TOK>
<TOK ID="TOK482" root="chema" pv="Verb" Type="main" Mood="indic."

Tense="present" Person="third">cheamă</TOK>
```

Grupuri nominale

Solicitat să comenteze [un <u>editorial</u> recent al lui [<u>Dinu Patriciu</u>]], în [<u>care</u>] [<u>acesta</u>] preciza că nu crede în [<u>social-liberalism</u>] și să aprecieze dacă, astfel, a dat [o <u>lovitură</u> de [<u>imagine</u>]] [<u>USL</u>], [<u>Antonescu</u>] a spus că nu știe dacă [<u>Patriciu</u>] s-a referit la [<u>USL</u>].

Adnotare la grupuri nominale

```
<NP ID="NP903" HEADID="W3190" VERBPOS="W3191">
   <W ID="W3190" POS="PRON" NUM="SG" GENDER="M" ROLE="SUBJ"
                                                                  LEMMA="he"
   LINK="W3191" LINKTYPE="subj">He</W> </NP>
<W ID="W3191" POS="V" ROLE="+FAUXV" LEMMA="do" LINK="W3193" LINKTYPE="v-ch">did</
   W>
<W ID="W3192" POS="NEG-PART" ROLE="ADVL" LEMMA="not" LINK="W3191"
   LINKTYPE="neg">not</W>
<W ID="W3193" POS="V" ROLE="-FMAINV" LEMMA="know" LINK="W3189"</p>
   LINKTYPE="main">know</W>
<NP ID="NP1188" HEADID="W3195">
   <NP ID="NP904" HEADID="W3194" VERBPOS="W3189">
     <W ID="W3194" POS="PRON" NUM="SG" GENDER="F"
                                                             ROLE="OBJ"
   LEMMA="she" LINK="W3195" LINKTYPE="subj">her</W> </NP>
   <W ID="W3195" POS="V" ROLE="-FMAINV" LEMMA="name" LINK="W3193"
   LINKTYPE="obj">name</W> </NP>
```

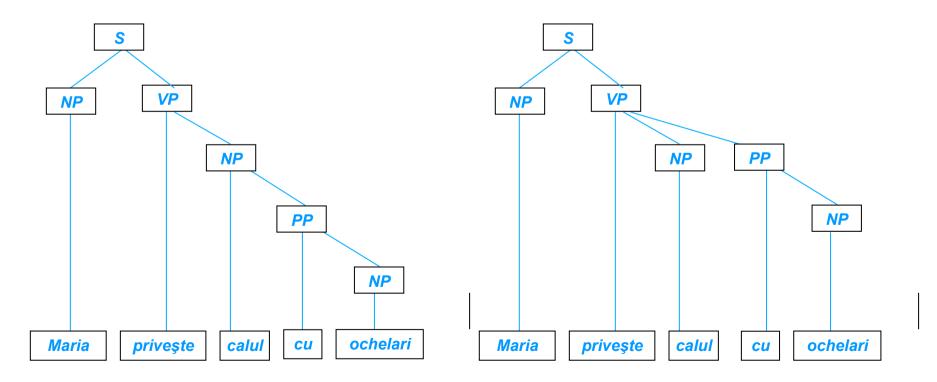
Tehnologiile limbajului scris

- Analiza şi înţelegerea limbajului
 - prelucrări sintactice
 - formalisme gramaticale
 - parsarea

 structura sintactică a frazei

Ambiguități sintactice

Maria privește calul cu ochelari.



- Tokenizer: determină granițele unităților lexicale
 - intrare: text (şir de caractere)
 - ieşire: <tok id="...">cuvânt</tok>
 - cum: prin expresii regulate

- POS-Tagger: etichetare la parte de vorbire (dezambiguizare morfosintactică)
 - intrare: <tok id="...">cuvânt</tok>
 - ieșire: <tok id="..." POS="...">cuvânt</tok>
 - cum: exploatând frecvențele de apariție a anumitor secvențe de părți de vorbire => optimizare globală a secvențelor de etichete

The saw made noise.

DET V N N N N N V

 Lematizator: determină forma de bază a cuvintelor

```
- intrare: <tok id="..." POS="...">word</tok>
```

- ieşire: <tok id="..." POS="..." lemma="...">word</
 tok>
- cum: pe baza unui dicţionar de leme şi exploatând frecvenţe de apariţie a secvenţelor de leme => optimizare globală

```
The saw made noise.

the saw made noise
see make
```

- NP-Chunker: detectează grupuri nominale
 - intrare: secvențe de elemente <tok>
 - ieşire: <np id="...">...</np>
 - cum: aplicând expresii regulate

- NER (name entity recogniser): recunoaște și clasifică nume de entități
 - intrare: text
 - ieșire: <ne id="..." type ="...">...</ne>
 - cum: pe bază de expresii regulate și liste foarte mari de nume de entități specializate pe limbi (gazeteers)

Tehnologiile limbajului scris

- Analiza şi înţelegerea limbajului
 - Prelucrări semantice şi de discurs
 - dezambiguizare semantică → sensurile cuvintelor
 - determinarea rolurilor semantice ale verbelor
 - structura retorică a discursului şi dialogului
 - rezoluţia anaforelor
 - rezumarea textelor

Winston was just taking his place in one of the middle rows when two people whom he knew by sight, but had never spoken to, came unexpectedly into the room. One of them was a girl whom he often passed in the corridors. He did not know her name, but he knew that she worked in the Fiction Department.

Winston was just taking his place in one of the middle rows when two people whom he knew by sight, but had never spoken to, came unexpectedly into the room.

One of them was a girl whom he often passed in the corridors. He did not know her name, but he knew that she worked in the Fiction Department.

Winston was just taking his place in one of the middle rows when two people whom he knew by sight, but had never spoken to, came unexpectedly into the room.

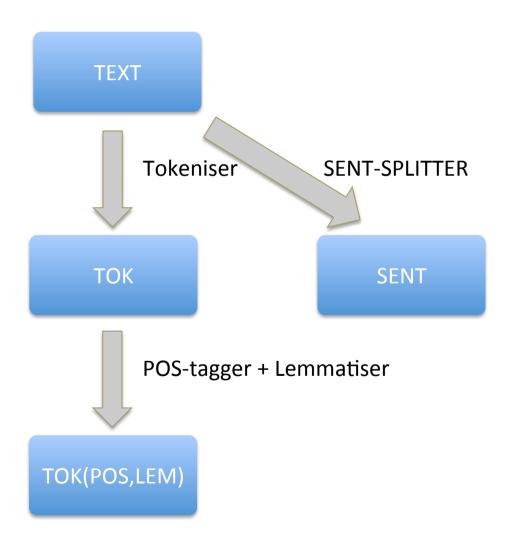
One of them was a girl whom he often passed in the corridors. He did not know her name, but he knew that she worked in the Fiction Department

Winston was just taking his place in one of the middle rows when two people whom he knew by sight, but had never spoken to, came unexpectedly into the room. One of them was a girl whom he often passed in the corridors. He did not know her name, but he knew that she worked in the Fiction Department.

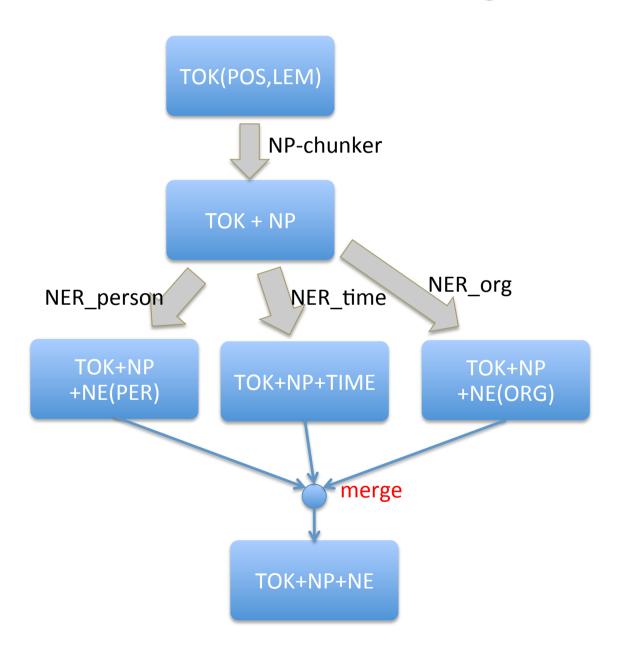
Cuvintele îşi precizează sensul în context

- Ion se prinse în horă cu o fată cu cosițe lungi.
- Când <u>fată</u> iapa ta?
- Mă mai dau o dată pe pârtia roșie.
- I-am <u>dat</u> una peste mână.
- Maria a <u>dat</u> cartea înapoi.
- *M-am scos...*
- Mi-am <u>scos</u> măseaua de minte.

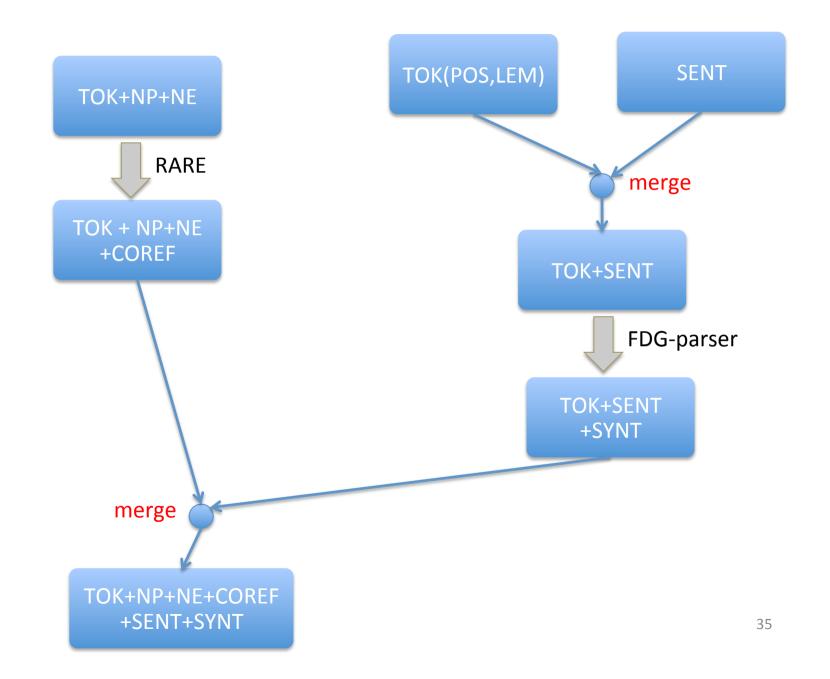
Pre-processing



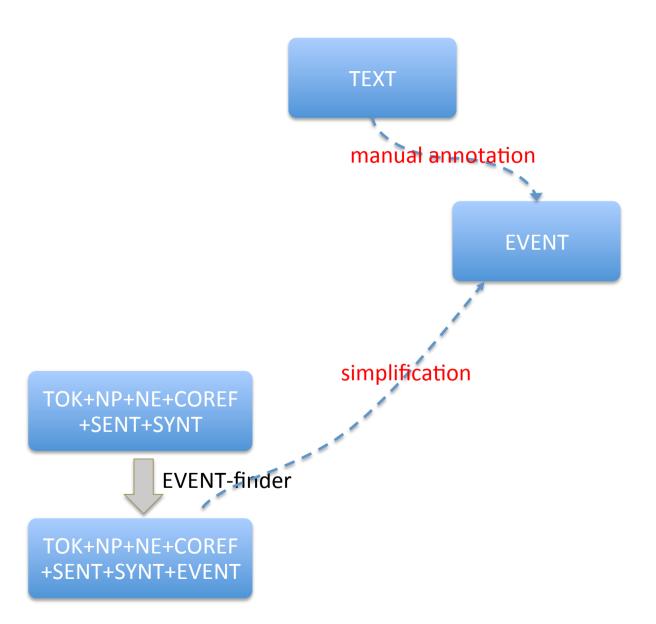
NP-chunking, NER



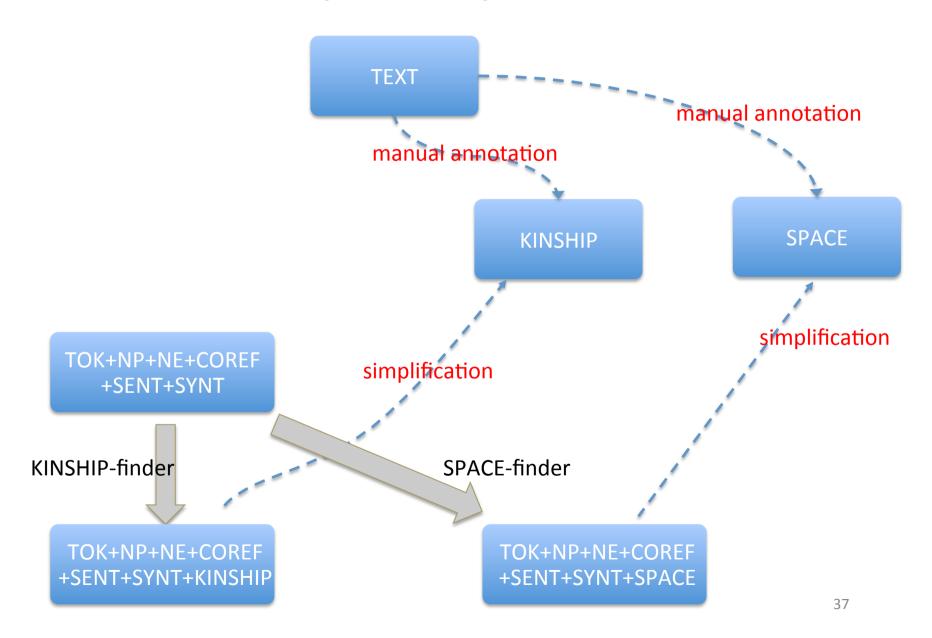
Coreference, syntactic parsing



Events



Kinship and Space



Relații de rudenie: exemplu

 Las că cu tine mă răfuiesc după, îi scăpă printre dinți omului ei Donca, nevasta călugărului zbanghiu Zuicu, care-I adusese la el acasă pe Ion și pe președinte.

```
Apoziție: Per-X, Rel (atrib) Per-Y<sub>gen</sub>, => marriage(X:person[sex:?], Y:person[sex:?]) marriage(Donca:person[sex:f], Zuicu:person[sex:m])
```

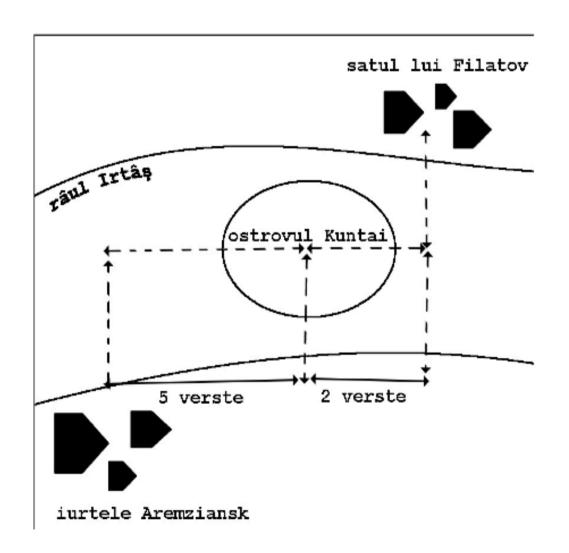
Relații de rudenie: exemplu

Vreme de patruzeci de ani viața Ellei Rubinstein₁
 fusese ca o apă stătătoare... Soțul ei₁, David, era un dentist de succes...

```
Apoziție: Rel Per-X<sub>pron,gen</sub>, Per-Y, =>
marriage(antecedent(X):person[sex:?],
Y:person[sex:?])
marriage(Ella Rubistein:person[sex:f],
David:person[sex:m])
```

Relații spațiale: exemplu

La cinci verste de iurtele Aremziansk, în mijlocul râului Irtâş, se află ostrovul Kuntai. Satul lui Filatov se află pe malul stâng la două verste de ostrov.



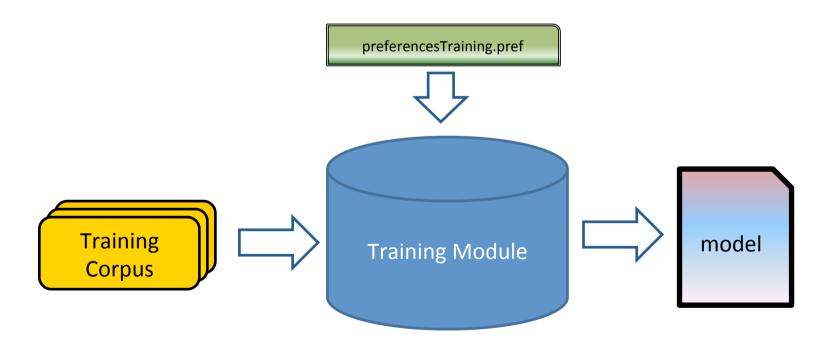
Cum se calibrează un modul?

Să presupunem că vrem să construim un modul care să realizeze un anumit obiectiv. Atunci, de fapt, va trebui să fabricăm 3 module:

- Modulul de antrenare (TM)
- Modulul propriu-zis (X)
- Modulul de evaluare (EM)

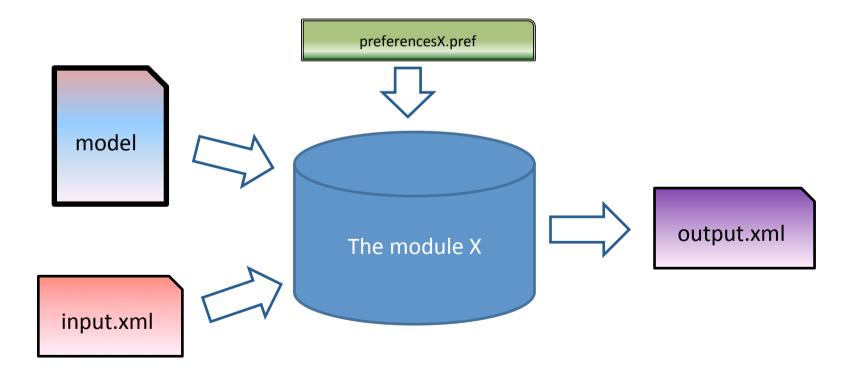
Modulul de antrenare (TM)

 TM extrage dintr-un corpus de antrenare un model care va fi apoi folosit de molulul X.



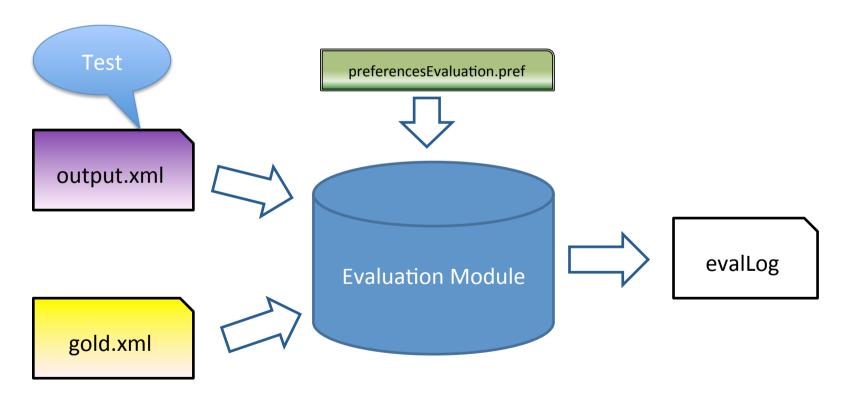
Modulul X

• X aplică un algoritm asupra unei *intrări* pentru a o transforma în conformitate cu *modelul* învățat.



Modulul de evaluare (EM)

• EM evaluează (compară) un fișier *Test* față de un fișier considerat corect (de aur) *Gold*.



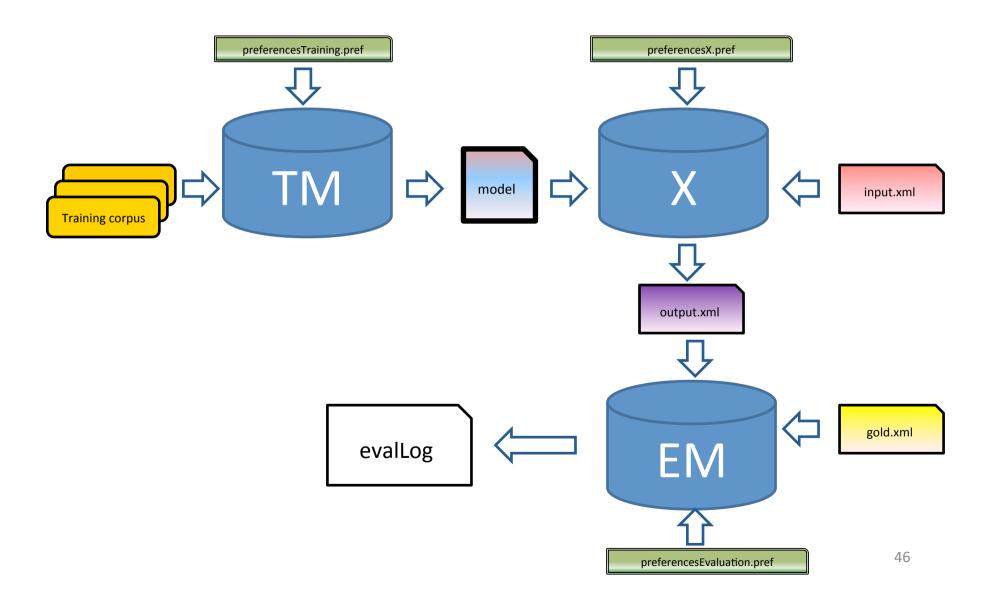
Măsuri în evaluare

Precision =
 #itemi în comun în Test & Gold/#itemi în Test

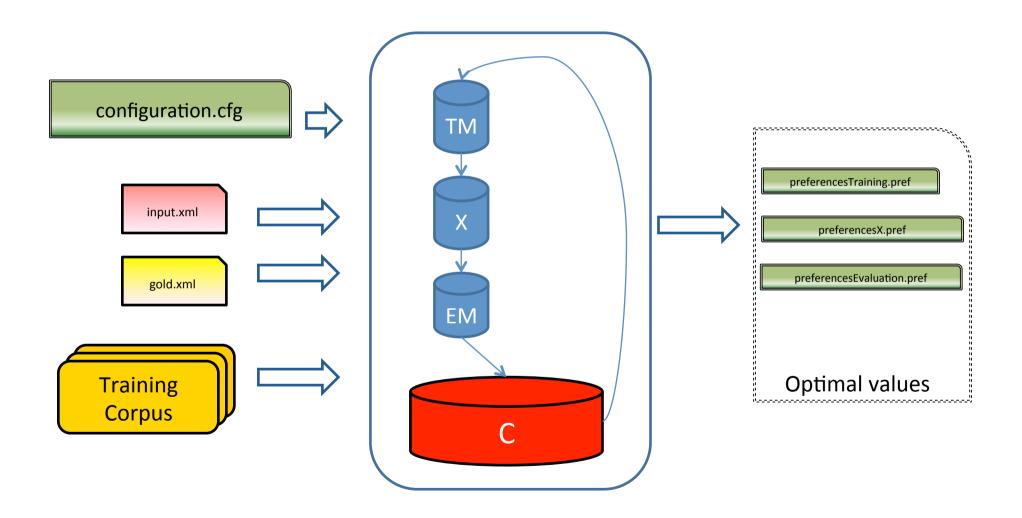
Recall =
 #itemi în comun în Test & Gold/#itemi în Gold

F-measure = 2 * P * R / (P + R)

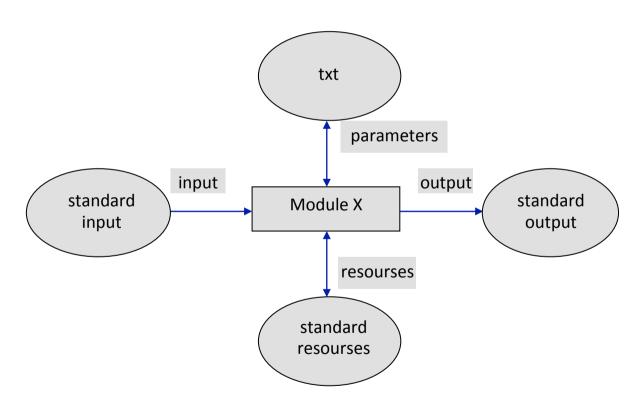
Arhitectura generală



Sistem de calibrare



Forma recomandată a unui instrument NLP care participă într-un lanț de prelucrări



Events happen in time

Când <u>a intrat în cameră_{e1}, Ion a aprins lumina_{e2}.</u>
După cinci minute <u>a ieşit_{e3}.</u> La ieşire <u>a stins</u> $\underline{lumina_{e4}}$.

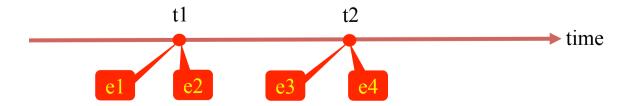
Events happen in time

Când <u>a intrat în cameră_{e1}, Ion a aprins lumina_{e2}.</u>
După cinci minute <u>a ieşit_{e3}.</u> La ieşire <u>a stins</u> $\underline{lumina_{e4}}$.

Two types of temporal expressions:

instants...

e1:t1 / e2:t1 / e3:t2=t1+5min / e4:t2

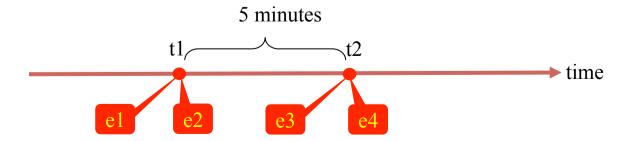


Events happen in time

Când <u>a intrat în cameră_{e1}, Ion a aprins lumina_{e2}.</u>
După cinci minute <u>a ieşit_{e3}.</u> La ieşire <u>a stins</u> $\underline{lumina_{e4}}$.

Two types of temporal expressions:

• ...and intervals:

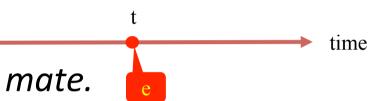


Events can be...

Instantaneous:

Ion a ieşit din cameră.

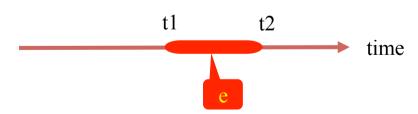
Maria s-a întâlnit cu proful de mate.



• Take time:

Ion a citit toată seara.

Afară plouă.



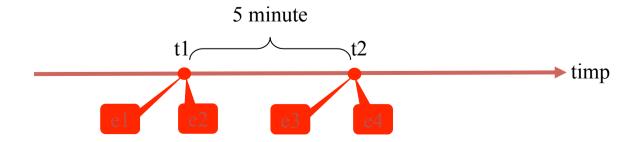
Signals for temporal relations

Când <u>a intrat în cameră</u>_{e1}, <u>Ion a aprins lumina</u>_{e2}.

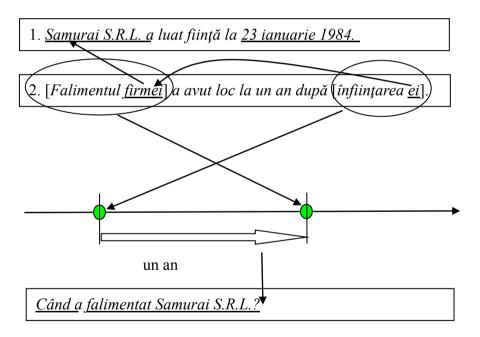
După cinci minute <u>a ieşit</u>_{e3}. La ieşire <u>a stins</u>

<u>lumina</u>_{e4}.

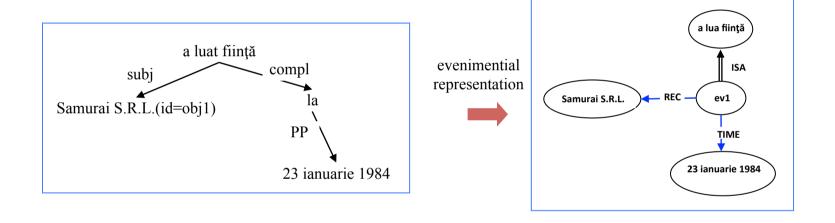
$$c\hat{a}nd \ e_i, \ e_j \implies t(e_i) = t(e_j)$$
 $e_i. \ După < interval > e_j \implies t(e_j) = t(e_i) + < interval >$
 $La < reference(e_i) > e_j \implies t(e_i) = t(e_j)$



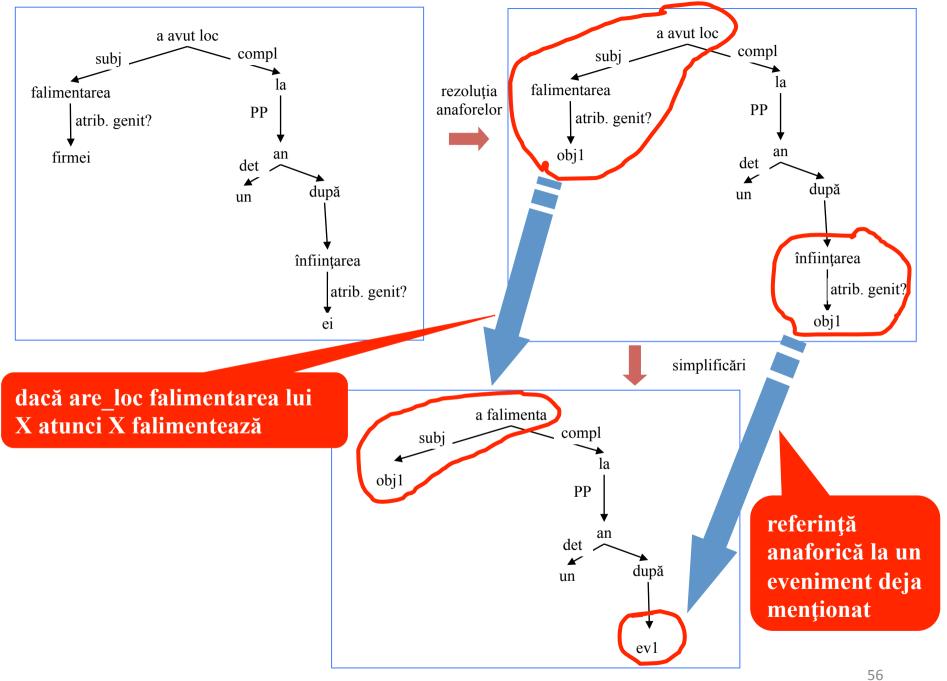
Type of reasoning where time matters



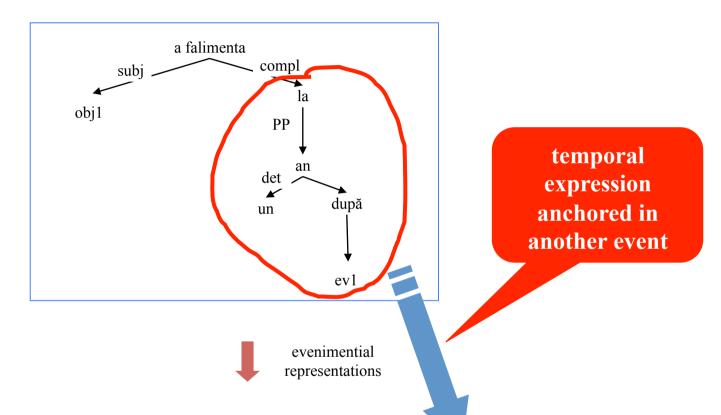
Processing statements



<object ID="obj1" ISA="companie" NAME="Samurai S.R.L."/>
<event ID="ev1" ISA="a_lua_fiinţă" REC="obj1" TIME="23.01.1984"/>



Processing statements



<event ID="ev2" ISA="a_falimenta" REC="obj1" TIME="timex1"/>

<timex ID="timex1" TYPE="after" REF="ev1" DUR="1" UNIT="year"/>

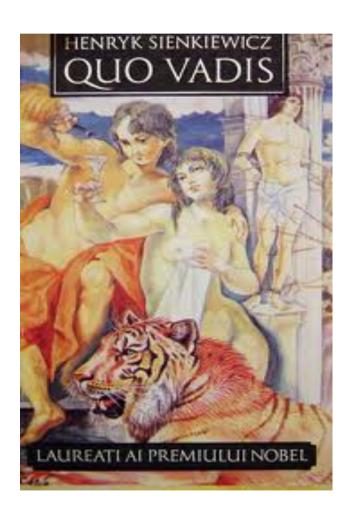
Computing time

```
<object ID="obj1" ISA="companie" NAME="Samurai S.R.L."/>
<event ID="ev1" ISA="a_lua_fiinţă" REC="obj1" TIME="23.01.1984"/>
<event ID="ev2" ISA="a_falimenta" REC="obj1" TIME="timex1"/>
<timex ID="timex1" TYPE="after" REF="ev1" DUR="1" UNIT="year"/>
```



<event ID="ev2" ISA="a_falimenta" REC="obj1" TIME="23.01.1985"/>

Corpusul 'QuoVadis'



Un corpus de entități și relații semantice

- Tipuri de entități:
 - persoane
 - zei
 - grupuri de persoane și zei
 - părți fizice
- Relaţii semantice exprimate între aceste tipuri de entităţi



Entități

- Personaje (*Marcus Vinicius, Ligia*), grupuri (*creștinii, soldații*);
- La nivelul textului: grupuri nominale (<u>tânărul</u> patrician, fiul consulului);
- Entități incluse:

[Te]₁ [iubesc; REALISATION=INCLUDED]₂, Marcus!

• Expresii referențiale imbricate:

[fiica [lui Aulus]₂]₁



Tipuri de relații

- Anaforice
- Semantice
 - rudenie
 - afective
 - sociale



Relații anaforice

- coref
- coref-interpret
- member-of, has-as-member (inverse)
- *isa, class-of* (inverse)
- part-of, has-as-part (inverse)
- subgroup-of, has-as-subgroup (inverse)
- has-name, name-of (inverse)



1:[*Acteea*]... 2:[*tânăra libertă*]... => [2] coref [1]

1:[mâna 2:[lui] dreaptă] => [1] part-of [2]

Relații de rudenie

- parent-of
- child-of (inverse of parent-of)
- grandparent-of and grandchild-of (inverse)
- *sibling* (symmetrical)
- ant-uncle-of, nephew-of (inverse relation)
- cousin-of (symmetrical)
- spouse-of (symmetrical)
- unknown



1:[celui de-al doilea soț 2:[al Popeii]] => [1] spouse-of [2]

1:[sora lui 2:[Petronius]] => [1] sibling-of [2]

Relații sociale

- superior-of
- inferior-of
- in cooperation-with
- colleague-of
- in competition-with
- opposite-to



Eliberând- 1:[o], 2:[Nero]... => [2] superior-of [1]
1:[Tânărul] luptase sub comanda 2:[lui Corbulon] =>
[1] inferior-of [2]

Relații afective

- love
- loved-by
- hate
- hated by
- upset
- friendship
- worship
- anger



Pe 1:[Vinicus] îl cuprinse o <u>mânie</u> năprasnică împotriva 2:[împăratului] și împotriva 3:[Acteii] => [1] anger [2], [1] anger [3]

Adnotarea

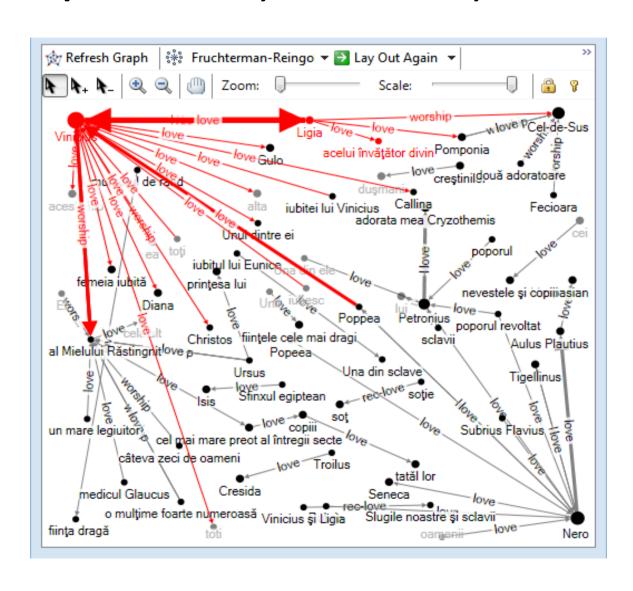
<entity id="E8" type="PERSON"></entity>	<w id="44" lemma="căsători">căsătorise</w>	
<w id="28" lemma="Marcus">Marcus</w>	<w id="45" lemma="cu">cu</w>	
<w id="29" lemma="Vinicius">Vinicius</w>	<kinship <="" from="E15" id="KIN61" td="" to="E14" trigger="46"></kinship>	
	TYPE="parent-of">	
<w id="30" lemma="fi">era</w>	<entity id="E15" type="PERSON"></entity>	
<kinship <="" from="E12" id="KIN57" p="" to="E11" trigger="31"></kinship>	<w id="46" lemma="tată">tatăl</w>	
TYPE="child-of">	<entity id="E14" type="PERSON"></entity>	
<entity id="E12" type="PERSON"></entity>	<w id="47" lemma="acesta">acestuia</w>	
<w id="31" lemma="fiu">fiul</w>		
<kinship <="" from="E11" id="KIN53" td="" to="E10" trigger="32"><td></td></kinship>		
TYPE="sibling-of">		
<entity id="E11" type="PERSON"></entity>		
<w id="32" lemma="soră">surorii</w>	<social <="" from="E17" id="SOC9" td="" to="E16" trigger="49"></social>	
<entity id="E10" type="PERSON"></entity>	TYPE="inferior-of">	
<w id="33" lemma="său">sale</w>	<entity id="E17" type="PERSON"></entity>	
	<w id="49" lemma="consul">consul</w>	
<w id="34" lemma="mai">mai</w>	<w id="50" lemma="pe">pe</w>	
<w id="35" lemma="mare">mari</w>	<w id="51" lemma="vreme">vremea</w>	
	<w id="52" lemma="el">lui</w>	
	<entity id="E16" type="PERSON"></entity>	
	<w id="53" lemma="Tiberiu">Tiberiu</w>	
- 		
<w id="36" lemma=",">,</w>		
<kinship <="" from="E13" id="KIN59" td="" to="E15" trigger="44"><td></td></kinship>		
TYPE="spouse-of">	<w id="54" lemma=".">.</w>	
<entity id="E13" type="PERSON"></entity>		
<w id="37" lemma="care">care</w>	<referential <="" from="E12" id="REF37" td="" to="E8" type="coref"></referential>	
	REFERENTIAL>	
<w id="38" lemma=",">,</w>	<referential <="" from="E13" id="REF38" td="" to="E11" type="coref"></referential>	
<w id="39" lemma="cu">cu</w>	REFERENTIAL>	
<w id="40" lemma="an">ani</w>	<referential from="E14" id="REF39" referential="" to="E8" type="coref"></referential>	
<w id="41" lemma="în_urmă">în urmă</w>	<pre><referential> <referential 42"="" from="E17" id="REF40" lemma="," to="E15" type="class-</pre></td></tr><tr><td><W id=">,</referential></referential></pre>	of" /REFERENTIAL>
<w id="43" lemma="sine">se</w>	· · · · · · · · · · · · · · · · · · ·	

Statistici asupra corpusului

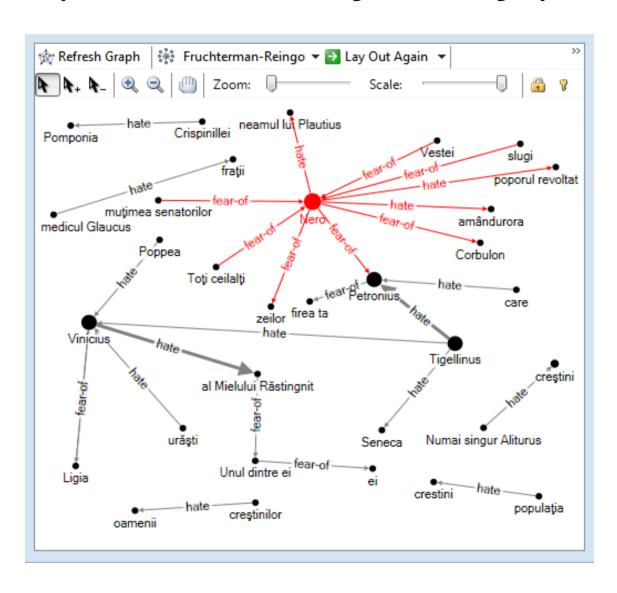
- 7.281 fraze
- 146.822 cuvinte și semne de punctuație
- 24.636 mențiuni de entități
- 22.301 relații referențiale
- 755 relaţii AKS (Affective + Kinship + Social)
- 752 triggere



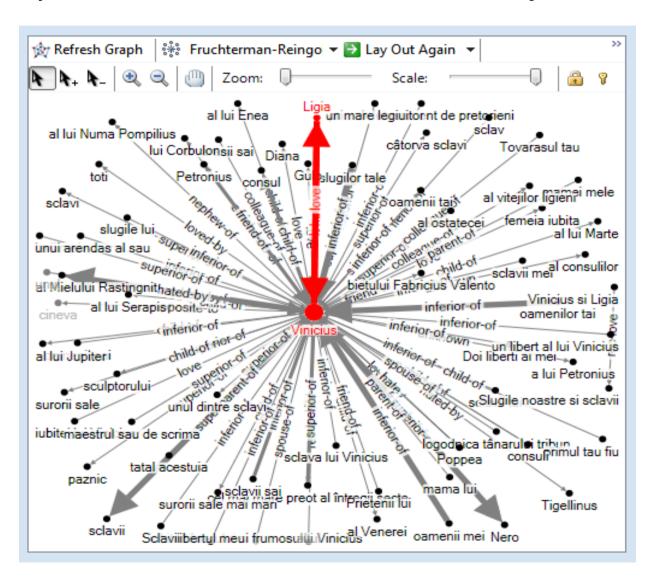
Example: relațiile love și worship



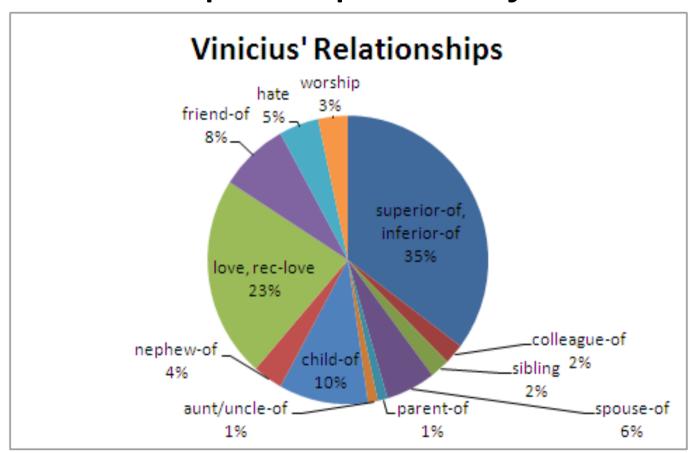
Relațiile afective fear-of și hate



Relațiile lui Vinicius cu alte personaje



Distribuția relațiilor semantice în care este implicat personajul Vinicius



Linguistics Linked Open Data (LLOD)

- Dezvoltarea de tehnici care vor permite descifrarea conţinutului semantic al textelor
 - rezumate (generale, parțiale, focalizate pe personaje),
 - linii narative (e.g. evoluția sentimentelor dintre Vinicius și Ligia)
 - conexiuni statice între entități (e.g. arbori genealogici),
 - statistici asupra entităților (e.g. sentimentele majoritare ale creștinilor comparate cu cele ale romanilor)

Linguistics Linked Open Data (LLOD)

- Generarea de ontologii din colecții de tratate
 - aplicații care "citesc" tratatele unui domeniu și formalizează conceptele și instanțele acestora
- Căutare documentară inteligentă
 - asistenți personalizați ai activității de cercetare