

Calcul Numeric

Cursul 2

2017

Anca Ignat

Fie vectorii \mathbf{x}, \mathbf{y} , cu ajutorul lor definim produsele scalare în \mathbb{C}^n și \mathbb{R}^n :

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{C}^n, \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{C}^n$$

$$(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n x_i \overline{y_i} = \mathbf{y}^H \mathbf{x} = \begin{pmatrix} \overline{y_1} & \overline{y_2} & \cdots & \overline{y_n} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n, \boldsymbol{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n$$

$$(\boldsymbol{x}, \boldsymbol{y}) = \sum_{i=1}^n x_i y_i = \boldsymbol{y}^T \boldsymbol{x} = (y_1 \ y_2 \ \cdots \ y_n) \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

Proprietățile matricii A^H

1. $(A + B)^H = A^H + B^H$

2. $(A^H)^H = A$

3. $(AB)^H = B^H A^H$

4. $(A^{-1})^H = (A^H)^{-1}$

Proprietăți ale matricii A^T

$$(A + B)^T = A^T + B^T$$

$$(A^T)^T = A$$

$$(AB)^T = B^T A^T$$

$$(A^{-1})^T = (A^T)^{-1}$$

Propoziție

Fie $A \in \mathbb{C}^{m \times n}$, $x \in \mathbb{C}^n$, $y \in \mathbb{C}^m$ atunci:

$$(Ax, y)_{\mathbb{C}^m} = (x, A^H y)_{\mathbb{C}^n}.$$

Pentru cazul real avem:

$$A \in \mathbb{R}^{m \times n}, x \in \mathbb{R}^n, y \in \mathbb{R}^m \Rightarrow (Ax, y)_{\mathbb{R}^m} = (x, A^T y)_{\mathbb{R}^n}$$

Demonstrație

$$\begin{aligned}(Ax, y) &= y^H (Ax) = y^H A x = y^H (A^H)^H x = \\ &= (A^H y)^H x = (x, A^H y).\end{aligned}$$

Tipuri de matrici

Definiții

O matrice $A \in \mathbb{R}^{n \times n}$ se numește *simetrică* dacă $A = A^T$.

O matrice $A \in \mathbb{C}^{n \times n}$ se numește *autoadjunctă* dacă $A = A^H$.

O matrice $A \in \mathbb{C}^{n \times n}$ se numește *unitară* dacă $A^H A = A A^H = I_n$.

O matrice $A \in \mathbb{C}^{n \times n}$ se numește *ortogonală* dacă

$$A^T A = A A^T = I_n.$$

O matrice $A \in \mathbb{C}^{n \times n}$, $A=(a_{ij})$ se numește matrice *triunghiulară inferior* (sau *inferior triunghiulară*) dacă

$$a_{ij} = 0 \text{ pentru } j > i$$

$$A = \begin{pmatrix} a_{11} & 0 & \dots\dots\dots 0 \\ a_{21} & a_{22} & \dots\dots\dots 0 \\ \vdots & & & 0 \\ \vdots & & & \vdots \\ a_{n1} & a_{n2} & \dots\dots\dots a_{nn} \end{pmatrix}$$

O matrice $A \in \mathbb{C}^{n \times n}$, $A=(a_{ij})$ se numește matrice *triunghiulară superior* (sau *superior triunghiulară*) dacă

$$a_{ij} = 0 \text{ pentru } j < i$$

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ 0 & a_{22} & a_{23} & \dots & a_{2n} \\ 0 & 0 & a_{33} & \dots & a_{3n} \\ \vdots & & & & \\ 0 & 0 & 0 & \dots & a_{nn} \end{pmatrix}$$

Notăm cu \mathbf{I}_n matricea unitate:

$$\mathbf{I}_n \in \mathbb{R}^{n \times n}, \mathbf{I}_n = \begin{pmatrix} \mathbf{1} & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{1} & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \vdots & & & & & \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \mathbf{1} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} & \mathbf{1} \end{pmatrix}$$

Matrice diagonală $\mathbf{D}=\text{diag}[d_1, d_2, \dots, d_n]$

$$\mathbf{D} \in \mathbb{R}^{n \times n}, \mathbf{D} = \begin{pmatrix} d_1 & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & d_2 & \mathbf{0} & \dots & \mathbf{0} & \mathbf{0} \\ \vdots & & & & & \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & d_{n-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} & d_n \end{pmatrix}$$

Norme

Definiție

Fie X un spațiu vectorial real. Se numește ***normă*** aplicația:

$$\| \cdot \| : X \rightarrow \mathbb{R}_+$$

care îndeplinește condițiile:

- (1) $\|x\| \geq 0$; $\|x\| = 0 \Leftrightarrow x = 0$;
- (2) $\|x + y\| \leq \|x\| + \|y\|, \forall x, y \in X$;
- (3) $\|\lambda x\| = |\lambda| \|x\|, \forall x \in X, \forall \lambda \in \mathbb{R}$.

Vom numi ***norme vectoriale*** normele definite pe spațiile $X = \mathbb{C}^n$ sau \mathbb{R}^n .

Exemple

Fie spațiile vectoriale \mathbb{C}^n sau \mathbb{R}^n . Pe aceste spații următoarele aplicații sunt norme vectoriale:

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |\mathbf{x}_i|;$$

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n |\mathbf{x}_i|^2};$$

$$\|\mathbf{x}\|_\infty = \max\{|\mathbf{x}_i|, i = 1..n\}.$$

Dacă $\|\cdot\|_v$ este o normă vectorială și $\mathbf{P} \in \mathbb{R}^{n \times n}$ este o matrice nesingulară atunci aplicația

$$\|\cdot\|_P : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \|\mathbf{x}\|_P = \|\mathbf{P}\mathbf{x}\|_v$$

este de asemenea o normă vectorială.

Definiție

Se numește *produs scalar* în spațiul vectorial X aplicația:

$$(\cdot, \cdot): X \times X \rightarrow K$$

care satisface condițiile :

$$(a) \quad (x, x) \geq 0, \forall x \in X, \quad (x, x) = 0 \Leftrightarrow x = 0;$$

$$(b) \quad (x, y) = \overline{(y, x)}, \forall x, y \in X,$$

$$(c) \quad (\lambda x, y) = \lambda (x, y), \forall x, y \in X, \forall \lambda \in K,$$

$$(d) \quad (x + y, z) = (x, z) + (y, z), \forall x, y, z \in X.$$

Inegalitatea lui Cauchy-Buniakovski-Schwarz:

$$|(x, y)| \leq \sqrt{(x, x)} \sqrt{(y, y)} \quad \forall x, y \in X$$

Într-un spațiu vectorial dotat cu produs scalar se poate induce o normă numită euclidiană:

$$\|x\|_2 = |x| := \sqrt{(x, x)}.$$

Reaminitm definiția produselor scalare pe \mathbb{C}^n și pe \mathbb{R}^n introduse anterior:

$$(\mathbf{x}, \mathbf{y})_{\mathbb{C}^n} = \sum_{i=1}^n x_i \overline{y_i} \quad , \quad (\mathbf{x}, \mathbf{y})_{\mathbb{R}^n} = \sum_{i=1}^n x_i y_i$$

Obținem norma euclidiană (valabilă în ambele spații \mathbb{C}^n și \mathbb{R}^n):

$$\|\mathbf{x}\|_2 = |\mathbf{x}| = \sqrt{\sum_{i=1}^n |x_i|^2}.$$

Norme matriciale

Definiție

Aplicația $\| \cdot \| : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$ se numește *normă matricială* dacă:

$$(1) \|A\| \geq 0 \quad \forall A \in \mathbb{R}^{n \times n} ; \|A\| = 0 \Leftrightarrow A = 0.$$

$$(2) \|\alpha A\| = |\alpha| \|A\| , \quad \forall \alpha \in \mathbb{R} , \forall A \in \mathbb{R}^{n \times n} .$$

$$(3) \|A + B\| \leq \|A\| + \|B\| , \quad \forall A, B \in \mathbb{R}^{n \times n} .$$

$$(4) \|A * B\| \leq \|A\| \cdot \|B\| , \quad \forall A, B \in \mathbb{R}^{n \times n} .$$

Exemple

Norma Frobenius definită de relația $\|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2}$ este o normă matricială.

Aplicația $\|A\|_{\max} = \max\{|a_{ij}|; i = 1, \dots, n, j = 1, \dots, n\}$ NU este o normă matricială.

Pentru $n = 2$ fie:

$$A = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}, B = A^T = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$A * B = I_2, \|A\|_{\max} = \|B\|_{\max} = \frac{1}{\sqrt{2}}$$

$$\|A * B\|_{\max} = 1 > \|A\|_{\max} \bullet \|B\|_{\max} = \frac{1}{2}.$$

Norme matriciale naturale

- $\|\cdot\|_v : \mathbb{R}^n \rightarrow \mathbb{R}_+$ o normă vectorială $\rightarrow \|\cdot\|_i : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}_+$
normă matricială naturală sau indusă.

$$\|A\|_i = \max \left\{ \frac{\|Ax\|_v}{\|x\|_v} ; x \in \mathbb{R}^n, x \neq 0 \right\}$$

Definiții echivalente :

$$\begin{aligned} \|A\|_i &= \max \{ \|Ax\|_v ; x \in \mathbb{R}^n, \|x\|_v \leq 1 \} \\ &= \max \{ \|Ax\|_v ; x \in \mathbb{R}^n, \|x\|_v = 1 \} \end{aligned}$$

$\|A\|_i$ se numește *normă matricială naturală* sau *normă indusă* de norma vectorială $\|\cdot\|_v$

Avem următoarea relație:

$$\|Ax\|_v \leq \|A\|_i \|x\|_v, \forall A \in \mathbb{R}^{n \times n}, \forall x \in \mathbb{R}^n.$$

Norma Frobenius $\|\cdot\|_F$ nu este o normă naturală.

$$\|I_n\|_i = \max\left\{ \frac{\|I_n x\|_v}{\|x\|_v}; x \neq 0 \right\} = 1, \quad \forall \|\cdot\|_i,$$

$$\|I_n\|_F = (1 + 1 + \cdots + 1)^{1/2} = \sqrt{n} \neq 1 \text{ pentru } n \geq 2.$$

Pentru $\|x\|_1 = \sum_{i=1}^n |x_i|$ norma matricială indusă este:

$$\|A\|_1 = \max\left\{\sum_{i=1}^n |a_{ij}|; j = 1, 2, \dots, n\right\}$$

Pentru $\|x\|_\infty = \max\{|x_i|; i = 1, \dots, n\}$ norma matricială indusă este:

$$\|A\|_\infty = \max\left\{\sum_{j=1}^n |a_{ij}|; i = 1, 2, \dots, n\right\}.$$

- $\|\cdot\|_{\mathbf{v}}$ și $\|\cdot\|_{\mathbf{v},\mathbf{P}}$ - **norme vectoriale** $\rightarrow \|\cdot\|_{\mathbf{i}}$ și respectiv $\|\cdot\|_{\mathbf{i},\mathbf{P}}$
normele matriciale induse

$$\|\mathbf{x}\|_{\mathbf{v},\mathbf{P}} = \|\mathbf{P}\mathbf{x}\|_{\mathbf{v}} \quad \rightarrow \quad \|\mathbf{A}\|_{\mathbf{i},\mathbf{P}} = \|\mathbf{P}\mathbf{A}\mathbf{P}^{-1}\|_{\mathbf{i}}$$

Valori și vectori proprii

Definiții

Fie $A \in \mathbb{R}^{n \times n}$. Se numește *valoare proprie (autovaloare)* a matricii A un număr complex $\lambda \in \mathbb{C}$ pentru care există un vector nenul $x \in \mathbb{C}^n$, $x \neq 0$ a.î.:

$$Ax = \lambda x.$$

Vectorul x se numește *vector propriu (autovector)* asociat val. proprii λ .

$$Ax = \lambda x \Leftrightarrow (\lambda I_n - A)x = 0, x \neq 0 \Leftrightarrow \det(\lambda I_n - A) = 0$$

→ Matricea $\lambda I_n - A$ este singulară.

Polinomul:

$$p_A(\lambda) = \det(\lambda I_n - A) = \lambda^n - a_1 \lambda^{n-1} - a_2 \lambda^{n-2} - \dots - a_{n-1} \lambda - a_n$$

se numește *polinom caracteristic* asociat matricii A .

→ **grad** $p_A = n \rightarrow$ are n rădăcini care sunt valorile proprii ale matricii A .

Se numește *rază spectrală* a matricii A :

$$\rho(A) = \max\{|\lambda_i|, i = 1, \dots, n, \lambda_i - \text{valorile proprii ale matricii } A\}$$

$$\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2} \quad \text{norma indusă este}$$

$$\|A\|_2 = |A| = \sqrt{\rho(A^T A)} \quad \text{se numește } \textit{norma spectrală}.$$

Propoziția 1

Fie $\|\cdot\|$ o normă matricială naturală. Atunci:

$$\rho(A) \leq \|A\|, \forall A \in \mathbb{R}^{n \times n}.$$

Fie $A \in \mathbb{R}^{n \times n}$, $\{A^k\}$ un șir de matrici.

$$A^k \rightarrow \mathbf{0}_{n \times n}, k \rightarrow \infty \Leftrightarrow \|A^k\| \rightarrow 0, k \rightarrow \infty.$$

Propoziția 2

Fie $A \in \mathbb{R}^{n \times n}$. Atunci:

$$A^k \rightarrow \mathbf{0}, k \rightarrow \infty \Leftrightarrow \rho(A) < 1.$$

Dacă există o normă matricială naturală pentru care $\|A\| < 1$ atunci:

$$A^k \rightarrow \mathbf{0} \text{ pentru } k \rightarrow \infty.$$

$$(n = 1 \rightarrow a \in \mathbb{R}, a^k \rightarrow 0 \text{ pentru } k \rightarrow \infty \Leftrightarrow |a| < 1.)$$

Propoziția 3

Fie $A \in \mathbb{R}^{n \times n}$. Seria $\sum_{k=0}^{\infty} A^k$ converge dacă și numai dacă raza spectrală a matricii A este subunitară:

$$\sum_{k=0}^{\infty} A^k = S \Leftrightarrow \rho(A) < 1.$$

Dacă există o normă a matricii A astfel încât $\|A\| < 1$ atunci seria converge. În cazul convergenței avem :

$$\sum_{k=0}^{\infty} A^k = S = (I - A)^{-1}.$$

Propoziția 4

Fie $A \in \mathbb{R}^{n \times n}$ pentru care există o normă matricială naturală astfel ca $\|A\| < 1$. Atunci există matricile $(I_n \pm A)^{-1}$ și avem evaluările:

$$\frac{1}{1 + \|A\|} \leq \|(I \pm A)^{-1}\| \leq \frac{1}{1 - \|A\|}.$$

Surse de erori în calculule numerice

1. Erori în datele de intrare:

- măsurători afectate de erori sistematice sau perturbații temporare,
- erori de rotunjire: $1/3$, π , $1/7, \dots$

2. Erori de rotunjire în timpul calculelor:

- datorate capacității limitate de memorare a datelor, operațiile nu sunt efectuate exact.

3. Erori de discretizare:

- limita unui șir , suma unei serii , funcții neliniare approximate de funcții liniare, aproximarea derivatei unei funcții

4. Simplificări în modelul matematic

- idealizări , ignorarea unor parametri.

5. Erori umane și erori ale bibliotecilor folosite...

Eroare absolută , eroare relativă

a – valoarea exactă,

\tilde{a} – valoarea aproximativă.

Eroare absolută : $a - \tilde{a}$ sau $|a - \tilde{a}|$ sau $\|a - \tilde{a}\|$

$$a = \tilde{a} \pm \Delta_a, |a - \tilde{a}| \leq \Delta_a$$

Eroare relativă: $a \neq 0$ $\frac{a - \tilde{a}}{a}$ sau $\frac{|a - \tilde{a}|}{|a|}$ sau $\frac{\|a - \tilde{a}\|}{\|a\|}$

$$\frac{|a - \tilde{a}|}{|a|} \leq \delta_a \quad (\delta_a \text{ se exprimă de regulă în } \%).$$

În aproximările $1\text{kg} \pm 5\text{g}$, $50\text{g} \pm 5\text{g}$ erorile absolute sunt egale dar pentru prima cantitate eroarea relativă este 0,5% iar pentru a doua eroarea relativă este 10%.

$$a_1 = \tilde{a}_1 \pm \Delta_{a_1}, a_2 = \tilde{a}_2 \pm \Delta_{a_2},$$

$$a_1 \pm a_2 = (\tilde{a}_1 \pm \tilde{a}_2) \pm (\Delta_{a_1} \pm \Delta_{a_2})$$

$$\Delta_{a_1+a_2} \leq \Delta_{a_1} + \Delta_{a_2}.$$

a_1 cu eroare relativă δ_{a_1} și a_2 cu eroare relativă δ_{a_2} :

$$a = a_1 * a_2 \text{ sau } \frac{a_1}{a_2} \text{ rezultă } \delta_a = \delta_{a_1} + \delta_{a_2}.$$

Condiționare \leftrightarrow stabilitate

Condiționarea unei probleme caracterizează sensibilitatea soluției în raport cu perturbarea datelor de intrare, în ipoteza unor calcule exacte (independent de algoritmul folosit pentru rezolvarea problemei).

Fie \mathbf{x} datele exacte de intrare, $\tilde{\mathbf{x}}$ o aproximație cunoscută a acestora, $P(\mathbf{x})$ soluția exactă a problemei și $P(\tilde{\mathbf{x}})$ soluția problemei cu $\tilde{\mathbf{x}}$ ca date de intrare. Se presupune că s-au făcut calcule exacte la obținerea soluțiilor $P(\mathbf{x})$ și $P(\tilde{\mathbf{x}})$.

O problemă se consideră a fi *prost condiționată* dacă $P(\mathbf{x})$ și $P(\tilde{\mathbf{x}})$ diferă mult chiar dacă eroarea relativă $\frac{\|\mathbf{x} - \tilde{\mathbf{x}}\|}{\|\mathbf{x}\|}$ este mică.

Condiționarea numerică a unei probleme este exprimată prin amplificarea erorii relative:

$$k(\mathbf{x}) = \frac{\frac{\|P(\mathbf{x}) - P(\tilde{\mathbf{x}})\|}{\|P(\mathbf{x})\|}}{\frac{\|\mathbf{x} - \tilde{\mathbf{x}}\|}{\|\mathbf{x}\|}} \quad \text{pentru } \mathbf{x} \neq \mathbf{0} \text{ și } P(\mathbf{x}) \neq \mathbf{0}$$

O valoare mică pentru $k(\mathbf{x})$ caracterizează o problemă bine-condiționată.

Condiționarea este o proprietate locală (se evaluează pentru diverse date de intrare \mathbf{x}). O problemă este bine-condiționată dacă este bine-condiționată în orice punct.

Pentru rezolvarea unei probleme P , calculatorul execută un algoritm \tilde{P} . Deoarece se folosesc numere în virgulă mobilă, calculele sunt afectate de erori:

$$P(\mathbf{x}) \neq \tilde{P}(\mathbf{x})$$

Stabilitatea numerică exprimă mărimea erorilor numerice introduse de algoritm, în ipoteza unor date de intrare exacte,

$$\|P(x) - \tilde{P}(x)\| \text{ sau } \frac{\|P(x) - \tilde{P}(x)\|}{\|P(x)\|}.$$

O eroare relativă de ordinul erorii de rotunjire caracterizează un *algoritm numeric stabil*.

Un **algoritm numeric stabil** aplicat unei probleme bine condiționate conduce la rezultate cu precizie foarte bună.

Un algoritm \tilde{P} destinat rezolvării problemei P este numeric stabil dacă este îndeplinită una din condițiile:

1. $\tilde{P}(\mathbf{x}) \approx P(\mathbf{x})$ pentru orice intrare \mathbf{x} ;

2. există $\tilde{\mathbf{x}}$ apropiat de \mathbf{x} , astfel ca $\tilde{P}(\mathbf{x}) \approx P(\tilde{\mathbf{x}})$

\mathbf{x} = datele exacte,

$P(\mathbf{x})$ = soluția exactă folosind date exacte,

$\tilde{P}(\mathbf{x})$ = soluția „*calculată*” folosind algoritmul \tilde{P} cu date
exacte de intrare

Rezolvarea sistemelor liniare

Istoric

- 1900 î.Hr., Babilon - apar primele probleme legate de ecuații liniare simultane
- 300 î.Hr. Babilon - tăbliță cu următoarea problemă:
”Avem două câmpuri de arie totală 1800 ha. Producția la hectar pe primul câmp este de $\frac{2}{3}$ bușel (=36,3l) iar pe al doilea este de $\frac{1}{2}$ bușel. Dacă producția totală este de 1100 bușeli, să se determine aria fiecărui teren în parte.”

- 200-100 î.Hr. China – *9 capitole despre arta matematică* – metodă de rezolvare foarte asemănătoare eliminării Gauss
(„*Avem 3 tipuri de grâu. Știm că 3 baloturi din primul tip, 2 baloturi din al doilea tip și 1 balot din al treilea tip cântăresc 39 măsuri. De asemenea, 2 baloturi din primul tip, 3 baloturi din al doilea tip și 1 balot din al treilea tip cântăresc 34 măsuri și 1 balot din primul tip, 2 baloturi din al doilea tip și 3 baloturi din al treilea tip cântăresc 26 măsuri. Câte măsuri cântărește un balot din fiecare tip de grâu*”)

- 1545, Cardan – în *Ars Magna*, propune o regulă (*regula de modo*) pentru rezolvarea unui sistem de 2 ecuații cu 2 necunoscute (seamănă cu regula lui Cramer)
- 1683, Seki Kowa, Japonia - ideea de „*determinant*”- „*Method of solving the dissimulated problems*”. Calculează ceea ce astăzi cunoaștem sub numele de determinant, determinanții matricelor 2×2 , 3×3 , 4×4 , 5×5 în legătură cu rezolvarea unor ecuații dar nu a sistemelor de ecuații.

- 1683, Leibniz într-o scrisoare către l'Hôpital explică faptul că sistemul de ecuații:

$$10 + 11x + 12y = 0$$

$$20 + 21x + 22y = 0$$

$$30 + 31x + 32y = 0$$

are soluție deoarece :

$$10*21*32+11*22*30+12*20*31=10*22*31+11*20*32+12*21*30$$

(condiția ca determinantul metricii coeficienților este 0).

Leibniz era convins că o notație matematică bună este cheia progresului și experimentează mai mult de 50 de moduri diferite de a scrie coeficienții unui sistem de ecuații. Leibniz folosește termenul de „*rezultant*” în loc de determinant și a demonstrat regula lui Cramer pentru „rezultanți”. Știa că orice determinant poate fi dezvoltat în raport cu o coloană – operația se numește azi dezvoltarea Laplace.

- 1750, Cramer prezintă o formulă bazată pe determinanți pentru rezolvarea unui sistem de ecuații liniare – *regula lui Cramer* – „*Introduction in the analysis of algebraic curves*” (dă o regulă generală pentru sisteme $n \times n$:
„One finds the value of each unknown by forming n fractions of which the common denominator has as many terms as there are permutations of n things’
- 1764 Bezout, 1771 Vandermonde, 1772 Laplace – reguli de calcul al determinanților

- 1773 Lagrange – prima utilizare implicită a matricelor în legătură cu formele biliniare ce apar la optimizarea unei funcții reale de 2 sau mai multe variabile (dorea să caracterizeze punctele de maxim și minim a funcțiilor de mai multe variabile)

- 1800-1801, Gauss introduce noțiunea de „*determinant*” (determină proprietățile forme pătratică) – *Disquisitiones arithmeticae*(1801); descrie operațiile de înmulțire matricială și inversă a unei matrici în contextul tabloului coeficienților unei forme pătratică. Gauss dezvoltă *eliminarea Gaussiană* pe când studia orbita asteroidului Pallas de unde obține un sistem liniar cu 6 ecuații cu 6 necunoscute.

- 1812, Cauchy folosește termenul de „*determinant*” în sensul cunoscut azi.
- 1826, Cauchy găsește valorile proprii și deduce rezultate legate de diagonalizarea unei matrici. Introduce noțiunea de matrici asemenea și demonstrează ca acestea au aceeași ecuație caracteristică. Demonstrează că orice matrice reală simetrică este diagonalizabilă.

- 1850, Sylvester introduce pentru prima data termenul de *matrice* (din latină, „uter” – un loc unde ceva se formează sau este produs, „*an oblong arrangement of terms*”)
- 1855, Cayley – algebră matricială, prima definiție abstarctă a unei matrici. Studiază transformările liniare și compunerea lor ceea ce îl conduce la operațiile cu matrici (adunare, înmulțire, înmulțirea cu un scalar, inversa)

- 1858, Cayley în *Memoriu asupra teoriei matricilor* : „*Sunt multe lucruri de spus despre această teorie a matricilor și, după părerea mea, această teorie ar trebui să preceadă teoria determinanților*”
- Jordan (1870 – Treatise on substitutions and algebraic equations – forma canonică Jordan), Frobenius (1878 – On linear substitutions and bilinear forms, rangul unei matrici), Peano

- 1890, Weierstrass – On determinant theory, definiția axiomatică a determinantului
- 1925, Heisenberg reinventează algebra matricială pentru mecanica cuantică
- 1947, vonNeuman & Goldstine introduc numerele de condiționare atunci când analizează erorile de rotunjire
- 1948, Turing introduce descompunerea LU a unei matrici
- 1958, Wilkinson dezvoltă factorizarea QR

....