

Tema nr. 6

Fie $p \in \mathbf{N}^*$ și $n \in \mathbf{N}^*$ dimensiunile matricii A , $p \geq n$, ϵ - precizia calculelor, matricea $A \in \mathbf{R}^{p \times n}$, vectorul $b \in \mathbf{R}^p$.

- Pentru $p = n > 500$ să se genereze aleator o matrice pătratică, rară și simetrică ($A = A^T$), folosind schema de memorare cu liste descrisă în *Tema 3*. De asemenea, să se genereze structurile rare citind matricea din fișierul postat pe pagina cursului.
- Pentru $p = n$ și A matrice simetrică ($A = A^T$) și rară să se implementeze metoda puterii pentru aproximarea celei mai mari valori proprii a matricii A și a unui vector propriu asociat. După citirea matricii din fișier, să se verifice dacă matricea este simetrică. Să se afișeze valorile proprii de modul maxim approximate pentru matricea generată aleator și pentru cea din fișier.
- Cazul $p > n$ (matrici clasice, nerare): utilizând descompunerea după valori singulare (**S**ingular **V**alue **D**ecomposition) din biblioteca folosită la *Tema 2*, să se calculeze și să se afișeze:
 - valorile singulare ale matricii A ,
 - rangul matricii A ,
 - numărul de condiționare al matricii A ,
 - norma $\|A - USV^T\|_\infty$,
 - matricea $A_s = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_s u_s v_s^T$ și norma $\|A - A_s\|_\infty$ unde $s \leq \text{rang}(A)$, este un număr natural citit de la tastatură.

Vectori și valori proprii - definiții

Fie $A \in \mathbf{R}^{n \times n}$ o matrice reală de dimensiune n . Se numește *valoare proprie* asociată matricii A , numărul complex $\lambda \in \mathbf{C}$, pentru care există un vector nenul $u \neq 0$ numit și *vector propriu* asociat valorii proprii λ pentru care:

$$Au = \lambda u$$

Valorile proprii ale matricii A pot fi definite și ca rădăcini ale polinomului caracteristic asociat matricii A , $p_A(\lambda)$:

$$p_A(\lambda) = \det(\lambda I - A) = 0$$

Polinomul caracteristic este un polinom de grad n , deci orice matrice de dimensiune n are n valori proprii (reale și/sau complex conjugate).

Despre matricile simetrice se poate arăta că au toate valorile proprii reale.

Metoda puterii

Fie $A \in \mathbf{R}^{n \times n}$ o matrice simetrică. Se poate arăta că, pentru un vector $x \in \mathbf{R}^n, x \neq 0$, șirul de vectori:

$$\frac{x}{\|x\|_2}, \frac{Ax}{\|Ax\|_2}, \frac{A^2x}{\|A^2x\|_2}, \frac{A^3x}{\|A^3x\|_2}, \dots \quad (1)$$

converge la vectorul propriu asociat valorii proprii de modul maxim.

Se definește *coeficientul Rayleigh* pentru un vector $x \in \mathbf{R}^n$ ca fiind numărul real:

$$r(x) = \frac{x^T Ax}{x^T x} = \frac{(Ax, x)_{\mathbf{R}^n}}{\|x\|_2^2}$$

În relațiile de mai sus am notat cu $\|\cdot\|_2, (\cdot, \cdot)_{\mathbf{R}^n}$ norma euclidiană a unui vector și respectiv produsul scalar a doi vectori.

Coeficientul Rayleigh are proprietatea că dacă x este vector propriu al matricii A asociat valorii proprii λ atunci $r(x) = \lambda$. Dacă, atunci când se calculează șirul (1), se calculează și coeficienții Rayleigh pentru vectorii din șir, obținem o metodă de aproximare a valorii proprii de modul maxim.

Ținând cont de observațiile de mai sus putem descrie metoda puterii astfel:

Metoda puterii - schema algoritmului

se alege vectorul $v^{(0)} \in \mathbf{R}^n$ aleator, dar cu $\|v^{(0)}\|_2 = 1$;

$w = Av^{(0)}$;

$\lambda_0 = (w, v^{(0)})_{\mathbf{R}^n}$;

$k = 0$;

do

$v^{(k+1)} = \frac{1}{\|w\|_2} w$;

$w = Av^{(k+1)}$;

$\lambda_{k+1} = (w, v^{(k+1)})_{\mathbf{R}^n}$;

$k++$;

while ($\|w - \lambda_k v^{(k)}\|_2 > n\epsilon$ și $k \leq k_{max}$);

(la introducerea datelor, se pot lua $\epsilon \leq 10^{-9}$ și $k_{max} = 1000000$)

Dacă se iese din bucla *while* pe varianta $k > k_{max}$ algoritmul nu a reușit să calculeze valoarea proprie de modul maxim și un vector propriu asociat. În acest caz se poate încerca mărirea valorii lui ϵ și reluarea calculelor.

Dacă s-a ieșit pe cealaltă variantă, ($\|Av^{(k)} - \lambda_k v^{(k)}\|_2 \leq n\epsilon$), în λ_{k+1} avem o aproximare a unei valori proprii de modul maxim a matricii A , iar în $v^{(k+1)}$ o aproximare a unui vector propriu asociat acestei autovalori.

În algoritmul de mai sus nu este nevoie să alocăm șiruri pentru λ_k și $v^{(k)}$ ci avem nevoie doar de un singur element pentru fiecare șir: $\lambda \in \mathbf{R}$ pentru a memora valoarea lui λ_k și $v \in \mathbf{R}^n$ pentru $v^{(k)}$.

Alegerea vectorului inițial $v^{(0)}$ cu $\|v^{(0)}\|_2 = 1$ se poate face pornind de la un vector nenul generat aleator, $x \in \mathbf{R}^n$, $x \neq 0$, și punând:

$$v^{(0)} = \frac{1}{\|x\|_2} x$$

Metoda puterii - schema algoritmului

se alege vectorul $v \in \mathbf{R}^n$ aleator, de normă euclidiană 1, $\|v\|_2 = 1$;

$$(v = \frac{1}{\|x\|_2} x, \ x \in \mathbf{R}^n, x \neq 0)$$

$$w = Av ;$$

$$\lambda = (w, v)_{\mathbf{R}^n} ;$$

$$k = 0;$$

do

$$v = \frac{1}{\|w\|_2} w ;$$

$$w = Av ;$$

$$\lambda = (w, v)_{\mathbf{R}^n} ;$$

$$k++ \quad ;$$

while ($\|w - \lambda v\|_2 > n\epsilon$ și $k \leq k_{max}$);

Descompunerea după valori singulare

(Singular Value Decomposition)

Fie $A \in \mathbf{R}^{p \times n}$. Se numește descompunere după valori singulare a matricii:

$$A = USV^T \quad , \quad U \in \mathbf{R}^{p \times p} \quad , \quad S \in \mathbf{R}^{p \times n} \quad , \quad V \in \mathbf{R}^{n \times n}$$

cu $U = [u_1 \ u_2 \ \dots \ u_p]$ (vectorii u_i sunt coloanele matricii U) și $V = [v_1 \ v_2 \ \dots \ v_n]$ matrici ortogonale iar S matrice de forma:

$$\text{pentru } p \leq n \quad S = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 & \cdots & 0 \\ \vdots & & & & & \\ 0 & 0 & \cdots & \sigma_p & \cdots & 0 \end{pmatrix} \in \mathbf{R}^{p \times n}$$

$$\text{pentru } p > n \quad S = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & & & \\ 0 & 0 & \cdots & \sigma_n \\ \vdots & & & \\ 0 & 0 & \cdots & 0 \end{pmatrix} \in \mathbf{R}^{p \times n}$$

unde numerele nenegative $\sigma_i \geq 0, \forall i$ sunt valorile singulare ale matricii A .

Rangul matricii A este numărul de valori singulare strict pozitive:

$$\text{rang}(A) = \text{numărul de valori singulare } \sigma_i > 0.$$

Numărul de condiționare al matricii A este raportul dintre cea mai mare valoare singulară și cea mai mică valoare singulară strict pozitivă.

$$k_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}} \quad ,$$

$$\sigma_{\max} = \max\{\sigma_i; \sigma_i \text{ valoare singulară}\} \quad ,$$

$$\sigma_{\min} = \min\{\sigma_i; \sigma_i > 0 \text{ valoare singulară}\}$$

Pentru calculul matricilor $A_s = \sum_{i=1}^s \sigma_i u_i v_i^T$ se folosesc primele s coloane ale matricilor U și V . O matrice $u_i v_i^T$ are forma:

$$u = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix}, \quad v = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad uv^T = \begin{pmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_n \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_n \end{pmatrix}.$$

Matricile de forma $W = uv^T \in \mathbf{R}^{p \times n}$ au aceeași dimensiune ca matricea A , $W = (w_{ij} = x_i y_j; i = 1, \dots, p, j = 1, \dots, n)$.