

# **Calcul Numeric**

**Cursul 13**

**2017**

*Anca Ignat*

## Optimizare numerică

$$\min \{ f(x) ; x \in \mathbb{R}^n \} , \quad f : \mathbb{R}^n \rightarrow \mathbb{R}$$

Un punct  $x^* \in \mathbb{R}^n$  se numește **punct de minim global** pentru funcția  $f$  dacă  $f(x^*) \leq f(x) \quad \forall x \in \mathbb{R}^n$ .

Un punct  $x^* \in \mathbb{R}^n$  se numește **punct de minim local** pentru funcția  $f$  dacă există o vecinătate  $V$  a punctului  $x^*$  pentru care  $f(x^*) \leq f(x) \quad \forall x \in V$ .

Un punct  $x^* \in \mathbb{R}^n$  se numește **punct de minim strict local** pentru funcția  $f$  dacă există o vecinătate  $V$  a punctului  $x^*$  pentru care  $f(x^*) < f(x) \quad \forall x \in V, x \neq x^*$ .

$$V = S(x^*, r) = \{ x \in \mathbb{R}^n ; \|x - x^*\| \leq r \}.$$

Dacă funcția  $f \in C^1(\mathbb{R}^n)$  se numește **gradient** al funcției  $f$  în punctul  $\mathbf{x}$  vectorul:

$$\nabla f(\mathbf{x}) = \left( \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)^T.$$

Dacă funcția  $f \in C^2(\mathbb{R}^n)$  se numește **matrice hessiană** a funcției  $f$  în punctul  $\mathbf{x}$  matricea:

$$\nabla^2 f(\mathbf{x}) = \left( \frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}) \right)_{i,j=1,\dots,n}$$

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(\mathbf{x}) & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_2^2}(\mathbf{x}) & \dots & \frac{\partial^2 f}{\partial x_2 \partial x_n}(\mathbf{x}) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_n \partial x_2}(\mathbf{x}) & \dots & \frac{\partial^2 f}{\partial x_n^2}(\mathbf{x}) \end{pmatrix}$$

## Teorema lui Taylor

Dacă funcția  $f \in C^1(\mathbb{R}^n)$  este continuu diferențiabilă atunci există  $t \in (0,1)$  astfel ca:

$$f(x + p) = f(x) + \nabla f(x + tp)^T p. \quad (1)$$

Dacă  $f \in C^2(\mathbb{R}^n)$  este de două ori continuu diferențiabilă atunci există  $t \in (0,1)$  astfel ca:

$$f(x + p) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x + tp) p. \quad (2)$$

## **Teorema 1** (condiții necesare de optim de ordinul întâi)

Fie  $f \in C^1(\mathbb{R}^n)$  și  $x^* \in \mathbb{R}^n$  un punct de minim local pentru  $f$ .  
Atunci  $\nabla f(x^*) = 0$ .

Demonstrație: Presupunem prin reducere la absurd că  $\nabla f(x^*) \neq 0$ . Fie  $p = -\nabla f(x^*)$ . Avem:

$$p^T \nabla f(x^*) = -\|\nabla f(x^*)\| < 0.$$

Deoarece  $\nabla f$  este continuă în vecinătatea lui  $x^*$ , există  $T > 0$  astfel ca:

$$p^T \nabla f(x + tp) < 0, \quad \forall t \in [0, T].$$

Pentru orice  $s \in (0, T]$ , din Teorema lui Taylor avem:

$$f(x^* + sp) = f(x^*) + sp^T \nabla f(x^* + tp), \quad \text{pentru un } t \in (0, s).$$

Prin urmare  $f(x^* + sp) < f(x^*) \forall s \in (0, T]$ , ceea ce implică faptul că  $x^*$  nu este punct de minim local.

Un punct  $x^*$  pentru care  $\nabla f(x^*) = \mathbf{0}$  se numește **punct staționar**. Teorema de mai sus spune că orice punct de minim local trebuie să fie punct staționar.

**Teorema 2** (condiții necesare de optim de ordinul al doilea)

Fie  $f \in C^2(\mathbb{R}^n)$  și  $x^* \in \mathbb{R}^n$  un punct de minim local pentru  $f$ . Atunci  $\nabla f(x^*) = \mathbf{0}$  și matricea hessiană  $\nabla^2 f(x^*)$  este pozitiv semidefinită.

O matrice  $A \in \mathbb{R}^{n \times n}$  este **pozitiv semidefinită** dacă

$$(Ax, x)_{\mathbb{R}^n} \geq 0 \quad \forall x \in \mathbb{R}^n$$

și este **pozitiv definită** dacă

$$(Ax, x)_{\mathbb{R}^n} > 0 \quad \forall x \in \mathbb{R}^n, x \neq 0.$$

Demonstrație: Din Teorema 1 rezultă că  $\nabla f(x^*) = 0$ .

Presupunem prin reducere la absurd că matricea hessiană în  $x^*$  nu este pozitiv semidefinită, adică există un vector  $p$  pentru care  $p^T \nabla^2 f(x^*) p < 0$  și deoarece matricea hessiană este continuă avem  $p^T \nabla^2 f(x^* + tp) p < 0 \quad \forall t \in [0, T]$ .

Folosind relația (2) din Teorema lui Taylor, avem  $\forall s \in (0, T]$ :

$$f(x^* + sp) = f(x^*) + s \nabla f(x^*)^T p + \frac{1}{2} s^2 p^T \nabla^2 f(x^* + tp) p < f(x^*).$$



### Teorema 3 (condiții suficiente de ordinul al doilea)

Fie  $f \in C^2(\mathbb{R}^n)$  și  $x^* \in \mathbb{R}^n$  un punct pentru care  $\nabla f(x^*) = 0$  și matricea hessiană  $\nabla^2 f(x^*)$  este pozitiv definită. Atunci  $x^*$  este punct de minim strict local pentru  $f$ .

Demonstrație: Deoarece  $\nabla^2 f$  este continuă matricea hessiană este pozitiv definită într-o vecinătate  $V = S(x^*, r)$  a punctului  $x^*$ . Fie  $p \neq 0$  cu  $\|p\| < r$  atunci  $x^* + p \in V$  și:

$$\begin{aligned} f(x^* + p) &= f(x^*) + \nabla f(x^*)^T p + \frac{1}{2} p^T \nabla^2 f(x^* + tp) p \\ &= f(x^*) + \frac{1}{2} p^T \nabla^2 f(x^* + tp) p, \quad t \in (0, 1) \end{aligned}$$

de unde deducem că:

$$f(x^*) < f(x^* + p) \quad \forall p, \|p\| < r, p \neq 0$$

O funcție  $f$  se numește **convexă** dacă:

$$f(ax_1 + (1-a)x_2) \leq af(x_1) + (1-a)f(x_2), \quad \forall x_1, x_2 \in \mathbb{R}^n, \forall a \in [0,1].$$

## Teorema

Dacă  $f$  este funcție convexă orice punct de minim local este punct de minim global. Dacă în plus  $f \in C^1(\mathbb{R}^n)$  atunci orice punct staționar este punct de minim global.

## Metode de descreştere

Se numeşte **direcţie de descreştere** a funcţiei  $f$  în punctul  $x$  un vector  $d \in \mathbb{R}^n$  pentru care

$$f(x + \alpha d) \leq f(x) \quad , \quad \forall \alpha \in [0, \bar{\alpha}).$$

### Teorema

Fie  $f \in C^1(\mathbb{R}^n)$ . Un vector  $d$  este direcţie de descreştere pentru  $f$  în  $x$  dacă şi numai dacă:

$$\nabla f(x)^T d = (d, \nabla f(x))_{\mathbb{R}^n} < 0.$$

## *Algoritm de descreștere*

1. alege  $\mathbf{x} \in \mathbb{R}^n$

2. do

- găsește o direcție de descreștere  $\mathbf{d}$  a lui  $f$  în  $\mathbf{x}$

- găsește  $\tilde{\alpha} > 0$  astfel ca

$$f(\mathbf{x} + \tilde{\alpha}\mathbf{d}) = \min\{f(\mathbf{x} + \alpha\mathbf{d}); \alpha \in (0, \bar{\alpha})\}$$

(ajustarea pasului – line search)

- $\mathbf{x} = \mathbf{x} + \tilde{\alpha}\mathbf{d}$

while (nu am găsit soluția)

## Ajustarea pasului (line search)

Trebuie rezolvată o problemă de minimizare unidimensională

$$\min\{g(a) ; a \in [b, c]\}$$

## Metoda Newton

Fie  $a_k$  aproximarea curentă a soluției problemei de minimizare de mai sus. Vom folosi dezvoltarea în serie Taylor a funcției  $g$

$$g(a) = g(a_k) + g'(a_k)(a - a_k) + \frac{1}{2}g''(a_k)(a - a_k)^2 + \frac{1}{3!}g'''(a_k)(a - a_k)^3$$

$$q(a) = g(a_k) + g'(a_k)(a - a_k) + \frac{1}{2}g''(a_k)(a - a_k)^2$$

Pentru  $a \approx a_k$  putem considera că funcția  $q$  aproximează funcția  $g$ ,  $q(a) \approx g(a)$  și

$$\min\{g(a) ; a \in [c, b]\} \simeq \min\{q(a) ; a \in [c, b]\}.$$

Construim elementul  $a_{k+1}$  ca fiind soluția problemei:

$$q(a_{k+1}) = \min\{q(a) ; a \in [c, b]\}$$

$a_{k+1}$  este soluția ecuației

$$q'(a) = 0 \Leftrightarrow q'(a) = g'(a_k) + g''(a_k)(a - a_k) \Rightarrow \boxed{a_{k+1} = a_k - \frac{g'(a_k)}{g''(a_k)}}$$

## Metoda secantei

Dacă în relațiile de mai sus se face următoarea aproximare:

$$g''(a_k) \approx \frac{g'(a_k) - g'(a_{k-1})}{a_k - a_{k-1}}$$

obținem următoarea metodă de aproximare, numită și metoda secantei:

$$a_{k+1} = a_k - g'(a_k) \frac{a_k - a_{k-1}}{g'(a_k) - g'(a_{k-1})}$$

## Aproximare spline cubică

Vom folosi pentru a construi  $a_{k+1}$  pe  $a_{k-1}$ ,  $a_k$ ,  $g(a_{k-1})$ ,  $g(a_k)$ ,  $g'(a_{k-1})$ ,  $g'(a_k)$ . Aproximăm funcția  $g$  cu un polinom de grad 3

$$g(a) \approx q(a) = c_0 a^3 + c_1 a^2 + c_2 a + c_3$$

Funcția  $q$  (respectiv constantele  $c_i$ ) se calculează a.î.

$$\begin{aligned} q(a_{k-1}) &= g(a_{k-1}) \quad , \quad q(a_k) = g(a_k) \\ q'(a_{k-1}) &= g'(a_{k-1}) \quad , \quad q'(a_k) = g'(a_k) \end{aligned}$$

$a_{k+1}$  este punctul de minim al funcției  $q$



$$a_{k+1} = a_k - (a_k - a_{k-1}) \left[ \frac{g'(a_k) + u_2 - u_1}{g'(a_k) - g'(a_{k-1}) + 2u_2} \right]$$

$$u_1 = g'(a_{k-1}) + g'(a_k) - 3 \frac{g(a_k) - g(a_{k-1})}{a_k - a_{k-1}}$$

$$u_2 = \sqrt{u_1^2 - g'(a_{k-1})g'(a_k)}$$

## Ajustarea inexactă a pasului

$$f(x + \tilde{\alpha}d) \cong \min\{f(x + \alpha d); \alpha \in (0, \bar{\alpha})\}$$

- nu se obține  $\tilde{\alpha}$  optimal
- pentru reducerea timpului de calcul optimizarea se oprește înainte de a ajunge la soluție, în funcție de anumite criterii/teste de oprire

## Regula lui Armijo

$$g(a) = f(x_k + a d_k) \quad , \quad \bar{g}(a) = g(0) + \varepsilon a g'(0) \quad , \quad \varepsilon \in (0,1)$$

$\bar{a}$  este acceptabil după regula lui Armijo dacă

$$(1) \quad g(\bar{a}) \leq \bar{g}(\bar{a})$$

$$(2) \quad g(\sigma \bar{a}) \geq \bar{g}(\sigma \bar{a})$$

$k = 0$ ;

se alege  $a_0$

*while* (  $g(a_k) > \bar{g}(a_k)$  )

$$\cdot \quad a_{k+1} = \frac{1}{\sigma} a_k$$

$$\cdot \quad k = k + 1$$

$$(\sigma = 2 \text{ sau } 10 \quad , \quad \varepsilon = 0.2)$$

## Testul Goldstein

Dat  $\varepsilon \in (0, 2)$ ,  $\bar{\alpha}$  este considerat acceptabil dacă:

$$g(\bar{\alpha}) \leq \bar{g}(\bar{\alpha}) \text{ si } g(\bar{\alpha}) > g(0) + (1 - \varepsilon)g'(0)$$

$$x_{k+1} = x_k + \bar{\alpha} d_k$$


$\bar{\alpha}$  este acceptat dacă

$$\varepsilon \leq \frac{f(x_{k+1}) - f(x_k)}{\alpha \nabla f(x_k) d_k} \leq 1 - \varepsilon$$


## Testul Wolfe

$$\varepsilon \in (0, 2)$$


$$\begin{aligned}\bar{\alpha} : \quad & g(\bar{\alpha}) \leq \bar{g}(\bar{\alpha}) = g(0) + \varepsilon \bar{\alpha} g'(0) \\ & g'(\bar{\alpha}) \geq (1 - \varepsilon)g'(0)\end{aligned}$$



(a) Armijo rule



(b) Goldstein test



(c) Wolfe test

## Metoda pantei maxime

$$\min \{ f(x) ; x \in \mathbb{R}^n \} , \quad f : \mathbb{R}^n \rightarrow \mathbb{R}$$

$$x_0 \text{ dat} , \quad x_{k+1} = x_k + \alpha_k d_k , \quad k = 0, 1, \dots$$

$d_k$  direcție de descreștere a lui  $f$  în  $x_k$

$$\alpha_k > 0 \quad f(x_k + \alpha_k d_k) = \min \{ f(x_k + \alpha d_k) ; \alpha \in [0, \bar{\alpha}] \}$$

$d_k$  direcție de descreștere dacă :

$$\nabla f(x_k)^T d_k < 0.$$

Metoda pantei maxime:

$$d_k = -\nabla f(x_k)$$

Cazul pătratic:

$$f(x) = \frac{1}{2} x^T A x - x^T b = \frac{1}{2} (Ax, x)_{\mathbb{R}^n} - (b, x)_{\mathbb{R}^n}$$

$b \in \mathbb{R}^n$  ,  $A \in \mathbb{R}^{n \times n}$  simetrică și pozitiv definită

$A$  pozitiv definită  $\rightarrow \det A \neq 0$ ,  $f$  este strict convexă

$$\nabla f(x) = Ax - b \quad , \quad \nabla^2 f(x) = A$$



$$f(x^*) = \min\{f(x); x \in \mathbb{R}^n\} \quad x^* \text{ punct unic de minim} \Leftrightarrow$$

$$x^* \text{ soluția sistemului liniar } Ax = b, \quad x^* = A^{-1}b$$

$$g(x) = Ax - b$$

$$x_{k+1} = x_k - \alpha_k g_k, \quad g_k = Ax_k - b$$

$$\alpha_k = \arg \min\{f(x_k - \alpha g_k); \alpha \in [0, \bar{\alpha}]\}$$

$$\begin{aligned}
f(\mathbf{x}_k - \alpha \mathbf{g}_k) &= \frac{1}{2}(\mathbf{x}_k - \alpha \mathbf{g}_k)^T A(\mathbf{x}_k - \alpha \mathbf{g}_k) - (\mathbf{x}_k - \alpha \mathbf{g}_k)^T \mathbf{b} = \\
&= \frac{1}{2}(\mathbf{g}_k^T A \mathbf{g}_k) \alpha^2 - (\mathbf{g}_k^T A \mathbf{x}_k - \mathbf{g}_k^T \mathbf{b}) \alpha + f(\mathbf{x}_k) = \\
&= \frac{1}{2}(\mathbf{g}_k^T A \mathbf{g}_k) \alpha^2 - (\mathbf{g}_k^T \mathbf{g}_k) \alpha + f(\mathbf{x}_k)
\end{aligned}$$

$f(\mathbf{x}_k - \alpha \mathbf{g}_k)$  ecuație de gr. 2 în  $\alpha$ , coef. lui  $\alpha^2$ ,  $\mathbf{g}_k^T A \mathbf{g}_k > 0$

$$\alpha_{\min} = \alpha_k = \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_k^T A \mathbf{g}_k}$$

Metoda pantei maxime pentru funcționale pătratică:

$$\mathbf{x}_0 - \text{dat}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \left( \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_k^T \mathbf{A} \mathbf{g}_k} \right) \mathbf{g}_k \quad , \quad k = 0, 1, \dots$$

$$\mathbf{g}_k = \mathbf{A} \mathbf{x}_k - \mathbf{b}$$

$$E(\mathbf{x}) = \frac{1}{2} (\mathbf{x} - \mathbf{x}^*)^T \mathbf{A} (\mathbf{x} - \mathbf{x}^*) = f(\mathbf{x}) + \frac{1}{2} \mathbf{x}^{*T} \mathbf{A} \mathbf{x}^*$$

$$\nabla E(\mathbf{x}) = \nabla f(\mathbf{x}) = \mathbf{g}(\mathbf{x})$$

Șirul construit cu metoda pantei maxime satisface:

$$E(\mathbf{x}_{k+1}) = \left[ 1 - \frac{(\mathbf{g}_k^T \mathbf{g}_k)^2}{(\mathbf{g}_k^T A \mathbf{g}_k)(\mathbf{g}_k^T A^{-1} \mathbf{g}_k)} \right] E(\mathbf{x}_k)$$

Inegalitatea lui Kantorovich

$A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$ ,  $A > 0$  pozitiv definită

$$\frac{(\mathbf{x}^T \mathbf{x})^2}{(\mathbf{x}^T A \mathbf{x})(\mathbf{x}^T A^{-1} \mathbf{x})} \geq \frac{4cC}{(c + C)^2}$$

$c, C$  - cea mai mica și cea mai mare valoare proprie a lui  $A$ .

## Teoremă

Cazul pătratic: Pentru orice iterație inițială  $\mathbf{x}_0$ , șirul construit cu metoda pantei maxime converge la  $\mathbf{x}^*$  unicul punct de minim al funcției  $f$ .  
Avem:

$$E(\mathbf{x}_{k+1}) \leq \left( \frac{C - c}{C + c} \right)^2 E(\mathbf{x}_k)$$

Cazul general:  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $f \in C^2(\mathbb{R}^n)$ ,  $f$  are un punct de minim local  $\mathbf{x}^*$ . Presupunem că  $F(\mathbf{x}^*) = \nabla^2 f(\mathbf{x}^*)$  are  $c > 0$  cea mai mică valoare proprie și  $C > 0$  cea mai mare valoare proprie. Dacă șirul  $\{\mathbf{x}_k\}$  construit cu metoda pantei maxime converge la  $\mathbf{x}^*$  (la fiecare pas  $\mathbf{A} = \nabla^2 f(\mathbf{x}_k)$ ,  $\mathbf{b} = \nabla f(\mathbf{x}_k)$ ),  $\mathbf{x}_k \rightarrow \mathbf{x}^*$  atunci  $f(\mathbf{x}_k) \rightarrow f(\mathbf{x}^*)$  converge liniar cu o rată de convergență  $\leq \left( \frac{C - c}{C + c} \right)^2$ .

## Metoda Newton

$\mathbf{x}_k$  - punctul curent de aproximare

$$f(\mathbf{x}) \simeq f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T (\mathbf{x} - \mathbf{x}_k) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_k)^T \nabla^2 f(\mathbf{x}_k) (\mathbf{x} - \mathbf{x}_k) = g(\mathbf{y})$$

$g$  – funcțională pătratică,  $\mathbf{y} = \mathbf{x} - \mathbf{x}_k$ ,

$$g(\mathbf{y}) = \frac{1}{2} \mathbf{y}^T \mathbf{A} \mathbf{y} - \mathbf{y}^T \mathbf{b} + c$$

$$\mathbf{A} = \nabla^2 f(\mathbf{x}_k) \quad , \quad \mathbf{b} = -\nabla f(\mathbf{x}_k) \quad , \quad c = f(\mathbf{x}_k)$$

$\mathbf{y}^* = \arg \min \{g(\mathbf{y}); \mathbf{y} \in \mathbb{R}^n\}$  este unica soluție a sistemului liniar  $A\mathbf{y} = \mathbf{b}$  ,  $\mathbf{y}^* = A^{-1}\mathbf{b} = -[\nabla^2 f(\mathbf{x}_k)]^{-1} \nabla f(\mathbf{x}_k)$

Metoda Newton

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [\nabla^2 f(\mathbf{x}_k)]^{-1} \nabla f(\mathbf{x}_k) , \quad k = 0, 1, \dots , \quad \mathbf{x}_0 - \text{dat}$$

### Teoremă

Fie  $f \in C^3(\mathbb{R}^n)$  care are un punct de minim local  $\mathbf{x}^*$  astfel ca matricea  $\nabla^2 f(\mathbf{x}^*) > \mathbf{0}$  este pozitiv definită. Dacă punctul de început  $\mathbf{x}_0$  este suficient de aproape de  $\mathbf{x}^*$ ,  $\|\mathbf{x} - \mathbf{x}^*\| \leq r$ , atunci șirul  $\{\mathbf{x}_k\}$  generat cu metoda lui Newton converge la  $\mathbf{x}^*$  și ordinul de convergență este cel puțin 2.

## Variante ale metodei lui Newton

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k \left[ \nabla^2 f(\mathbf{x}_k) \right]^{-1} \nabla f(\mathbf{x}_k), \quad k = 0, 1, \dots$$

$\alpha_k$  se alege astfel ca :

$$f(\mathbf{x}_{k+1}) = \min \{ f(\mathbf{x}_k - \alpha \left[ \nabla^2 f(\mathbf{x}_k) \right]^{-1} \nabla f(\mathbf{x}_k)); \alpha \in [0, \bar{\alpha}] \}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha M_k \mathbf{g}_k, \quad \alpha > 0, \quad M_k \in \mathbb{R}^{n \times n}, \quad \mathbf{g}_k = \nabla f(\mathbf{x}_k)$$



$$\mathbf{M}_k = \mathbf{I}_n \quad \forall k - \text{panta maximă}$$

$$\mathbf{M}_k = [\nabla^2 f(\mathbf{x}_k)]^{-1} - \text{metoda Newton}$$

Cum alegem  $\mathbf{M}_k$ ?  $\mathbf{d}_k = -\mathbf{M}_k \mathbf{g}_k$  direcție de descreștere

$$f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T (\mathbf{x}_{k+1} - \mathbf{x}_k) + O(\|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2)$$

$$\begin{aligned} f(\mathbf{x}_{k+1}) &= f(\mathbf{x}_k) - \alpha \mathbf{g}_k^T \mathbf{M}_k \mathbf{g}_k + O(\alpha^2) \\ f(\mathbf{x}_{k+1}) &< f(\mathbf{x}_k), \quad \alpha > 0 \Rightarrow \mathbf{g}_k^T \mathbf{M}_k \mathbf{g}_k > 0 \end{aligned}$$

Luăm  $M_k > 0$  pozitiv definită

$$M_k = \left[ \varepsilon_k I_n + \nabla^2 f(x_k) \right]^{-1}, \quad \varepsilon_k > 0$$

Întotdeauna există  $\varepsilon_k > 0$  astfel ca matricea  $M_k > 0$  să fie pozitiv definită.

- Fie  $F_k = \nabla^2 f(x_k)$  și  $\delta > 0$  constantă fixată.
- Se calculează valorile proprii ale matricii  $F_k : \lambda_1, \lambda_2, \dots, \lambda_n$
- Se alege  $\varepsilon_k \geq 0$  cea mai mică constantă nenegativă pentru care matricea  $\varepsilon_k I_n + F_k$  are valorile proprii  $\geq \delta$ :

$$\varepsilon_k \geq 0 \ \& \ \varepsilon_k + \lambda_i \geq \delta, \ i = 1, \dots, n$$

$$\varepsilon_k \geq 0 \ \& \ \varepsilon_k = \max\{\delta - \lambda_i; \ i = 1, \dots, n\}$$

Noua direcție de descreștere este:

$$d_k = -\left(\varepsilon_k I_n + F_k\right)^{-1} g_k .$$

$$x_{k+1} = x_k + \alpha_k d_k, \ \alpha_k \text{ - se det. cu ajustarea pasului}$$

## Metoda gradientilor conjugați (a direcțiilor conjugate)

$A \in \mathbb{R}^{n \times n}$  ,  $A = A^T$  ,  $A > 0$  pozitiv definită

$$\min \{ f(x) = \frac{1}{2} x^T A x - x^T b ; x \in \mathbb{R}^n \}$$

### Definiție

Pentru o matrice  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$  simetrică, doi vectori  $d_1, d_2 \in \mathbb{R}^n$  se numesc  **$A$ -ortogonali** sau **conjugați în raport cu  $A$**  dacă:

$$d_1^T A d_2 = (A d_2, d_1)_{\mathbb{R}^n} = (d_2, A d_1)_{\mathbb{R}^n} = (A d_1, d_2)_{\mathbb{R}^n} = 0$$

$A = \mathbf{0}_{n \times n} \Rightarrow \forall d_1, d_2$  sunt  $A$ -ortogonali

$A = I_n \Rightarrow$  ortogonalitate clasică  $(d_1, d_2)_{\mathbb{R}^n} = 0$

Vectorii  $\{d_0, d_1, \dots, d_k\}$  se numesc  $A$ -ortogonali sau  $A$ -conjugăți dacă:

$$d_i^T A d_j = (A d_j, d_i)_{\mathbb{R}^n} = 0, \quad \forall i \neq j, \quad i, j = 0, 1, \dots, k$$

### Propoziție

Fie  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$ ,  $A > 0$ , și  $\{d_0, d_1, \dots, d_k\}$  direcții  $A$ -conjugate,  $d_i \neq 0$ ,  $\forall i = 0, \dots, k$ . Atunci vectorii  $\{d_0, d_1, \dots, d_k\}$  sunt liniar independenți.

$$\left. \begin{array}{l} A \in \mathbb{R}^{n \times n} \text{ , } A = A^T \text{ , } A > 0 \\ \{d_0, d_1, \dots, d_{n-1}\} \text{ - direcții } A \text{ - conjugate} \end{array} \right\} \Rightarrow \begin{array}{l} \{d_0, d_1, \dots, d_{n-1}\} \\ \text{bază în } \mathbb{R}^n \end{array}$$

$$x^* = \arg \min \{f(x); x \in \mathbb{R}^n\} \Leftrightarrow x^* \text{ soluția sist. } Ax = b$$

$$x^* = \alpha_0 d_0 + \alpha_1 d_1 + \dots + \alpha_{n-1} d_{n-1}$$

$$\left( \underbrace{Ax^*}_{=b}, d_i \right)_{\mathbb{R}^n} = d_i^T Ax^* = \alpha_i d_i^T A d_i$$

$$\alpha_i = \frac{d_i^T b}{d_i^T A d_i} = \frac{(b, d_i)_{\mathbb{R}^n}}{(A d_i, d_i)_{\mathbb{R}^n}}$$

$$x^* = \sum_{i=0}^{n-1} \frac{(b, d_i)_{\mathbb{R}^n}}{(A d_i, d_i)_{\mathbb{R}^n}} d_i$$

Procesul iterativ

$$x_0 \in \mathbb{R}^n - \text{dat}$$

$$x_{k+1} = x_k + \alpha_k d_k, \quad k = 0, 1, 2, \dots, n-1$$

$$\alpha_k = -\frac{g_k^T d_k}{d_k^T A d_k}, \quad g_k = A x_k - b$$

are proprietatea că  $x_n = x^*$ .

$$\mathbf{x}_k = \mathbf{x}_0 + \alpha_0 \mathbf{d}_0 + \alpha_1 \mathbf{d}_1 + \cdots + \alpha_{k-1} \mathbf{d}_{k-1}$$

$$\mathbf{x}^* = \mathbf{x}_0 + \beta_0 \mathbf{d}_0 + \beta_1 \mathbf{d}_1 + \cdots + \beta_{n-1} \mathbf{d}_{n-1}$$

$$\alpha_i = \frac{\mathbf{d}_i^T A(\mathbf{x}_k - \mathbf{x}_0)}{\mathbf{d}_i^T A \mathbf{d}_i} \quad , \quad \beta_i = \frac{\mathbf{d}_i^T A(\mathbf{x}^* - \mathbf{x}_0)}{\mathbf{d}_i^T A \mathbf{d}_i}$$

$$\mathbf{d}_k^T A(\mathbf{x}_k - \mathbf{x}_0) = 0$$

$$\mathbf{x}^* - \mathbf{x}_k = (\beta_0 - \alpha_0) \mathbf{d}_0 + \cdots + (\beta_{k-1} - \alpha_{k-1}) \mathbf{d}_{k-1} + \beta_k \mathbf{d}_k + \cdots + \beta_{n-1} \mathbf{d}_{n-1}$$

**Corolar**

$$\mathbf{g}_k^T \mathbf{d}_i = 0 \quad \forall i < k$$



## Algoritmul gradientilor conjugați

$$\mathbf{x}_0 \in \mathbb{R}^n, \mathbf{g}_0 = A\mathbf{x}_0 - \mathbf{b}$$

$$\mathbf{d}_0 = -\mathbf{g}_0 = \mathbf{b} - A\mathbf{x}_0$$

$$\alpha_k = -\frac{\mathbf{g}_k^T \mathbf{d}_k}{\mathbf{d}_k^T A \mathbf{d}_k}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

$$\mathbf{g}_{k+1} = A\mathbf{x}_{k+1} - \mathbf{b} \text{ sau } \mathbf{g}_{k+1} = \mathbf{g}_k + \alpha_k A \mathbf{d}_k$$

$$\beta_k = \frac{\mathbf{g}_{k+1}^T A \mathbf{d}_k}{\mathbf{d}_k^T A \mathbf{d}_k}$$

$$\mathbf{d}_{k+1} = -\mathbf{g}_{k+1} + \beta_k \mathbf{d}_k$$

$$\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_p \in \mathbb{R}^n$$

$$\begin{aligned} \text{span}\{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_p\} &= \{\mathbf{y} = \mathbf{a}_1 \mathbf{y}_1 + \dots + \mathbf{a}_p \mathbf{y}_p \in \mathbb{R}^n; \mathbf{a}_i \in \mathbb{R}, i = 1, \dots, p\} \\ &= \text{subspațiul generat de vectorii } \mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_p \end{aligned}$$

## Teoremă

Presupunem că  $\mathbf{x}_k \neq \mathbf{x}^*$ . Avem următoarele relații:

$$(1) \quad \mathbf{g}_k^T \mathbf{g}_i = 0 \quad \forall i = 0, 1, \dots, k-1$$

$$(2) \quad \text{span}\{\mathbf{g}_0, \mathbf{g}_1, \dots, \mathbf{g}_k\} = \text{span}\{\mathbf{g}_0, A\mathbf{g}_0, \dots, A^k \mathbf{g}_0\}$$

$$(3) \quad \text{span}\{\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_k\} = \text{span}\{\mathbf{g}_0, A\mathbf{g}_0, \dots, A^k \mathbf{g}_0\}$$

$$(4) \quad d_k^T A d_i = 0 \quad \forall i = 0, 1, \dots, k-1$$

Șirul  $x_k \rightarrow x^*$  în cel mult  $n$  pași.

$\mathcal{K}(g_0, k) = \text{span}\{g_0, Ag_0, \dots, A^k g_0\}$  - se numește **subspațiu Krylov de grad  $k$**  pentru  $g_0$ .

## Forma practică a metodei gradientilor conjugați

$$\mathbf{x}_0 \in \mathbb{R}^n - \text{dat}, \quad k = 0$$

$$\mathbf{g}_0 = A\mathbf{x}_0 - \mathbf{b}, \quad \mathbf{d}_0 = -\mathbf{g}_0$$

$$\text{while}(\mathbf{g}_k \neq \mathbf{0})$$

$$\left\{ \begin{array}{l} \alpha_k = \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{d}_k^T A \mathbf{d}_k} \\ \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k \\ \mathbf{g}_{k+1} = \mathbf{g}_k + \alpha_k A \mathbf{d}_k \\ \beta_k = \frac{\mathbf{g}_{k+1}^T \mathbf{g}_{k+1}}{\mathbf{g}_k^T \mathbf{g}_k} \\ \mathbf{d}_{k+1} = -\mathbf{g}_{k+1} + \beta_k \mathbf{d}_k \\ k = k + 1; \end{array} \right.$$

### Teoremă

Dacă matricea  $A$  are doar  $r$  valori proprii distincte, algoritmul gradientilor conjugați calculează soluția  $\mathbf{x}^*$  în cel mult  $r$  iterații.

### Teoremă

Dacă  $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$  sunt valorile proprii ale matricii  $A$  atunci:

$$\|\mathbf{x}_{k+1} - \mathbf{x}^*\|_A^2 \leq \left( \frac{\lambda_{n-k} - \lambda_1}{\lambda_{n-k} + \lambda_1} \right)^2 \|\mathbf{x}_0 - \mathbf{x}^*\|_A^2$$

$$\|\mathbf{x}_{k+1} - \mathbf{x}^*\|_A^2 = 2E(\mathbf{x}_{k+1})$$

$$E(\mathbf{x}_{k+1}) \leq \left( \frac{\lambda_{n-k} - \lambda_1}{\lambda_{n-k} + \lambda_1} \right)^2 E(\mathbf{x}_0).$$

## Metodele neliniare ale gradientilor conjugați

$$f(x) \approx f(x_k) + \nabla f(x_k)(x - x_k) + \frac{1}{2}(x - x_k)^T \nabla^2 f(x_k)(x - x_k)$$

$$g_k \leftrightarrow \nabla f(x_k)$$

$$A \leftrightarrow \nabla^2 f(x_k)$$

Varianta pentru funcții oarecare a metodei gradientilor conjugați:

$$\mathbf{x}_0 \in \mathbb{R}^n - \text{dat}, \quad k = 0$$

$$\mathbf{g}_0 = \nabla f(\mathbf{x}_0), \quad \mathbf{d}_0 = -\mathbf{g}_0$$

$$\text{while}(\mathbf{g}_k \neq \mathbf{0})$$

$$\left\{ \begin{array}{l} \mathbf{A} = [\nabla^2 f(\mathbf{x}_k)] \\ \alpha_k = -\frac{\mathbf{g}_k^T \mathbf{d}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k} \\ \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k \\ \mathbf{g}_{k+1} = \nabla f(\mathbf{x}_{k+1}) \\ \beta_k = \frac{\mathbf{g}_{k+1}^T \mathbf{A} \mathbf{d}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k} \\ \mathbf{d}_{k+1} = -\mathbf{g}_{k+1} + \beta_k \mathbf{d}_k \\ k = k + 1; \end{array} \right.$$

## Metoda Fletcher-Reeves

$\alpha_k$  se calculează folosind metoda ajustării pasului

$$\beta_k = \frac{\mathbf{g}_{k+1}^T \mathbf{g}_{k+1}}{\mathbf{g}_k^T \mathbf{g}_k}$$

$\mathbf{x}_0 \in \mathbb{R}^n$  – dat,

$\mathbf{g}_0 = \nabla f(\mathbf{x}_0)$ ,  $\mathbf{d}_0 = -\mathbf{g}_0$  ,  $k = 0$



***while***( $\mathbf{g}_k \neq \mathbf{0}$ )

$$\left\{ \begin{array}{l} \alpha_k = \min\{f(\mathbf{x}_k + \alpha \mathbf{d}_k); \alpha \in [0, \bar{\alpha})\} \\ \text{(exact sau inexact cu testul lui Wolfe)} \\ \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k \\ \mathbf{g}_{k+1} = \nabla f(\mathbf{x}_{k+1}) \\ \beta_k^{FR} = \frac{\mathbf{g}_{k+1}^T \mathbf{g}_k}{\mathbf{g}_k^T \mathbf{g}_k} \\ \mathbf{d}_{k+1} = -\mathbf{g}_{k+1} + \beta_k^{FR} \mathbf{d}_k \\ k = k + 1; \end{array} \right.$$

Se pune problema dacă  $d_k$  sunt direcții de descreștere?

$$d_k = -g_k + \beta_{k-1} d_{k-1}$$

$$g_k^T d_k = -g_k^T g_k + \beta_{k-1} g_k^T d_{k-1}$$

Dacă se folosește ajustarea pasului exactă:

$\alpha_{k-1}$  este punct de minim local pentru  $f$  pe direcția  $d_{k-1}$  prin urmare  $g_k^T d_{k-1} = 0$  ( $g_k = \nabla f(x_k)$ ).

$\Rightarrow g_k^T d_k = -g_k^T g_k = -\|g_k\|_2^2 < 0 \Rightarrow d_k$  direcție de descreștere

Dacă se folosește ajustarea pasului inexactă am putea avea  $\mathbf{g}_k^T \mathbf{d}_k > \mathbf{0}$  ( $\mathbf{d}_k$  direcție de creștere!!) dar folosind testul lui Wolfe deducem:

$$\begin{aligned} f(\mathbf{x}_k + \alpha_k \mathbf{d}_k) &\leq f(\mathbf{x}_k) + \varepsilon \alpha_k \mathbf{g}_k^T \mathbf{d}_k \\ |\nabla f(\mathbf{x}_k + \alpha_k \mathbf{d}_k)^T \mathbf{d}_k| &\leq (1 - \varepsilon) |\mathbf{g}_k^T \mathbf{d}_k| \\ \varepsilon \in \left(0, \frac{1}{2}\right) &\Rightarrow \mathbf{g}_k^T \mathbf{d}_k < \mathbf{0} \end{aligned}$$

## Metoda Polak-Ribière

- variantă a metodei Fletcher-Reeves

$$\beta_k^{PR} = \frac{\mathbf{g}_{k+1}^T (\mathbf{g}_{k+1} - \mathbf{g}_k)}{\mathbf{g}_k^T \mathbf{g}_k}$$

Dacă se face ajustarea pasului inexactă cu testul lui Wolfe nu putem deduce că  $\mathbf{d}_k$  sunt direcții de descreștere.

Se folosește  $\beta_k^+ = \max\{\beta_k^{PR}, 0\}$  și un test Wolfe adaptat pentru a obține  $\mathbf{d}_k$  direcții de descreștere.

## Varianta Hestenes-Stiefel

$$\beta_k^{HS} = \frac{\mathbf{g}_{k+1}^T (\mathbf{g}_{k+1} - \mathbf{g}_k)}{(\mathbf{g}_{k+1} - \mathbf{g}_k)^T \mathbf{d}_k}$$

## Precondiționare

Se consideră norma:

$$\| \mathbf{x} \|_A = \sqrt{(A\mathbf{x}, \mathbf{x})_{\mathbb{R}^n}}$$

Evaluarea erorii în metoda pantei maxime:

$$\| \mathbf{x}^{(k)} - \mathbf{x}^* \|_A \leq \left( \frac{k(A) - 1}{k(A) + 1} \right)^k \| \mathbf{x}^{(0)} - \mathbf{x}^* \|_A$$

$$k(A) = \frac{\lambda_n}{\lambda_1} - \text{numărul de condiționare spectral}$$

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n \text{ valorile proprii ale matricii } A$$

Avem convergență rapidă dacă numărul de condiționare spectrală al matricii  $A$  este apropiat de 1 ( $k(A) \geq 1$  întotdeauna).

Ideea preconditionării este de a transforma sistemul  $Ax=b$  astfel încât să îmbunătățim proprietățile spectrale.

$$Ax = b \quad \Leftrightarrow \quad \tilde{A}x = \tilde{b} \quad , \quad \text{cu } k(\tilde{A}) \ll k(A)$$

### *Precondiționare*

$$Ax = b \rightarrow M^{-1}Ax = M^{-1}b \quad (\text{la stânga})$$

$$\rightarrow AM^{-1}y = b \quad , \quad x = M^{-1}y \quad (\text{la dreapta})$$

$$\rightarrow M_1^{-1}AM_2^{-1}y = M_1^{-1}b \quad , \quad x = M_2^{-1}y \quad (\text{split}) \quad , \quad M = M_1M_2$$

cu  $M$  matrice nesaringulară ,  $M \approx A$ . Matricea  $M$  sau  $M^{-1}$  poartă numele de *matrice de preconditionare*.

Cum trebuie să alegem matricea  $M$ ?

- sistemul preconditionat ( $\tilde{A}x = \tilde{b}$ ) să fie ușor de rezolvat (convergență rapidă)
- matricea de preconditionare să fie economic de construit și aplicat – ietarțiile să nu fie costisitor de construit

### *Matricea de preconditionare Jacobi*

$$M = \text{diag}[a_{11}, a_{22}, \dots, a_{nn}]$$

### *Matrici de preconditionare SSOR*

$$M = (D + L) D^{-1} (D + L)^T \quad (A = L + D + L^T)$$

$$M(\omega) = \frac{1}{2 - \omega} \left( \frac{1}{\omega} D + L \right) \left( \frac{1}{\omega} D \right)^{-1} \left( \frac{1}{\omega} D + L \right)^T, \quad \omega \in (0, 2)$$

Pentru  $\omega$  - optimal, în anumite cazuri:

$$k(M(\omega_{opt})^{-1} A) = O(\sqrt{k(A)})$$

( $\omega_{opt}$  - foarte costisitor de calculat)