

Variabile aleatoare

9. (Variabile aleatoare: proprietăți de bază pentru medii, varianță, covarianță)

Fie variabila aleatoare $X : \Omega \rightarrow \mathbb{R}$, cu funcția de probabilitate P .

Dacă X este variabilă aleatoare *discretă*, atunci prin definiție $P(x) \stackrel{\text{not.}}{=} P(X = x) \stackrel{\text{not.}}{=} P(\{\omega \mid X(\omega) = x\}) \geq 0$ pentru orice $x \in \mathbb{R}$, și $\sum_{x_i \in \text{Val}(X)} P(x_i) = 1$, unde $\text{Val}(X)$ este mulțimea valorilor variabilei aleatoare X .

Dacă X este variabilă aleatoare *continuă*, având funcția densitate de probabilitate p , atunci prin definiție $p(X = x) \geq 0$ pentru orice $x \in \mathbb{R}$, și $\int_{-\infty}^{\infty} p(X = x) dx = 1$ (sau, scris mai simplu: $\int_{-\infty}^{\infty} p(x) dx = 1$).

- a. ■ CMU, 2010 spring, E. Xing, T. Mitchell, A. Singh, HW1, pr. 1.1

Dacă X este variabilă aleatoare discretă, *media* sa se definește ca fiind numărul real $E[X] = \sum_{x_i \in \text{Val}(X)} x_i \cdot P(X = x_i)$. Dacă X este variabilă aleatoare continuă, media sa este $E[X] = \int_{-\infty}^{\infty} x \cdot p(X = x) dx$.

Arătați că pentru orice două variabile aleatoare W și Z de același tip (adică fie ambele discrete fie ambele continue), având același domeniu de definiție (Ω), avem

$$E[W + Z] = E[W] + E[Z].$$

- b. CMU, 2010 spring, E. Xing, T. Mitchell, A. Singh, HW1, pr. 1.3

Fie X o variabilă aleatoare. Notăm $\bar{X} = E[X]$. *Varianța* lui X se definește ca fiind $\text{Var}(X) = E[(X - \bar{X})^2]$. Arătați că:

$$\text{Var}(X) = E[X^2] - (E[X])^2.$$

Indicație: Nu este necesar să faceți demonstrația separat pentru cele două cazuri, discret și respectiv continuu.

- c. CMU, 2009 spring, Tom Mitchell, HW2, pr. 1.3.1

Covarianța a două variabile aleatoare X și Y care au același domeniu de definiție (Ω) se definește astfel: $\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$, unde $E[X]$ este media lui X .

Demonstrați egalitatea:

$$\text{Cov}(X, Y) = E[XY] - E[X] \cdot E[Y].$$

Răspuns:

a. Pentru cazul discret vom folosi o formă echivalentă a formulei pentru media unei variabile aleatoare și anume $E[X] = \sum_{\omega \in \Omega} X(\omega) \cdot P(\omega)$. Prin urmare, putem

scrie:

$$\begin{aligned}
E[W + Z] &= \sum_{u \in \text{Val}(W+Z)} u \cdot P(W + Z = u) \\
&= \sum_{w \in \text{Val}(W), z \in \text{Val}(Z)} (w + z) \cdot P(W + Z = w + z) \\
&= \sum_{w \in \text{Val}(W)} \sum_{z \in \text{Val}(Z)} (w + z) \cdot P(\{\omega \in \Omega \mid (W + Z)(\omega) = w + z\}) \\
&= \sum_{w \in \text{Val}(W)} \sum_{z \in \text{Val}(Z)} w \cdot P(\{\omega \in \Omega \mid (W + Z)(\omega) = w + z\}) + \\
&\quad \sum_{w \in \text{Val}(W)} \sum_{z \in \text{Val}(Z)} z \cdot P(\{\omega \in \Omega \mid (W + Z)(\omega) = w + z\}) \\
&= \sum_{w \in \text{Val}(W)} w \sum_{z \in \text{Val}(Z)} P(\{\omega \in \Omega \mid W(\omega) = w, Z(\omega) = z\}) + \\
&\quad \sum_{z \in \text{Val}(Z)} z \sum_{w \in \text{Val}(W)} P(\{\omega \in \Omega \mid W(\omega) = w, Z(\omega) = z\}) \\
&= \sum_{w \in \text{Val}(W)} w P(\{\omega \in \Omega \mid W(\omega) = w\}) + \sum_{z \in \text{Val}(Z)} z P(\{\omega \in \Omega \mid Z(\omega) = z\}) \\
&= E[W] + E[Z]
\end{aligned}$$

Pentru cazul continuu:

$$\begin{aligned}
E[W + Z] &= \int_w \int_z (w + z) p_{WZ}(w, z) dz dw \\
&= \int_w \int_z w p_{WZ}(w, z) dz dw + \int_w \int_z z p_{WZ}(w, z) dz dw \\
&= \int_w w \int_z p_{WZ}(w, z) dz dw + \int_z z \int_w p_{WZ}(w, z) dw dz \\
&= \int_w w p_W(w) dw + \int_z z p_Z(z) dz \\
&= E[W] + E[Z]
\end{aligned}$$

b. Pentru a demonstra această proprietate vom ține cont de liniaritatea mediei unei variabile aleatoare — $E[aX + b] = aE[X] + b$, o proprietate care se demonstrează imediat —, precum și de faptul că $E[X + Y] = E[X] + E[Y]$, unde X, Y sunt variabile aleatoare iar a și b sunt constante reale:

$$\begin{aligned}
\text{Var}(X) &= E[(X - \bar{X})^2] = E[X^2 - 2X\bar{X} + \bar{X}^2] \\
&= E[X^2] - E[2X\bar{X}] + E[\bar{X}^2] = E[X^2] - 2\bar{X}E[X] + \bar{X}^2 \\
&= E[X^2] - 2\bar{X}^2 + \bar{X}^2 = E[X^2] - \bar{X}^2 = E[X^2] - (E[X])^2
\end{aligned}$$

c. Se folosește același gen de raționament ca la punctul precedent:

$$\begin{aligned}
\text{Cov}(X, Y) &= E[(X - E[X])(Y - E[Y])] \\
&= E[XY - XE[Y] - E[X]Y + E[X]E[Y]] \\
&= E[XY] - E[XE[Y]] - E[E[X]Y] + E[E[X]E[Y]] \\
&= E[XY] - E[X]E[Y] - E[X]E[Y] + E[X]E[Y] = E[XY] - E[X]E[Y]
\end{aligned}$$

10.

(Rezultat teoretic:

covarianța oricăror 2 variabile aleatoare independente este 0)

■ CMU, 2010 spring, E. Xing, T. Mitchell, A. Singh, HW1, pr. 1.2

În mod intuitiv, două variabile aleatoare X și Y sunt *independente* atunci când cunoașterea valorii uneia dintre ele (de exemplu X) nu furnizează niciun indiciu despre valoarea celeilalte variabile (Y , în acest caz).

Formal, dacă X și Y sunt variabile aleatoare discrete, independența lor revine la egalitatea $P(X = x, Y = y) = P(X = x) \cdot P(Y = y)$ pentru orice $x \in \text{Val}(X)$ și orice $y \in \text{Val}(Y)$.

Similar, dacă X și Y sunt variabile aleatoare continue, atunci $p(X = x, Y = y) = p(X = x) \cdot p(Y = y)$ pentru orice valori x și y posibile.

Arătați că dacă X și Y sunt variabile aleatoare independente de același tip (adică fie discret fie continuu), atunci

$$E[XY] = E[X] \cdot E[Y].$$

Echivalent: X, Y independente $\Rightarrow \text{Cov}(X, Y) = 0$. (A se vedea problema 9 punctul c.)

Observație: Reciproca implicației de mai sus nu este în general adevărată. A se vedea problema 11.

Răspuns:

Pentru cazul în care variabilele aleatoare independente X și Y sunt discrete, putem scrie:

$$\begin{aligned} E[XY] &= \sum_{x \in \text{Val}(X)} \sum_{y \in \text{Val}(Y)} xy P(X = x, Y = y) \\ &\stackrel{\text{indep.}}{=} \sum_{x \in \text{Val}(X)} \sum_{y \in \text{Val}(Y)} xy P(X = x) \cdot P(Y = y) \\ &= \sum_{x \in \text{Val}(X)} \left(x P(X = x) \sum_{y \in \text{Val}(Y)} y P(Y = y) \right) \\ &= \sum_{x \in \text{Val}(X)} x P(X = x) E[Y] = \left(\sum_{x \in \text{Val}(X)} x P(X = x) \right) E[Y] \\ &= E[X] \cdot E[Y] \end{aligned}$$

Pentru cazul continuu demonstrația este similară:

$$\begin{aligned} E[XY] &= \int_x \int_y xy p(X = x, Y = y) dy dx \\ &\stackrel{\text{indep.}}{=} \int_x \int_y xy p(X = x) \cdot p(Y = y) dy dx \\ &= \int_x x p(X = x) \int_y y p(Y = y) dy dx = \int_x x p(X = x) E[Y] dx \\ &= E[Y] \cdot \int_x x p(X = x) dx = E[Y] \cdot E[X] = E[X] \cdot E[Y] \end{aligned}$$

11.

(Covarianța nulă nu implică în mod neapărat independența variabilelor aleatoare)

CMU, 2009 spring, Tom Mitchell, HW2, pr. 1.3.2

CMU, 2009 fall, Geoff Gordon, HW1, pr. 3.1

a. Reciproca afirmației din problema 10 nu este în general adevărată, deci $Cov(X, Y) = 0 \not\Rightarrow X$ și Y sunt independente. Arătați aceasta folosind ca exemplu variabilele aleatoare ale căror distribuții sunt date în tabelul alăturat.

X	Y	$P(X, Y)$
0	0	1/3
1	0	0
2	0	1/3
0	1	0
1	1	1/3
2	1	0

b. Totuși, dacă X și Y sunt variabile aleatoare binare luând valori în mulțimea $\{0, 1\}$, iar $E[XY] = E[X] \cdot E[Y]$, atunci X și Y sunt independente. Justificați.

(Așadar, două variabile aleatoare binare cu valori în mulțimea $\{0, 1\}$ sunt independente atunci și numai atunci când au covarianța nulă.)

Răspuns:

a. Din datele furnizate în exemplul a rezultă următoarele probabilități:

$$\begin{aligned} P(X=0) &= 1/3 & P(Y=0) &= 2/3 & P(XY=0) &= 2/3 \\ P(X=1) &= 1/3 & P(Y=1) &= 1/3 & P(XY=1) &= 1/3 \\ P(X=2) &= 1/3 & & & P(XY=2) &= 0 \end{aligned}$$

Putem calcula mediile acestor variabile aleatoare folosind formula de definiție pentru variabile discrete $E[X] = \sum_x x \cdot P(X=x)$:

$$\begin{aligned} E[X] &= 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + 2 \cdot \frac{1}{3} = 1 \\ E[Y] &= 0 \cdot \frac{2}{3} + 1 \cdot \frac{1}{3} = \frac{1}{3} \\ E[XY] &= 0 \cdot \frac{2}{3} + 1 \cdot \frac{1}{3} + 2 \cdot 0 = \frac{1}{3} \end{aligned}$$

Conform formulei care a fost demonstrată la problema 10, covarianța variabilelor X și Y este: $Cov(X, Y) = E[XY] - E[X] \cdot E[Y] = \frac{1}{3} - 1 \cdot \frac{1}{3} = 0$. Cu toate acestea, variabilele X și Y nu sunt independente. Într-adevăr, pentru $X=0$ și $Y=0$ se observă că $P(X=0, Y=0) = 1/3$ dar $P(X=0)P(Y=0) = 1/3 \cdot 2/3 = 2/9 \neq \frac{1}{3}$.

Prin acest contra-exemplu am arătat că implicația „ $Cov(X, Y) = 0 \Rightarrow X$ și Y sunt independente” nu este în general adevărată.

b. În continuare vom demonstra că în cazul în care X și Y iau valori în mulțimea $\{0, 1\}$ implicația de mai sus este adevărată.

Dacă X și Y sunt variabile aleatoare binare, atunci:

$$\begin{aligned} E[X] &= 0 \cdot P(X=0) + 1 \cdot P(X=1) = P(X=1) \\ E[Y] &= P(Y=1) \\ E[XY] &= P(X=1, Y=1) \end{aligned}$$

Covarianța nulă înseamnă — conform problemelor 9 și 10 — că $E[XY] = E[X] \cdot E[Y]$, adică:

$$P(X=1, Y=1) = P(X=1)P(Y=1)$$

Însă, a demonstra independența variabilelor aleatoare X și Y revine la a arăta că $P(X, Y) = P(X)P(Y)$ pentru toate combinațiile posibile de valori ale variabilelor. Unul din cazuri ($X = 1, Y = 1$) este deja demonstrat, deci mai există încă 3 cazuri. Pentru acestea vom utiliza formulele: $P(A \cap B) = P(A) - P(A \cap \bar{B})$ și $P(\bar{A}) = 1 - P(A)$.

Cazul $X = 1, Y = 0$:

$$\begin{aligned} P(X = 1, Y = 0) &= P(X = 1) - P(X = 1, Y = 1) \\ &= P(X = 1) - P(X = 1)P(Y = 1) \\ &= P(X = 1)(1 - P(Y = 1)) \\ &= P(X = 1)P(Y = 0) \end{aligned}$$

Cazul $X = 0, Y = 1$ se tratează similar cu cazul anterior:

$$\begin{aligned} P(X = 0, Y = 1) &= P(Y = 1) - P(X = 1, Y = 1) \\ &= P(Y = 1) - P(X = 1)P(Y = 1) \\ &= P(Y = 1)(1 - P(X = 1)) \\ &= P(Y = 1)P(X = 0) \end{aligned}$$

Cazul $X = 0, Y = 0$:

$$\begin{aligned} P(X = 0, Y = 0) &= P(X = 0) - P(X = 0, Y = 1) \\ &= P(X = 0) - P(X = 0)P(Y = 1) \\ &= P(X = 0)(1 - P(Y = 1)) \\ &= P(X = 0)P(Y = 0) \end{aligned}$$

Prin urmare, egalitatea $P(X, Y) = P(X)P(Y)$ este adevărată pentru toate cazurile, deci variabilele X și Y sunt independente.

12. (Variabile aleatoare: calcul de medii)

Fie X o variabilă aleatoare pentru care $E(X) = \mu$ și $Var(X) = \sigma^2$.

a. *CMU, 2004 fall, T. Mitchell, Z. Bar-Joseph, HW1, pr. 2.4*

Cât este $E[X(X - 1)]$ în funcție de μ și σ ?

b. *CMU, 2004 fall, T. Mitchell, Z. Bar-Joseph, midterm, pr. 1.c*

Fie $c \in \mathbb{R}$. Care din următoarele variante sunt adevărate?

- | | |
|--------------------------------------------|---------------------------------------------|
| A. $E[(X - c)^2] = (\mu - c)^2 + \sigma^2$ | D. $E[(X - c)^2] = (\mu - c)^2 + 2\sigma^2$ |
| B. $E[(X - c)^2] = (\mu - c)^2$ | E. $E[(X - c)^2] = \mu^2 + c^2 + 2\sigma^2$ |
| C. $E[(X - c)^2] = (\mu - c)^2 - \sigma^2$ | F. $E[(X - c)^2] = \mu^2 + c^2 - 2\sigma^2$ |

Răspuns:

a. De la problema 9.a știm că media sumei a două variabile aleatoare este suma mediilor variabilelor respective. De asemenea, este imediat demonstrabil că

$E[c \cdot X] = c \cdot E[X]$, unde X, Y sunt variabile aleatoare iar c este o constantă. Ținând cont că $Var(X) = E[X^2] - (E[X])^2$ (vezi problema 9.b), putem scrie:

$$\begin{aligned} E[X(X-1)] &= E[X^2 - X] = E[X^2] - E[X] \\ &= E[X^2] - (E[X])^2 + (E[X])^2 - E[X] \\ &= Var(X) + (E[X])^2 - E[X] \\ &= \sigma^2 + \mu^2 - \mu \end{aligned}$$

b. Pentru a găsi varianta adevărată vom calcula $E[(X-c)^2]$:

$$\begin{aligned} E[(X-c)^2] &= E[X^2 - 2cX + c^2] = E[X^2] - 2cE[X] + c^2 \\ &= E[X^2] - (E[X])^2 + (E[X])^2 - 2cE[X] + c^2 \\ &= \sigma^2 + \mu^2 - 2c\mu + c^2 \\ &= \sigma^2 + (\mu - c)^2 \end{aligned}$$

Deci varianta A este adevărată.

13. (Variabile aleatoare discrete – distribuția Bernoulli – și evenimente aleatoare identic distribuite: calcul de medii)

CMU, 2004 fall, T. Mitchell, Z. Bar-Joseph, HW1, pr. 2.2

Un iepuraș se joacă „de-a săritelele”. Poziția lui inițială coincide cu originea axei reale. După aceea, iepurașul face câte un salt de-a lungul axei, fie la stânga fie la dreapta. Pentru a determina în ce direcție să sară, iepurașul dă cu banul. Dacă obține stema, va sări spre dreapta, iar dacă obține banul, va sări spre stânga. Probabilitatea de a obține stema este p . Se presupune că toate salturile iepurașului au aceeași lungime, și anume 1.

Care va fi poziția (medie) la care ne așteptăm să fie iepurașul după ce face n salturi?

Răspuns:

Fiecare săritură a iepurașului este modelată de o variabilă aleatoare. Un salt spre dreapta înseamnă o deplasare cu $+1$ pe axă, iar un salt spre stânga -1 . Să notăm cu X_i variabila aleatoare corespunzătoare săriturii i . Aceasta este:

$$X_i : \begin{pmatrix} -1 & 1 \\ 1-p & p \end{pmatrix}$$

Media acestei variabile aleatoare este $E[X_i] = -1 \cdot (1-p) + 1 \cdot p = 2p - 1$.

Ținând cont de proprietatea de liniaritate a mediilor, poziția iepurașului după n salturi este de așteptat să fie:

$$E[X_1 + X_2 + \dots + X_n] = E[X_1] + E[X_2] + \dots + E[X_n] = n(2p - 1).$$

De exemplu, pentru $p = 1/2$, se va obține poziția 0 pe axa reală (așa cum este de așteptat dacă n este număr par), în vreme ce pentru $p = 2/3$ va rezulta poziția $n/3$ (dacă $n/3 \in \mathbb{N}$), iar pentru $p = 1/3$ poziția $-n/3$ (similar).

14.

(Distribuții de probabilitate condiționale:
regula de multiplicare)

CMU, 2009 fall, Geoff Gordon, HW2, pr. 2.1

Arătați că pentru orice valori x, y și z ale variabilelor aleatoare X, Y și Z respectiv, avem:

$$P(X = x, Y = y \mid Z = z) = P(X \mid Y = y, Z = z) \cdot P(Y = y \mid Z = z).$$

În notație simplificată: $P(X, Y \mid Z) = P(X \mid Y, Z) \cdot P(Y \mid Z)$.

Indicație: Folosiți regula de înlănțuire pentru evenimente aleatoare.

Răspuns:

Folosind definiția probabilității condiționale și regula de înlănțuire (cu termenii ordonați în mod convenabil), egalitatea cerută se obține astfel:

$$\begin{aligned} P(X, Y \mid Z) &\stackrel{\text{def.}}{=} \frac{P(X, Y, Z)}{P(Z)} \stackrel{\text{not.}}{=} \frac{P(Z \cap Y \cap X)}{P(Z)} \\ &= \frac{P(Z)P(Y \mid Z)P(X \mid Y, Z)}{P(Z)} = P(Y \mid Z) \cdot P(X \mid Y, Z) \end{aligned}$$

Observație: O altă metodă de rezolvare constă în a aplica pentru fiecare membru al egalității din enunț definiția probabilității condiționale, după simplificări obținându-se pentru ambii membri aceeași valoare:

$$\begin{aligned} P(X, Y \mid Z) &= \frac{P(X, Y, Z)}{P(Z)} \\ P(X \mid Y, Z) \cdot P(Y \mid Z) &= \frac{P(X, Y, Z)}{P(Y, Z)} \cdot \frac{P(Y, Z)}{P(Z)} = \frac{P(X, Y, Z)}{P(Z)} \end{aligned}$$

15.

(Variabile aleatoare discrete:
distribuții corelate, marginale, condiționale)

CMU, 2002 fall, Andrew Moore, final exam, pr. 4.a

Considerăm un set de date definit cu ajutorul a 3 variabile aleatoare cu valori booleene X, Y și Z . Care dintre seturile de informații de mai jos sunt suficiente pentru a specifica distribuția corelată $P(x, y, z)$?

A.

$P(\neg X \mid Z)$
 $P(\neg X \mid \neg Z)$
 $P(\neg Y \mid X, Z)$
 $P(\neg Y \mid X, \neg Z)$
 $P(\neg Y \mid \neg X, Z)$
 $P(\neg Y \mid \neg X, \neg Z)$
 $P(Z)$

B.

$P(\neg X \mid \neg Z)$
 $P(X \mid \neg Z)$
 $P(Y \mid X, Z)$
 $P(Y \mid X, \neg Z)$
 $P(Y \mid \neg X, Z)$
 $P(Y \mid \neg X, \neg Z)$
 $P(Z)$

C.

$P(X \mid Z)$
 $P(X \mid \neg Z)$
 $P(Y \mid X, Z)$
 $P(Y \mid X, \neg Z)$
 $P(Y \mid \neg X, Z)$
 $P(\neg Y \mid \neg X, \neg Z)$
 $P(\neg Z)$

D.

$P(X \mid Z)$
 $P(X \mid \neg Z)$
 $P(Y \mid X, Z)$
 $P(Y \mid X, \neg Z)$
 $P(\neg Y \mid \neg X, \neg Z)$
 $P(Y \mid \neg X, \neg Z)$
 $P(Z)$

Răspuns:

Pentru a calcula distribuția corelată a mai multor variabile aleatoare se poate aplica regula de înălțuire.¹¹ În cazul nostru putem scrie că:

$$P(X, Y, Z) = P(Z) \cdot P(X | Z) \cdot P(Y | X, Z)$$

Deoarece variabilele aleatoare X , Y și Z au valori booleene, pentru a specifica distribuția corelată $P(X, Y, Z)$ este nevoie să se calculeze valoarea acesteia în fiecare din cele 8 cazuri posibile:

$$\begin{array}{cccc} P(X, Y, Z) & P(X, Y, \neg Z) & P(X, \neg Y, Z) & P(X, \neg Y, \neg Z) \\ P(\neg X, Y, Z) & P(\neg X, Y, \neg Z) & P(\neg X, \neg Y, Z) & P(\neg X, \neg Y, \neg Z) \end{array}$$

Cunoaștem de asemenea relații de calcul de forma:

$$\begin{aligned} P(\neg X) &= 1 - P(X) \\ P(\neg X | Y) &= 1 - P(X | Y) \end{aligned}$$

Așadar, pentru a aplica regula de înălțuire de mai sus vom avea nevoie de

$$\begin{array}{ll} P(Z) \text{ sau } P(\neg Z); & P(Y | X, Z) \text{ sau } P(\neg Y | X, Z); \\ P(X | Z) \text{ sau } P(\neg X | Z); & P(Y | \neg X, Z) \text{ sau } P(\neg Y | \neg X, Z); \\ P(X | \neg Z) \text{ sau } P(\neg X | \neg Z); & P(Y | X, \neg Z) \text{ sau } P(\neg Y | X, \neg Z); \\ & P(Y | \neg X, \neg Z) \text{ sau } P(\neg Y | \neg X, \neg Z). \end{array}$$

Cu aceste precizări, putem specifica pentru fiecare dintre seturile de informații din enunț dacă sunt suficiente pentru a calcula distribuția corelată $P(X, Y, Z)$.

Cazul A. Da. Se observă că putem calcula $P(X | Z)$ și $P(X | \neg Z)$ din primele două probabilități din enunț. De asemenea, utilizând următoarele 4 probabilități se pot deduce: $P(Y | X, Z)$, $P(Y | X, \neg Z)$, $P(Y | \neg X, Z)$ și $P(Y | \neg X, \neg Z)$. Iar din $P(Z)$ se obține $P(\neg Z)$. Prin urmare, există toate informațiile necesare distribuției corelate $P(X, Y, Z)$.

Cazul B. Nu, informațiile din enunț nu sunt suficiente. Nu putem deduce valoarea pentru $P(X | Z)$.

Cazul C. Da, informațiile din enunț sunt suficiente. Din $P(X | Z)$ se obține $P(\neg X | Z)$, iar din $P(X | \neg Z)$ se obține $P(\neg X | \neg Z)$. Din următoarele 4 probabilități se obțin celelalte 4 necesare pentru $P(Y | X, Z)$, și anume: $P(\neg Y | X, Z)$, $P(\neg Y | X, \neg Z)$, $P(\neg Y | \neg X, Z)$ și respectiv $P(Y | \neg X, \neg Z)$.

Cazul D. Nu, informațiile din enunț nu sunt suficiente. Nu putem deduce valoarea pentru $P(Y | \neg X, Z)$.

16. (Variabile aleatoare discrete: independență condițională)
CMU, 2005 fall, T. Mitchell, A. Moore, midterm, pr. 4

Fie variabilele aleatoare discrete A , B și C având distribuția corelată conform tabelului de mai jos.

¹¹ Pentru variabile aleatoare, regula de înălțuire

$$P(A_1, A_2, \dots, A_n) = P(A_1) \cdot P(A_2 | A_1) \cdot P(A_n | A_1, A_2, \dots, A_{n-1})$$

se demonstrează imediat pornind de la regula de înălțuire pentru (probabilități de) evenimente aleatoare. A se vedea problema 14.

a. Este variabila A independentă condițional de B în raport cu variabila C ?

b. Dacă ați răspuns afirmativ la întrebarea a , faceți o schimbare în primele două linii ale tabelului de mai sus pentru a obține o distribuție pentru care răspunsul la aceeași întrebare să devină negativ. Invers, dacă ați răspuns negativ la întrebarea a , faceți o schimbare în primele două linii ale tabelului încât răspunsul să devină afirmativ.

A	B	C	$P(A, B, C)$
0	0	0	1/8
0	0	1	1/8
0	1	0	1/8
0	1	1	1/8
1	0	0	1/8
1	0	1	1/8
1	1	0	1/8
1	1	1	1/8

Răspuns:

a. Faptul că variabila A este independentă condițional de B în raport cu variabila C se mai notează prin $A \perp B \mid C$ și poate fi demonstrat prin una din următoarele două relații:

$$P(A = a, B = b \mid C = c) = P(A = a \mid C = c) \cdot P(B = b \mid C = c) \text{ sau}$$

$$P(A = a \mid B = b, C = c) = P(A = a \mid C = c), \text{ dacă } P(B = b, C = c) \neq 0.$$

pentru orice $a \in \text{Val}(A), b \in \text{Val}(B), c \in \text{Val}(C)$. Deși în general se folosește prima relație, pentru acest exercițiu este mai ușor să utilizăm cea de-a doua relație. Conform tabelului dat în enunț, rezultă imediat că $P(B = b, C = c) \neq 0$ pentru orice $b, c \in \{0, 1\}$. Vom demonstra că pentru orice $a, b, c \in \{0, 1\}$ este adevărat că $P(A = a \mid B = b, C = c) = P(A = a \mid C = c)$. Cele două probabilități condiționate vor fi calculate folosind datele din tabel:

$$\text{Cazul } (0, 0, 0): P(A = 0 \mid B = 0, C = 0) = \frac{1 \cdot \frac{1}{8}}{2 \cdot \frac{1}{8}} = \frac{1}{2} \text{ și } P(A = 0 \mid C = 0) = \frac{2 \cdot \frac{1}{8}}{4 \cdot \frac{1}{8}} = \frac{1}{2}.$$

$$\text{Cazul } (0, 0, 1): P(A = 0 \mid B = 0, C = 1) = \frac{1 \cdot \frac{1}{8}}{2 \cdot \frac{1}{8}} = \frac{1}{2} \text{ și } P(A = 0 \mid C = 1) = \frac{2 \cdot \frac{1}{8}}{4 \cdot \frac{1}{8}} = \frac{1}{2}.$$

Se observă că pentru toate celelalte cazuri se obțin aceleași valori, deci

$$P(A = a \mid B = b, C = c) = P(A = a \mid C = c), \forall a, b, c \in \{0, 1\}.$$

Așadar, variabila A este independentă condițional de B în raport cu variabila C .

b. Schimbarea trebuie făcută în așa fel încât să se păstreze relația $\sum P(A, B, C) = 1$. O variantă posibilă este:

A	B	C	$P(A, B, C)$
0	0	0	1/4
0	0	1	0
...

Pentru aceste noi valori se observă că: $P(A = 0 \mid B = 0, C = 0) = \frac{1 \cdot 1/4}{1 \cdot 1/4 + 1 \cdot 1/8} = \frac{2}{3}$ și $P(A = 0 \mid C = 0) = \frac{1 \cdot 1/4 + 1 \cdot 1/8}{1 \cdot 1/4 + 3 \cdot 1/8} = \frac{3}{5}$. Este suficient un singur caz în care probabilitățile respective nu sunt egale, prin urmare variabila A nu este independentă condițional de variabila B în raport cu a treia variabilă, C .

17.

(Variabile aleatoare continue:
funcția densitate de probabilitate)*CMU, 2004 fall, T. Mitchell, Z. Bar-Joseph, HW1, pr. 1.5*

Fie variabila aleatoare continuă X a cărei funcție densitate de probabilitate (în limba engleză: “probability density functions”; scris, sub formă abreviată, pdf) este:

$$p(x) = \begin{cases} cx^2 & \text{pentru } 1 \leq x \leq 2 \\ 0 & \text{în caz contrar.} \end{cases}$$

a. Ținând cont de proprietățile funcției densitate de probabilitate (a se vedea notițele de la curs), cât trebuie să fie valoarea constantei c ?

b. Desenați graficul funcției de mai sus.

c. Calculați $P(X > 3/2)$.

Răspuns:

a. Faptul că $p(x)$ este funcție densitate de probabilitate pentru variabila aleatoare continuă X înseamnă că $p(x) \geq 0, \forall x$ și că $\int_{-\infty}^{+\infty} p(x)dx = 1$. Pentru a afla constanta c vom calcula valoarea integralei:


$$\begin{aligned} \int_{-\infty}^{+\infty} p(x)dx &= \underbrace{\int_{-\infty}^1 p(x)dx}_{=0} + \int_1^2 p(x)dx + \underbrace{\int_2^{+\infty} p(x)dx}_{=0} \\ &= \int_1^2 cx^2 dx = c \cdot \int_1^2 x^2 dx = c \cdot \left. \frac{x^3}{3} \right|_1^2 = c \left(\frac{2^3}{3} - \frac{1^3}{3} \right) = c \cdot \frac{7}{3} \end{aligned}$$

Prin urmare, $c \cdot \frac{7}{3} = 1 \Rightarrow c = \frac{3}{7}$.

b. Trebuie să reprezentăm grafic funcția:

$$p(x) = \begin{cases} \frac{3}{7}x^2 & \text{pentru } 1 \leq x \leq 2 \\ 0 & \text{în caz contrar.} \end{cases}$$

În intervalul $[1, 2]$, această funcție este un fragment din parabola corespunzătoare funcției de gradul al doilea: $\frac{3}{7}x^2$, parabola care are vârful în punctul $(0, 0)$. Putem calcula $p(1) = 3/7 \approx 0.42$ și $p(2) = 12/7 \approx 1.71$.



c. Valoarea probabilității cerute se poate calcula astfel:

$$\begin{aligned}
 P(X > 3/2) &\stackrel{\text{not.}}{=} P(\{\omega \mid X(\omega) > \frac{3}{2}\}) \stackrel{\text{def.}}{=} \int_{X(\omega)=x>3/2} p(x)dx = \int_{3/2}^{+\infty} p(x)dx \\
 &= \int_{3/2}^2 p(x)dx + \underbrace{\int_2^{+\infty} p(x)dx}_{=0} \\
 &= \int_{3/2}^2 \frac{3}{7}x^2dx = \frac{3}{7} \cdot \int_{3/2}^2 x^2dx = \frac{3}{7} \cdot \frac{x^3}{3} \Big|_{3/2}^2 = \frac{1}{7} \cdot x^3 \Big|_{3/2}^2 \\
 &= \frac{1}{7} \cdot \left(8 - \frac{27}{8}\right) = \frac{1}{7} \cdot \frac{64 - 27}{8} = \frac{37}{56}
 \end{aligned}$$

O altă variantă de rezolvare este bazată pe folosirea *funcției cumulative de distribuție*, care, după cum știm, se definește prin relația $F(x) \stackrel{\text{def.}}{=} P(X \leq x)$, pentru orice $x \in \mathbb{R}$:

$$\begin{aligned}
 P(X > 3/2) &= 1 - P(X \leq 3/2) = 1 - F\left(\frac{3}{2}\right) = 1 - \int_{-\infty}^{3/2} p(x)dx \\
 &= 1 - \left(\underbrace{\int_{-\infty}^1 p(x)dx}_0 + \int_1^{3/2} p(x)dx \right) = 1 - \left(0 + \int_1^{3/2} p(x)dx \right) \\
 &= 1 - \int_1^{3/2} p(x)dx = 1 - \int_1^{3/2} \frac{3}{7}x^2dx = 1 - \frac{1}{7} \cdot x^3 \Big|_1^{3/2} \\
 &= 1 - \frac{1}{7} \cdot \left(\frac{27}{8} - 1 \right) = 1 - \frac{1}{7} \cdot \frac{19}{8} \\
 &= 1 - \frac{19}{56} = \frac{37}{56}
 \end{aligned}$$

18.

(Variabile aleatoare continue:
funcția densitate de probabilitate)

CMU, 2008 spring, Eric Xing, HW1, pr. 1.1.b

Fie funcția

$$p(x) = \begin{cases} cx^{-d} & \text{pentru } x > 1 \\ 0 & \text{în caz contrar.} \end{cases}$$

Care sunt valorile posibile pentru c și d în așa fel ca p să poată reprezenta o funcție densitate de probabilitate?

Răspuns:

O funcție p poate reprezenta o funcție densitate de probabilitate dacă $p(x) \geq 0$ pentru $\forall x$, și $\int_{-\infty}^{\infty} p(x)dx = 1$. Vom folosi aceste două condiții pentru a calcula valorile posibile pentru c și d .

Prima condiție $p(x) \geq 0$ implică faptul că $c \geq 0$, asupra lui d neimpunând nicio restricție. Mai mult, ținând cont de forma lui p și de cea de-a doua condiție, vom avea chiar $c > 0$, fiindcă $c = 0$ ar implica $\int_{-\infty}^{\infty} p(x)dx = 0 \neq 1$.

Pentru a aplica cea de-a doua condiție, calculăm integrala:

$$\int_{-\infty}^{\infty} p(x)dx = \int_1^{\infty} cx^{-d}dx = c \int_1^{\infty} x^{-d}dx$$

Vom avea de tratat două cazuri:

$$\text{Cazul 1: } d = 1 \Rightarrow c \int_1^{\infty} x^{-d}dx = c \int_1^{\infty} \frac{1}{x}dx = c \cdot \ln x|_1^{\infty} = \infty$$

$$\text{Cazul 2: } d \neq 1 \Rightarrow c \int_1^{\infty} x^{-d}dx = c \cdot \frac{x^{-d+1}}{-d+1} \Big|_1^{\infty} = \frac{c}{1-d} \cdot x^{1-d} \Big|_1^{\infty}$$

Subcazul $d > 1$: $x^{1-d} \Big|_1^{\infty} = 0 - 1 = -1$. Deci în acest caz $c \int_1^{\infty} x^{-d}dx = \frac{c}{d-1}$.

Subcazul $d < 1$: $x^{1-d} \Big|_1^{\infty} = +\infty$. Deci în acest caz $c \int_1^{\infty} x^{-d}dx = +\infty$.

Prin urmare, $\int_{-\infty}^{\infty} p(x)dx = 1 \Rightarrow d > 1$ și $\frac{c}{d-1} = 1$.

În concluzie, p poate reprezenta o funcție densitate de probabilitate dacă

$$c > 0, d > 1 \text{ și } c = d - 1.$$

Referitor la aceste trei restricții, se observă că ultimele două o implică pe cea dintâi, deci o fac superfluă.

19. (Variabile aleatoare uniforme continue, independente;
funcții densitate de probabilitate)

CMU, 2008 spring, Eric Xing, HW1, pr. 1.5

O persoană pleacă la servicii între orele 8:00 și 8:30, iar timpul necesar deplasării este între 40 și 50 de minute. Considerăm X variabila aleatoare care reprezintă timpul de plecare exprimat în minute scurse după ora 8:00 și Y variabila aleatoare care reprezintă durata deplasării. Presupunând că aceste două variabile sunt independente și uniform distribuite, indicați:

a. funcțiile densitate de probabilitate $p(x) \stackrel{\text{not.}}{=} P_X(X = x)$, $p(y) \stackrel{\text{not.}}{=} P_X(Y = y)$ și $p(x, y) \stackrel{\text{not.}}{=} P_{XY}(X = x, Y = y)$.

b. probabilitatea ca persoana respectivă să ajungă la servicii înainte de ora 9.

Răspuns:

a. Conform enunțului $Val(X) = [0, 30]$ și $Val(Y) = [40, 50]$. Pentru a determina funcția densitate de probabilitate pentru X și respectiv Y vom impune restricția ca integrala valorilor pe domeniul de definiție să fie 1:

$$\int_{-\infty}^{\infty} p(x)dx = 1 \Leftrightarrow \int_0^{30} p(x)dx = 1 \stackrel{p^{-unif.}}{\Leftrightarrow} p(x) = \begin{cases} \frac{1}{30} & \text{pentru } 0 \leq x \leq 30 \\ 0 & \text{în caz contrar.} \end{cases}$$

$$\int_{-\infty}^{\infty} p(y)dy = 1 \Leftrightarrow \int_{40}^{50} p(y)dy = 1 \stackrel{p^{-unif.}}{\Leftrightarrow} p(y) = \begin{cases} \frac{1}{10} & \text{pentru } 40 \leq y \leq 50 \\ 0 & \text{în caz contrar.} \end{cases}$$

Deoarece variabilele X și Y sunt independente, funcția densitate de probabilitate corelată este:

$$p(x, y) = p(x) \cdot p(y) = \begin{cases} \frac{1}{300} & \text{pentru } 0 \leq x \leq 30 \text{ și } 40 \leq y \leq 50 \\ 0 & \text{în caz contrar.} \end{cases}$$


b. Probabilitatea ca persoana respectivă să ajungă la servicii înainte de ora 9 este $P(X + Y \leq 60)$.

Grafic, așa cum se observă din figura alăturată, această probabilitate este foarte simplu de găsit: $p(x + y \leq 60) = \frac{1}{2}$. Într-adevăr, știm că aria întregii zone dreptunghiulare pe care $p(x, y) \neq 0$ este

$$\int_{x=0}^{30} \int_{y=40}^{50} p(x, y) dy dx = 1.$$

Probabilitatea urmărită este aria zonei din acest dreptunghi care se găsește „sub” dreapta de ecuație $x + y = 60$. Această zonă corespunde perechilor de valori (x, y) care satisfac condiția ca persoana să ajungă la servicii înainte de ora 9.

Alternativ, această arie se poate obține prin calcul direct:



$$\begin{aligned} P(X + Y \leq 60) &= \int_{x=0}^{10} \int_{y=40}^{50} \frac{1}{300} dy dx + \int_{x=10}^{20} \int_{y=40}^{60-x} \frac{1}{300} dy dx \\ &= \int_{x=0}^{10} \frac{1}{300} \cdot y|_{40}^{50} dx + \int_{x=10}^{20} \frac{1}{300} \cdot y|_{40}^{60-x} dx \\ &= \int_{x=0}^{10} \frac{1}{300} \cdot 10 dx + \int_{x=10}^{20} \frac{1}{300} \cdot (20 - x) dx \\ &= \frac{1}{30} \cdot x|_0^{10} + \frac{1}{300} \cdot \left(20x - \frac{1}{2}x^2 \right) \Big|_{10}^{20} = \frac{10}{30} + \frac{50}{300} = \frac{1}{2}. \end{aligned}$$

20.

(Variabile aleatoare uniforme continue:
p.d.f. condițională; independență)

CMU, 2003 fall, T. Mitchell, A. Moore, midterm, pr. 2

Fie X și Y variabile aleatoare continue având funcția densitate de probabilitate corelată definită astfel:

$$p(x, y) = \begin{cases} 1 & \text{pentru } 0 < x < 1, |y| < x \\ 0 & \text{în caz contrar.} \end{cases}$$

a. Cât este $p(y | x = 0.5)$?

b. Este variabila X independentă de variabila Y ?

Răspuns:

Putem reprezenta grafic funcția densitate de probabilitate corelată a variabilelor aleatoare X și Y . În figura alăturată porțiunea triunghiulară reprezintă domeniul pentru care valoarea funcției este 1, în rest valoarea acesteia fiind 0.

a. Conform definiției p.d.f. condiționale, avem


$$p(y | x = 0.5) = \frac{p(x=0.5, y)}{p(x=0.5)}.$$

Conform definiției p.d.f. marginale,

$$p(x = 0.5) = \int_{-\infty}^{+\infty} p(x = 0.5, y) dy = \int_{-0.5}^{+0.5} 1 dy = 1$$

Deci $p(y | x = 0.5) = p(y, x = 0.5)$. Așadar, pentru a calcula valoarea cerută vom înlocui în definiția funcției densitate de probabilitate corelată valoarea cunoscută $x = 0.5$.

$$\begin{aligned} p(y | x = 0.5) = p(x = 0.5, y) &= \begin{cases} 1 & \text{pentru } 0 < 0.5 < 1, |y| < 0.5 \\ 0 & \text{în caz contrar.} \end{cases} \\ &= \begin{cases} 1 & \text{pentru } -0.5 < y < 0.5 \\ 0 & \text{în caz contrar.} \end{cases} \end{aligned}$$



b. Variabilele X și Y nu sunt independente. Intuitiv, se observă că în definiția funcției densitate de probabilitate corelată există o dependență între valorile lor, și anume: $|y| < x$.

Pentru a demonstra riguros faptul că variabilele X și Y nu sunt independente trebuie să arătăm că relația $p(x, y) = p(x) \cdot p(y)$ nu este adevărată pentru $\forall x, y$ din domeniul de definiție.

Se observă că $p(X = \frac{1}{4}, Y = 0) = 1$ (conform definiției), dar probabilitățile marginale corespunzătoare sunt:

$$p_X(X = \frac{1}{4}) = \int_{-\frac{1}{4}}^{\frac{1}{4}} 1 dy = y \Big|_{-\frac{1}{4}}^{\frac{1}{4}} = \frac{1}{2}$$

și

$$p_Y(Y = 0) = \int_0^1 1 dx = 1.$$

Așadar,

$$p(X = \frac{1}{4}, Y = 0) = 1 \neq \frac{1}{2} = p_X(X = \frac{1}{4}) \cdot p_Y(Y = 0).$$

21.


(Variabile aleatoare uniforme continue:
funcția densitate de probabilitate;
distribuții corelate, marginale, condiționale;
formula lui Bayes)

CMU, 2002 fall, Andrew Moore, midterm, pr. 2

Figura alăturată ilustrează o clasă simplă de funcții densitate de probabilitate (pdf) definite peste perechi de variabile continue reale x, y .

Numim această clasă de funcții *Rectangle-PDF*. O funcție din această clasă este desemnată în mod generic prin $Rectangle(x_{lo}, y_{lo}, x_{hi}, y_{hi})$.

Așadar, *parametrii* clasei *Rectangle-PDF* sunt cele 4 coordonate: x_{lo}, y_{lo}, x_{hi} și y_{hi} .



Definiția funcției densitate de probabilitate $Rectangle(x_{lo}, y_{lo}, x_{hi}, y_{hi})$ este:

$$p(x, y) = \begin{cases} \frac{1}{(x_{hi} - x_{lo})(y_{hi} - y_{lo})} & \text{dacă } x_{lo} \leq x \leq x_{hi} \text{ și } y_{lo} \leq y \leq y_{hi} \\ 0 & \text{în caz contrar.} \end{cases}$$

Observație: Se poate arăta imediat că $\int_x \int_y p(x, y) dx dy = 1$.

a. Pentru $Rectangle(0, 0, 1/2, 2)$, calculați: $p(x = 1/4, y = 1/4)$, $p(y = 1/4)$, $p(x = 1/4)$, $p(x = 1/4 | y = 1/4)$.


b. Fie D o mulțime de R puncte, $(x_1, y_1), (x_2, y_2), \dots, (x_R, y_R)$, selectate din $Rectangle(x_{lo}, y_{lo}, x_{hi}, y_{hi})$ în mod independent unele de altele.¹² Pentru simplitate, vom nota $\theta = (x_{lo}, y_{lo}, x_{hi}, y_{hi})$. Prin definiție, verosimilitatea datelor D este $P(D | \theta)$.

Dacă vrem să găsim $\theta^{MLE} \stackrel{not.}{=} (x_{lo}^{MLE}, y_{lo}^{MLE}, x_{hi}^{MLE}, y_{hi}^{MLE})$, valorile parametrilor care maximizează verosimilitatea datelor D , atunci este evident că vom lua

$$x_{lo}^{MLE} = \min_k \{x_k\}, y_{lo}^{MLE} = \min_k \{y_k\}, x_{hi}^{MLE} = \max_k \{x_k\}, y_{hi}^{MLE} = \max_k \{y_k\}.$$

În continuare, ca date concrete, vom folosi punctele $(x_i, y_i), i = 1, \dots, 6$, clasificate în trei „concepte” A, B, C care fac parte din clasa *Rectangle-PDF*:

x	y	Concept
1	4	A
3	1	A
2	2	B
7	3	B
3	2	C
4	5	C
5	2	C
6	5	C



¹²În mod riguros, în acest context conceptul $Rectangle(x_{lo}, y_{lo}, x_{hi}, y_{hi})$ desemnează mulțimea punctelor din plan pentru care funcția omonimă $Rectangle(x_{lo}, y_{lo}, x_{hi}, y_{hi})$ care a fost definită mai sus ia valori nenule. Această mulțime este exact dreptunghiul reprezentat în imaginea de mai sus și punctele din interiorul lui. Altfel spus, cu suprapunere de notație, funcția $Rectangle(x_{lo}, y_{lo}, x_{hi}, y_{hi})$ desemnează conceptul geometric $Rectangle(x_{lo}, y_{lo}, x_{hi}, y_{hi})$.

Vom avea, de *exemplu*, $p(2.5, 2.5 | A) \stackrel{\text{not.}}{=} p_{X,Y}(2.5, 2.5 | A) = 1/6$, fiindcă A este estimat în sensul verosimilității maxime (MLE) ca fiind $Rectangle(1, 1, 3, 4)$, deci cele două laturi ale dreptunghiului A sunt de mărime 2 și respectiv 3.


Folosind formula lui Bayes, calculați:

- $P(\text{Concept} = A | x = 1.5, y = 3)$
- $P(\text{Concept} = A | x = 2.5, y = 2.5)$
- $P(\text{Concept} = A | y = 5)$.

Răspuns:

a. În figura alăturată avem reprezentarea grafică a funcției $Rectangle(0, 0, 1/2, 2)$. Cum punctul $(1/4, 1/4)$ se găsește în interiorul dreptunghiului ($0 < \frac{1}{4} < \frac{1}{2}$ și $0 < \frac{1}{4} < 2$), rezultă că valoarea p.d.f. corelate cerute este:

$$p\left(x = \frac{1}{4}, y = \frac{1}{4}\right) = \frac{1}{\left(\frac{1}{2} - 0\right)(2 - 0)} = \frac{1}{\frac{1}{2} \cdot 2} = 1$$



Valorile p.d.f. marginale cerute sunt:

$$\begin{aligned} p\left(y = \frac{1}{4}\right) &= \int_{-\infty}^{\infty} p(x, y = \frac{1}{4}) dx \\ &= \int_{-\infty}^0 p(x, y = \frac{1}{4}) dx + \int_0^{1/2} p(x, y = \frac{1}{4}) dx + \int_{1/2}^{\infty} p(x, y = \frac{1}{4}) dx \\ &= \int_{-\infty}^0 0 dx + \int_0^{1/2} \frac{1}{\left(\frac{1}{2} - 0\right)(2 - 0)} dx + \int_{1/2}^{\infty} 0 dx \\ &= 0 + \int_0^{1/2} 1 dx + 0 = \frac{1}{2} - 0 = \frac{1}{2} \end{aligned}$$

$$\begin{aligned} p\left(x = \frac{1}{4}\right) &= \int_{-\infty}^{\infty} p(x = \frac{1}{4}, y) dy \\ &= \int_{-\infty}^0 p(x = \frac{1}{4}, y) dy + \int_0^2 p(x = \frac{1}{4}, y) dy + \int_2^{\infty} p(x = \frac{1}{4}, y) dy \\ &= \int_{-\infty}^0 0 dy + \int_0^2 \frac{1}{\left(\frac{1}{2} - 0\right)(2 - 0)} dy + \int_2^{\infty} 0 dy = 0 + \int_0^2 1 dy + 0 \\ &= 2 - 0 = 2 \end{aligned}$$

În sfârșit, valoarea p.d.f. condiționale cerute este:

$$p\left(x = \frac{1}{4} | y = \frac{1}{4}\right) = \frac{p(x = \frac{1}{4}, y = \frac{1}{4})}{p(y = \frac{1}{4})} = \frac{1}{\frac{1}{2}} = 2$$


Observație: Aceeași valoare pentru $p(x = \frac{1}{4} \mid y = \frac{1}{4})$ se obține și dacă observăm că variabilele x și y sunt independente, deci $p(x = \frac{1}{4} \mid y = \frac{1}{4}) = p(x = \frac{1}{4}) = 2$.

b. Ținând cont de date (vezi tabelul din enunț), cele trei concepte A, B, C vor fi estimate în sensul verosimilității maxime ca:

$$\text{Rectangle}_A(1, 1, 3, 4)$$

$$\text{Rectangle}_B(2, 2, 7, 3)$$

$$\text{Rectangle}_C(3, 2, 6, 5)$$



Așadar, vom avea:

$$p(x, y \mid A) = \begin{cases} \frac{1}{(3-1)(4-1)} = \frac{1}{6}, & \text{dacă } 1 \leq x \leq 3 \text{ și } 1 \leq y \leq 4 \\ 0, & \text{altfel;} \end{cases}$$

$$p(x, y \mid B) = \begin{cases} \frac{1}{(7-2)(3-2)} = \frac{1}{5}, & \text{dacă } 2 \leq x \leq 7 \text{ și } 2 \leq y \leq 3 \\ 0, & \text{altfel;} \end{cases}$$

$$p(x, y \mid C) = \begin{cases} \frac{1}{(6-3)(5-2)} = \frac{1}{9}, & \text{dacă } 3 \leq x \leq 6 \text{ și } 2 \leq y \leq 5 \\ 0, & \text{altfel.} \end{cases}$$

Acum putem calcula cele trei probabilități condiționale cerute, folosind formula lui Bayes. Probabilitățile a priori $P(A) = \frac{2}{8}$, $P(B) = \frac{2}{8}$ și $P(C) = \frac{4}{8}$ care intervin în aplicarea acestei formule au fost estimate din setul de date D din

enunț, în sensul verosimilității maxime. (A se vedea *Observația* de mai jos.)

$$\begin{aligned}
 P(\text{Concept} = A \mid x = 1.5, y = 3) &= \frac{P(x = 1.5, y = 3 \mid A) \cdot P(A)}{P(1.5, 3 \mid A) \cdot P(A) + P(1.5, 3 \mid B) \cdot P(B) + P(1.5, 3 \mid C) \cdot P(C)} \\
 &= \frac{\frac{1}{6} \cdot \frac{2}{8}}{\frac{1}{6} \cdot \frac{2}{8} + 0 \cdot \frac{2}{8} + 0 \cdot \frac{4}{8}} = 1 \\
 P(\text{Concept} = A \mid x = 2.5, y = 2.5) &= \frac{P(x = 2.5, y = 2.5 \mid A) \cdot P(A)}{P(2.5, 2.5 \mid A) \cdot P(A) + P(2.5, 2.5 \mid B) \cdot P(B) + P(2.5, 2.5 \mid C) \cdot P(C)} \\
 &= \frac{\frac{1}{6} \cdot \frac{2}{8}}{\frac{1}{6} \cdot \frac{2}{8} + \frac{1}{5} \cdot \frac{2}{8} + 0 \cdot \frac{4}{8}} = \frac{\frac{1}{6}}{\frac{1}{6} + \frac{1}{5}} = \frac{5}{5+6} = \frac{5}{11} \\
 P(\text{Concept} = A \mid y = 5) &= \frac{P(y = 5 \mid A) \cdot P(A)}{P(y = 5)} \\
 &= \frac{[\int_{-\infty}^{\infty} P(x = t, y = 5 \mid A) dt] \cdot P(A)}{P(y = 5)} = \frac{\int_{-\infty}^{\infty} 0 dt \cdot P(A)}{P(y = 5)} = \frac{0 \cdot P(A)}{P(y = 5)} = 0
 \end{aligned}$$

Observație: Așa cum am precizat deja, valorile probabilităților a priori $P(A) = \frac{2}{8}$, $P(B) = \frac{2}{8}$ și $P(C) = \frac{4}{8}$ au fost estimate (în sensul verosimilității maxime) din tabelul de date din enunț. Pentru a înțelege mai bine de ce s-a procedat așa, ar fi fost mai explicit dacă făceam condiționarea (și) în funcție de D , setul de date din enunț:

$$\begin{aligned}
 P(\text{Concept} = A \mid x = 1.5, y = 3, D) &= \\
 &= \frac{P(x = 1.5, y = 3 \mid A, D) \cdot P(A \mid D)}{P(1.5, 3 \mid A, D) \cdot P(A \mid D) + P(1.5, 3 \mid B, D) \cdot P(B \mid D) + P(1.5, 3 \mid C, D) \cdot P(C \mid D)}
 \end{aligned}$$

Totuși, din motive legate de simplitate, am optat pentru notația folosită mai sus.

22.

(Distribuția gaussiană uni-variată:
calculul mediei și al varianței)

■ □ CMU, 2010 spring, T. Mitchel, E. Xing, A. Singh, HW1, pr. 1.3.2

Distribuția gaussiană: p.d.f.

Considerăm o variabilă aleatoare X care are distribuția normală (gaussiană):


$$N(X = x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

unde σ poate fi orice număr real pozitiv, iar μ orice număr real.

Arătați că:

a. $E[X] = \mu$

b. $Var[X] = \sigma^2$



Răspuns:

a. Vom calcula media variabilei aleatoare X folosind formula de definiție:

$$E[X] = \int_{-\infty}^{\infty} xp(x)dx = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} x \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Facem schimbarea de variabilă $v = \frac{x-\mu}{\sigma} \Rightarrow x = \sigma v + \mu$ și $dx = \sigma dv$ și obținem:

$$\begin{aligned} E[X] &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} (\sigma v + \mu) e^{-\frac{v^2}{2}} (\sigma dv) = \frac{\sigma}{\sqrt{2\pi}\sigma} \left(\sigma \int_{-\infty}^{\infty} v e^{-\frac{v^2}{2}} dv + \mu \int_{-\infty}^{\infty} e^{-\frac{v^2}{2}} dv \right) \\ &= \frac{1}{\sqrt{2\pi}} \left(-\sigma \int_{-\infty}^{\infty} (-v) e^{-\frac{v^2}{2}} dv + \mu \int_{-\infty}^{\infty} e^{-\frac{v^2}{2}} dv \right) \\ &= \frac{1}{\sqrt{2\pi}} \left(\underbrace{-\sigma e^{-\frac{v^2}{2}}}_{=0} \Big|_{-\infty}^{\infty} + \mu \int_{-\infty}^{\infty} e^{-\frac{v^2}{2}} dv \right) = \frac{\mu}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{v^2}{2}} dv \end{aligned}$$

Pentru a calcula integrala din partea dreaptă vom folosi următorul artificiu:

$$\begin{aligned} \left(\int_{v=-\infty}^{\infty} e^{-\frac{v^2}{2}} dv \right)^2 &= \left(\int_{x=-\infty}^{\infty} e^{-\frac{x^2}{2}} dx \right) \cdot \left(\int_{y=-\infty}^{\infty} e^{-\frac{y^2}{2}} dy \right) \\ &= \int_{x=-\infty}^{\infty} \int_{y=-\infty}^{\infty} e^{-\frac{x^2+y^2}{2}} dy dx = \iint_{\mathbb{R}^2} e^{-\frac{x^2+y^2}{2}} dy dx \end{aligned}$$

Schimbând variabilele x, y în coordonatele polare r, θ obținem:

$$\begin{aligned} \left(\int_{v=-\infty}^{\infty} e^{-\frac{v^2}{2}} dv \right)^2 &= \int_{r=0}^{\infty} \int_{\theta=0}^{2\pi} e^{-\frac{r^2}{2}} (r dr d\theta) = \int_{r=0}^{\infty} r e^{-\frac{r^2}{2}} \left(\int_{\theta=0}^{2\pi} d\theta \right) dr \\ &= \int_{r=0}^{\infty} r e^{-\frac{r^2}{2}} \theta \Big|_0^{2\pi} dr = 2\pi \int_{r=0}^{\infty} r e^{-\frac{r^2}{2}} dr = 2\pi \left(-e^{-\frac{r^2}{2}} \right) \Big|_0^{\infty} = 2\pi(0 - (-1)) = 2\pi \end{aligned}$$

Notă: Schimbarea în coordonate polare a fost realizată utilizând formulele $x = r \cos \theta$ și $y = r \sin \theta$, cu $r \geq 0$ și $r \in [0, 2\pi)$. Așadar, $x^2 + y^2 = r^2$, iar matricea jacobiană corespunzătoare acestei transformări de coordonate este:

$$\frac{\partial(x, y)}{\partial(r, \theta)} = \begin{vmatrix} \frac{\partial x}{\partial r} & \frac{\partial x}{\partial \theta} \\ \frac{\partial y}{\partial r} & \frac{\partial y}{\partial \theta} \end{vmatrix} = \begin{vmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{vmatrix} = r \cos^2 \theta + r \sin^2 \theta = r \geq 0,$$

de unde a rezultat $dx dy = r dr d\theta$.

Revenind la calculul mediei variabilei aleatoare $X \sim N(\mu, \sigma)$, obținem:

$$E[X] = \frac{\mu}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{v^2}{2}} dv = \frac{\mu}{\sqrt{2\pi}} \sqrt{2\pi} = \mu.$$

b. Trebuie să arătăm că $\text{Var}[X] = \sigma^2$. Vom calcula varianța lui X utilizând formula $\text{Var}[X] = E[X^2] - (E[X])^2$. Întrucât am calculat $E[X]$, trebuie să mai calculăm valoarea mediei lui X^2 .

$$E[X^2] = \int_{-\infty}^{\infty} x^2 p(x) dx = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} x^2 \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Făcând aceeași schimbare de variabilă $v = \frac{x-\mu}{\sigma} \Rightarrow x = \sigma v + \mu$, cu $dx = \sigma dv$, obținem:

$$\begin{aligned} E[X^2] &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} (\sigma v + \mu)^2 e^{-\frac{v^2}{2}} (\sigma dv) = \frac{\sigma}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} (\sigma^2 v^2 + 2\sigma\mu v + \mu^2) e^{-\frac{v^2}{2}} dv \\ &= \frac{1}{\sqrt{2\pi}} \left(\sigma^2 \int_{-\infty}^{\infty} v^2 e^{-\frac{v^2}{2}} dv + 2\sigma\mu \int_{-\infty}^{\infty} v e^{-\frac{v^2}{2}} dv + \mu^2 \int_{-\infty}^{\infty} e^{-\frac{v^2}{2}} dv \right) \end{aligned}$$

Știm că $\int_{-\infty}^{\infty} e^{-\frac{v^2}{2}} dv = \sqrt{2\pi}$ (de la punctul a) și calculăm ușor $\int_{-\infty}^{\infty} v e^{-\frac{v^2}{2}} dv =$

$$\left. -e^{-\frac{v^2}{2}} \right|_{-\infty}^{\infty} = 0.$$

Rămâne de calculat prima integrală. Pentru aceasta vom utiliza metoda de integrare prin părți:

$$\begin{aligned}\int_{-\infty}^{\infty} v^2 e^{-\frac{v^2}{2}} dv &= \int_{-\infty}^{\infty} (-v) \left(-ve^{-\frac{v^2}{2}} \right) dv = \int_{-\infty}^{\infty} (-v) \left(e^{-\frac{v^2}{2}} \right)' dv \\ &= (-v) e^{-\frac{v^2}{2}} \Big|_{-\infty}^{\infty} - \int_{-\infty}^{\infty} (-1) e^{-\frac{v^2}{2}} dv = 0 + \int_{-\infty}^{\infty} e^{-\frac{v^2}{2}} dv = \sqrt{2\pi}.\end{aligned}$$

Pentru a calcula valoarea integralei definite am folosit următoarea proprietate:

$$\lim_{v \rightarrow \infty} v e^{-\frac{v^2}{2}} = \lim_{v \rightarrow \infty} \frac{v}{e^{\frac{v^2}{2}}} \stackrel{\text{L'Hôpital}}{=} \lim_{v \rightarrow \infty} \frac{1}{v e^{\frac{v^2}{2}}} = 0 = \lim_{v \rightarrow -\infty} v e^{-\frac{v^2}{2}}.$$

Așadar,

$$E[X^2] = \frac{1}{\sqrt{2\pi}} \left(\sigma^2 \sqrt{2\pi} + 2\sigma\mu \cdot 0 + \mu^2 \sqrt{2\pi} \right) = \sigma^2 + \mu^2.$$

Deci varianța variabilei aleatoare $X \sim N(\mu, \sigma)$ este:

$$\text{Var}[X] = E[X^2] - (E[X])^2 = (\sigma^2 + \mu^2) - \mu^2 = \sigma^2.$$

23.

(Distribuția normală:
reducerea cazului nestandard la cazul standard)

CMU, 2004 fall, T. Mitchell, Z. Bar-Joseph, HW1, pr. 3

Considerăm variabila aleatoare X cu distribuția normală de medie $\mu = 1$ și varianță $\sigma^2 = 4$. Calculați următoarele probabilități:

a. $P(X \leq 3)$.

b. $P(|X| \leq 2)$.

Indicație: Pentru a calcula aceste probabilități, soluția este să transformați variabila aleatoare X în distribuția normală standard Z după formula: $Z = \frac{X - \mu}{\sigma}$. Pentru distribuția probabilistă normală standard ($\mu = 0$ și $\sigma = 1$), valorile funcției de distribuție cumulativă (engl., cumulative distribution function), notată Φ și definită prin relația $\Phi(x) \stackrel{\text{not.}}{=} P(Z \leq x)$, se consideră că sunt deja calculate. Puteți folosi următorul tabel de valori:

x	$\Phi(x)$	x	$\Phi(x)$	x	$\Phi(x)$	x	$\Phi(x)$
-3.4	0.0003	-1.7	0.0446	0.0	0.5000	1.7	0.9554
-3.3	0.0005	-1.6	0.0548	0.1	0.5398	1.8	0.9641
-3.2	0.0007	-1.5	0.0668	0.2	0.5793	1.9	0.9713
-3.1	0.0010	-1.4	0.0808	0.3	0.6179	2.0	0.9772
-3.0	0.0013	-1.3	0.0968	0.4	0.6554	2.1	0.9821
-2.9	0.0019	-1.2	0.1151	0.5	0.6915	2.2	0.9861
-2.8	0.0026	-1.1	0.1357	0.6	0.7257	2.3	0.9893
-2.7	0.0035	-1.0	0.1587	0.7	0.7580	2.4	0.9918
-2.6	0.0062	-0.9	0.1841	0.8	0.7881	2.5	0.9938
-2.5	0.0062	-0.8	0.2119	0.9	0.8159	2.6	0.9953
-2.4	0.0082	-0.7	0.2420	1.0	0.8413	2.7	0.9965
-2.3	0.0107	-0.6	0.2743	1.1	0.8643	2.8	0.9974
-2.2	0.0139	-0.5	0.3085	1.2	0.8849	2.9	0.9981
-2.1	0.0179	-0.4	0.3446	1.3	0.9032	3.0	0.9987
-2.0	0.0228	-0.3	0.3821	1.4	0.9192	3.1	0.9990
-1.9	0.0287	-0.2	0.4207	1.5	0.9332	3.2	0.9993
-1.8	0.0359	-0.1	0.4602	1.6	0.9452	3.3	0.9995

Răspuns:

a. $P(X \leq 3) = P\left(\frac{X - \mu}{\sigma} \leq \frac{3 - \mu}{\sigma}\right) = P\left(Z \leq \frac{3 - 1}{\sqrt{4}}\right) = P(Z \leq 1) = \Phi(1) = 0.8413.$

b. Vom proceda analog, descompunând probabilitatea $P(|X| \leq 2) = P(-2 \leq X \leq 2)$ într-o diferență de două probabilități:

$$\begin{aligned}
 P(|X| \leq 2) &= P(-2 \leq X \leq 2) = P(X \leq 2) - P(X \leq -2) \\
 &= P(X - 1 \leq 2 - 1) - P(X - 1 \leq -2 - 1) \\
 &= P\left(\frac{X - 1}{\sqrt{4}} \leq \frac{2 - 1}{\sqrt{4}}\right) - P\left(\frac{X - 1}{\sqrt{4}} \leq \frac{-2 - 1}{\sqrt{4}}\right) \\
 &= P\left(Z \leq \frac{2 - 1}{2}\right) - P\left(Z \leq \frac{-2 - 1}{2}\right) = \Phi\left(\frac{1}{2}\right) - \Phi\left(-\frac{3}{2}\right) \\
 &= 0.6915 - 0.0668 = 0.6247
 \end{aligned}$$

24.

(O proprietate: matricea de covarianță a oricărui vector de variabile aleatoare este simetrică și pozitiv semi-definită)

■ □ prelucrare de Liviu Ciortuz după

“The Multivariate Gaussian Distribution”, Chuong B. Do, 2008

Fie variabilele aleatoare X_1, \dots, X_n , cu $X_i : \Omega \rightarrow \mathbb{R}$ pentru $i = 1, \dots, n$. Matricea de covarianță a vectorului de variabile aleatoare $X = (X_1, \dots, X_n)$ este o matrice pătratică de dimensiune $n \times n$, ale cărei elemente se definesc astfel: $[Cov(X)]_{ij} \stackrel{\text{def.}}{=} Cov(X_i, X_j)$, pentru orice $i, j \in \{1, \dots, n\}$.

Arătați că $\Sigma \stackrel{\text{not.}}{=} Cov(X)$ este matrice simetrică și pozitiv semi-definită, cea de-a doua proprietate însemnând că pentru orice vector $z \in \mathbb{R}^n$ are loc inegalitatea

$z^\top \Sigma z \geq 0$. (Vectorii $z \in \mathbb{R}^n$ sunt considerați vectori-coloană, iar simbolul \top reprezintă operația de transpunere de matrice.)

Răspuns:

Faptul că matricea Σ este simetrică decurge imediat din definiția ei: dacă $X = (X_1, \dots, X_n)$, atunci $[Cov(X)]_{i,j} \stackrel{\text{def.}}{=} Cov(X_i, X_j) = E[(X_i - E[X_i])(X_j - E[X_j])] = E[(X_j - E[X_j])(X_i - E[X_i])] = Cov(X_j, X_i) = [Cov(X)]_{j,i}$, pentru orice $i, j \in \{1, \dots, n\}$.

Apoi, pentru orice vector $z \in \mathbb{R}^n$ de forma $z = (z_1, \dots, z_n)$, avem:

$$\begin{aligned} z^\top \Sigma z &= \sum_{i=1}^n z_i \left(\sum_{j=1}^n \Sigma_{ij} z_j \right) = \sum_{i=1}^n \sum_{j=1}^n (z_i \Sigma_{ij} z_j) = \sum_{i=1}^n \sum_{j=1}^n (z_i Cov[X_i, X_j] z_j) \\ &= \sum_{i=1}^n \sum_{j=1}^n (z_i E[(X_i - E[X_i])(X_j - E[X_j])] z_j) \\ &= E \left[\sum_{i=1}^n \sum_{j=1}^n z_i (X_i - E[X_i])(X_j - E[X_j]) z_j \right] \end{aligned}$$

Ultima dintre egalitățile de mai sus derivă din proprietatea de liniaritate a mediilor. Mai departe,

$$\begin{aligned} z^\top \Sigma z &= E \left[\left(\sum_{i=1}^n z_i (X_i - E[X_i]) \right) \left(\sum_{j=1}^n (X_j - E[X_j]) z_j \right) \right] \\ &= E \left[\left(\sum_{i=1}^n (X_i - E[X_i]) z_i \right) \left(\sum_{j=1}^n (X_j - E[X_j]) z_j \right) \right] \end{aligned}$$

Pentru a finaliza demonstrația, să mai observăm că ultima expresie obținută mai sus se scrie sub formă vectorială astfel:

$$E[(X - E[X])^\top \cdot z]^2,$$

ceea ce evident, reprezintă o cantitate ne-negativă. Așadar, $z^\top \Sigma z \geq 0$.

25.

(Distribuții gaussiene multi-variate: o proprietate importantă, în cazul în care matricea de covarianță este diagonală)

■ □ ● prelucrare de Liviu Ciortuz după
“The Multivariate Gaussian Distribution”, Chuong B. Do, 2008

Fie o variabilă aleatoare $X : \Omega \rightarrow \mathbb{R}^d$. În cele ce urmează elementele din \mathbb{R}^d vor fi considerate vectori-coloană. Vom nota cu \mathbb{S}_+^d spațiul matricilor simetrice pozitiv definite¹³ de dimensiune $d \times d$.

Vom spune că variabila X , reprezentată sub forma $X = [X_1 \dots X_d]^\top$, urmează o distribuție gaussiană (sau, *normală*) multi-variată, având media $\mu \in \mathbb{R}^d$ și

¹³Prin definiție, o matrice $A \in \mathbb{R}^{d \times d}$ este pozitiv definită dacă $x^\top A x > 0$ pentru orice $x \neq 0$ din \mathbb{R}^d , unde simbolul \top reprezintă operația de transpunere de matrice.

matricea de covarianță $\Sigma \in \mathbb{S}_+^d$, dacă funcția ei de densitate [de probabilitate] are forma analitică următoare:

$$p(x; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu)^\top \Sigma^{-1} (x - \mu) \right),$$

unde notația $|\Sigma|$ desemnează discriminantul matricii Σ , iar $\exp(\cdot)$ desemnează funcția exponențială având baza e .¹⁴ Pe scurt, vom nota această proprietate de definiție a lui X sub forma $X \sim \mathcal{N}(\mu, \Sigma)$.

Observații:

1. Se poate demonstra că orice matrice pozitiv definită Σ este inversabilă (deci $|\Sigma| \neq 0$), iar Σ^{-1} este de asemenea matrice pozitiv definită. Așadar pentru orice vector nenul z , vom avea $z^\top \Sigma^{-1} z > 0$. Aceasta implică faptul că pentru orice vector $x \neq \mu$, vom avea:

$$(x - \mu)^\top \Sigma^{-1} (x - \mu) > 0, \text{ deci } -\frac{1}{2} (x - \mu)^\top \Sigma^{-1} (x - \mu) < 0.$$

Similar cazului uni-variat, graficul acestei funcții exponențiale va avea forma unui clopot cu deschiderea quadratică, îndreptată în jos.

2. Coeficientul funcției exponențiale, adică $\frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}}$, nu depinde de x , prin urmare el este doar un factor de normalizare folosit pentru a ne asigura că

$$\frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \exp((x - \mu)^\top \Sigma^{-1} (x - \mu)) dx_1 dx_2 \dots dx_d = 1.$$

Considerăm cazul simplu, în care $d = 2$ și matricea de covarianță Σ este diagonală,¹⁵ deci

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad \mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} \quad \Sigma = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$$

Arătați că într-un astfel de caz, expresia funcției de densitate [de probabilitate] gaussiană multi-variată este identică cu produsul a două funcții de densitate de tip gaussian, uni-variate și independente, prima funcție având media μ_1 și varianța σ_1^2 , iar cea de-a doua având media μ_2 și varianța σ_2^2 .

Răspuns:

În condițiile de mai sus, funcția de densitate [de probabilitate] gaussiană multi-variată are forma

$$p(x; \mu, \Sigma) = \frac{1}{2\pi \begin{vmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{vmatrix}^{\frac{1}{2}}} \exp \left(-\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^\top \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right)$$

¹⁴În cazul general al unui vector X format din d variabile aleatoare, elementul generic (i, j) al matricii de covarianță asociate lui X este prin definiție $Cov(X_i, X_j) = E[(X_i - E[X_i])(X_j - E[X_j])]$ pentru $i, j \in \{1, \dots, d\}$. Pentru demonstrația faptului că matricea de covarianță Σ este întotdeauna simetrică și pozitiv semi-definită vezi problema 24.

¹⁵În aceste condiții, se poate demonstra ușor că elementele de pe diagonala matricii Σ sunt strict pozitive. Într-adevăr, este suficient să se particularizeze vectorul z din formalizarea proprietății de *pozitiv-definită* a matricii Σ la valoarea $z = (1, 0)$ și respectiv $z = (0, 1)$.

Aplicând mai întâi formula pentru determinantul de ordin 2,¹⁶ și calculând apoi inversa matricei Σ , obținem:

$$\begin{aligned}
 p(x; \mu, \Sigma) &= \frac{1}{2\pi \sigma_1 \sigma_2} \exp \left(-\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^\top \left(\frac{1}{\sigma_1^2 \sigma_2^2} \begin{bmatrix} \sigma_2^2 & 0 \\ 0 & \sigma_1^2 \end{bmatrix} \right) \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right) \\
 &= \frac{1}{2\pi \sigma_1 \sigma_2} \exp \left(-\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^\top \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right) \\
 &= \frac{1}{2\pi \sigma_1 \sigma_2} \exp \left(-\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^\top \begin{bmatrix} \frac{1}{\sigma_1^2} (x_1 - \mu_1) \\ \frac{1}{\sigma_2^2} (x_2 - \mu_2) \end{bmatrix} \right) \\
 &= \frac{1}{2\pi \sigma_1 \sigma_2} \exp \left(-\frac{1}{2\sigma_1^2} (x_1 - \mu_1)^2 - \frac{1}{2\sigma_2^2} (x_2 - \mu_2)^2 \right) \\
 &= \frac{1}{\sqrt{2\pi} \sigma_1} \exp \left(-\frac{1}{2\sigma_1^2} (x_1 - \mu_1)^2 \right) \frac{1}{\sqrt{2\pi} \sigma_2} \exp \left(-\frac{1}{2\sigma_2^2} (x_2 - \mu_2)^2 \right) \\
 &= p(x_1; \mu_1, \sigma_1^2) p(x_2; \mu_2, \sigma_2^2).
 \end{aligned}$$

Generalizând, este imediat că orice variabilă gaussiană d -dimensională de medie $\mu \in \mathbb{R}^d$ și matrice de covarianță diagonală $\Sigma \stackrel{not.}{=} \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_d^2)$, se comportă ca o colecție de d variabile aleatoare gaussiene uni-variate independente, având respectiv mediile μ_i și varianțele σ_i^2 .

26.

(Distribuția gaussiană bi-variată; o proprietate:
distribuția condițională a unei componente
în raport cu cealaltă componentă
este tot de tip gaussian;
identificarea parametrilor acestei distribuții condiționale)

■ □ · formulare de Liviu Ciortuz, după
“Pattern Classification” (2nd ed.),

[Appendix A. Mathematical foundations]

R. Duda, P. Hart, D. Stork. John Wiley & Sons Inc., 2001

Fie X o variabilă aleatoare care urmează o distribuție gaussiană bi-variată de parametri μ (vectorul de medii) și Σ (matricea de covarianță). Așadar, $\mu = (\mu_1, \mu_2) \in \mathbb{R}^2$, iar $\Sigma \in \mathcal{M}_{2 \times 2}(\mathbb{R})$.

Prin definiție, $\Sigma = \text{Cov}(X, X)$, unde $X \stackrel{not.}{=} (X_1, X_2)$, așadar $\Sigma_{ij} = \text{Cov}(X_i, X_j)$ pentru $i, j \in \{1, 2\}$. De asemenea, $\text{Cov}(X_i, X_i) = \text{Var}[X_i] \stackrel{not.}{=} \sigma_i^2 \geq 0$ pentru $i \in \{1, 2\}$, în vreme ce pentru $i \neq j$ avem $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i) \stackrel{not.}{=} \sigma_{ij}$. În sfârșit, dacă introducem „coeficientul de corelare” $\rho \stackrel{def.}{=} \frac{\sigma_{12}}{\sigma_1 \sigma_2}$, rezultă că putem scrie matricea de covarianță Σ sub forma următoare:

¹⁶ Anume, $\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$.

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}. \quad (1)$$

Demonstrați că ipoteza $X \sim \mathcal{N}(\mu, \Sigma)$ implică faptul că distribuția condițională $X_2|X_1$ este de tip gaussian, și anume $X_2|X_1 = x_1 \sim \mathcal{N}(\mu_{2|1}, \sigma_{2|1}^2)$, cu $\mu_{2|1} = \mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ și $\sigma_{2|1}^2 = \sigma_2^2(1 - \rho^2)$.

Observație: Pentru $X_1|X_2$, rezultatul este similar: $X_1|X_2 = x_2 \sim \mathcal{N}(\mu_{1|2}, \sigma_{1|2}^2)$, cu $\mu_{1|2} = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(x_2 - \mu_2)$ și $\sigma_{1|2}^2 = \sigma_1^2(1 - \rho^2)$.

Răspuns:

Conform definiției distribuției condiționale, $X_2|X_1 = x_1$ are funcția de densitate de probabilitate

$$p(x_2|x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}, \quad (2)$$

unde p_{X_1, X_2} este densitatea distribuției gaussiene bi-variate de parametri μ și Σ , iar p_{X_1} este distribuția marginală a variabilei X_1 . Așadar,

$$\begin{aligned} p_{X_1, X_2}(x_1, x_2) &= \frac{1}{(\sqrt{2\pi})^2 \sqrt{|\Sigma|}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right) \text{ și} \\ p_{X_1}(x_1) &= \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{1}{2\sigma_1^2}(x_1 - \mu_1)^2\right). \end{aligned} \quad (3)$$

Se constată imediat din relația (1) că *determinantul* matricei Σ este $\sigma_1^2\sigma_2^2(1 - \rho^2)$. Întrucât din expresia lui p_{X_1, X_2} de mai sus rezultă că Σ trebuie să fie matrice inversabilă și că trebuie să existe radicalul din $|\Sigma|$, vom avea $\rho \in (-1, 1)$. În sfârșit, pentru că se consideră $\sigma_1, \sigma_2 > 0$, rezultă că $\sqrt{|\Sigma|} = \sigma_1\sigma_2\sqrt{1 - \rho^2}$.

Inversa matricei Σ se calculează astfel:

$$\begin{aligned} \Sigma^{-1} &= \frac{1}{\sigma_1^2\sigma_2^2(1 - \rho^2)} \Sigma^* = \frac{1}{\sigma_1^2\sigma_2^2(1 - \rho^2)} \begin{bmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{bmatrix} \\ &= \frac{1}{(1 - \rho^2)} \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{\rho}{\sigma_1\sigma_2} \\ -\frac{\rho}{\sigma_1\sigma_2} & \frac{1}{\sigma_2^2} \end{bmatrix} \end{aligned}$$

Prin urmare,

$$\begin{aligned} p_{X_1, X_2}(x_1, x_2) &= \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1 - \rho^2}} \exp\left(-\frac{1}{2}(x_1 - \mu_1) \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{\rho}{\sigma_1\sigma_2} \\ -\frac{\rho}{\sigma_1\sigma_2} & \frac{1}{\sigma_2^2} \end{bmatrix} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}\right) \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1 - \rho^2}} \cdot \\ &\quad \exp\left(-\frac{1}{2(1 - \rho^2)} \left[\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sigma_1}\right) \left(\frac{x_2 - \mu_2}{\sigma_2}\right) + \left(\frac{x_2 - \mu_2}{\sigma_2}\right)^2 \right]\right) \end{aligned} \quad (4)$$

Observație: Din expresia pe care tocmai am obținut-o se observă ușor că $p_{X_1, X_2}(x_1, x_2)$ își atinge maximul atunci când $(x_1, x_2) = (\mu_1, \mu_2)$. Curbele de ecuație $p_{X_1, X_2}(x_1, x_2) = c$, pentru diverse valori ale lui $c \in \mathbb{R}^+$, se numesc *curbe de izocontur*. Ele au formă elipsoidală.

Înlocuind expresiile (3) și (4) în definiția (2), vom obține:

$$\begin{aligned} p(x_2|x_1) &= \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)} \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \\ &\quad \exp\left(-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x_1-\mu_1}{\sigma_1}\right)^2 - 2\rho\left(\frac{x_1-\mu_1}{\sigma_1}\right)\left(\frac{x_2-\mu_2}{\sigma_2}\right) + \left(\frac{x_2-\mu_2}{\sigma_2}\right)^2\right]\right) \\ &\quad \cdot \sqrt{2\pi}\sigma_1 \exp\left(\frac{1}{2}\left(\frac{x_1-\mu_1}{\sigma_1}\right)^2\right) \\ &= \frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right] \\ &= \frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2}\left(\frac{x_2 - [\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)]}{\sigma_2\sqrt{1-\rho^2}}\right)^2\right] \end{aligned}$$

Din această expresie se observă că $X_2|X_1 = x_1$ urmează o distribuție gaussiană de parametri $\mu_{2|1} \stackrel{\text{not.}}{=} \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ și $\sigma_{2|1}^2 \stackrel{\text{not.}}{=} \sigma_2^2(1 - \rho^2)$.

27. (Variabile aleatoare discrete: distribuția Bernoulli, distribuția normală standard; intervale de încredere, teorema limită centrală; aplicație la calculul erorii reale a unui clasificator)
 ■● CMU, 2008 fall, Eric Xing, HW3, pr. 3.3

Nu demult, Chris s-a decis să folosească un nou clasificator (binar) care filtrează emailurile spam. Ulterior, el a vrut să evalueze cât de bun este acest clasificator. În acest scop, el a testat clasificatorul pe un mic set de date constituit din 100 de emailuri alese în mod aleatoriu dintre toate emailurile sale. Rezultatul pe care l-a obținut a fost următorul: 83 de emailuri au fost clasificate corect. Așadar rata erorii produse (sau: eroarea medie produsă) de clasificator pe acest mic set de date este de 17%. Este evident însă că eroarea aceasta este mai mică sau mai mare decât *eroarea reală*, pur și simplu datorită alegerii aleatoare a celor 100 de emailuri.

Dacă se consideră un nivel de încredere de 95%, în ce interval se va situa eroarea reală (ținând cont de acest experiment)?

Răspuns:

Vom nota cu X_i variabila aleatoare care reprezintă producerea unui mesaj email ($i = 1, \dots, n = 100$) și vom considera că $X_i = 1$ dacă emailul respectiv este clasificat eronat și 0 în cazul contrar.

Notăm cu $\mu \stackrel{\text{not.}}{=} e_{\text{real}}$ media variabilei X_i și cu σ^2 varianța variabilei X_i . (Valorile lui μ și σ nu depind de i).

Conform Teoremei Limită Centrală, eroarea la eșantionare,

$$e_{\text{sample}} \stackrel{\text{not.}}{=} \frac{X_1 + \dots + X_n}{n},$$

văzută ca variabilă aleatoare, este aproximată de $\mathcal{N}(\mu, \sigma)$, distribuția normală de medie μ și varianță σ^2 . În consecință, notând

$$Z_n = \frac{X_1 + \dots + X_n - n\mu}{\sqrt{n} \sigma},$$

rezultă că $Z_n \sim \mathcal{N}(0, 1)$, deci pentru orice $a \in \mathbb{R}$ vom avea $P(Z_n \leq a) \rightarrow \Phi(a)$, unde $\Phi(x) \stackrel{\text{def.}}{=} P(Z \leq x)$ desemnează funcția de distribuție cumulativă (engl., cumulative distribution function, c.d.f.) pentru distribuția normală standard (vezi problema 23).

Folosind notațiile de mai sus, vom scrie următoarele echivalențe, care au loc pentru orice $a \geq 0$:

$$\begin{aligned} |Z_n| \leq a &\Leftrightarrow \left| \frac{X_1 + \dots + X_n - n\mu}{\sqrt{n} \sigma} \right| \leq a \Leftrightarrow \left| \frac{X_1 + \dots + X_n - n\mu}{n\sigma} \right| \leq \frac{a}{\sqrt{n}} \\ &\Leftrightarrow \left| \frac{X_1 + \dots + X_n - n\mu}{n} \right| \leq \frac{a\sigma}{\sqrt{n}} \Leftrightarrow \left| \frac{X_1 + \dots + X_n}{n} - \mu \right| \leq \frac{a\sigma}{\sqrt{n}} \\ &\Leftrightarrow |e_{\text{sample}} - e_{\text{real}}| \leq \frac{a\sigma}{\sqrt{n}} \Leftrightarrow |e_{\text{real}} - e_{\text{sample}}| \leq \frac{a\sigma}{\sqrt{n}} \\ &\Leftrightarrow -\frac{a\sigma}{\sqrt{n}} \leq e_{\text{real}} - e_{\text{sample}} \leq \frac{a\sigma}{\sqrt{n}} \Leftrightarrow e_{\text{sample}} - \frac{a\sigma}{\sqrt{n}} \leq e_{\text{real}} \leq e_{\text{sample}} + \frac{a\sigma}{\sqrt{n}} \\ &\Leftrightarrow e_{\text{real}} \in [e_{\text{sample}} - \frac{a\sigma}{\sqrt{n}}, e_{\text{sample}} + \frac{a\sigma}{\sqrt{n}}] \end{aligned} \quad (5)$$

Pentru a determina efectiv intervalul de încredere cerut, rămâne să mai aflăm a și σ și apoi să le înlocuim în relația (5).

Constanta a se determină ușor ținând cont de faptul că în enunț se precizează *nivelul de încredere* (95%) pentru apartenența erorii reale la intervalul specificat. Această restricție corespunde relației $P(|Z_n| \leq a) = 0.95$. Pe de altă parte, întrucât $\Phi(-a) + \Phi(a) = 1$, avem:

$$P(|Z_n| \leq a) = \Phi(a) - \Phi(-a) = 2\Phi(a) - 1,$$

deci

$$P(|Z_n| \leq a) = 0.95 \Leftrightarrow 2\Phi(a) - 1 = 0.95 \Leftrightarrow \Phi(a) = 0.975 \Leftrightarrow a \cong 1.97 \text{ (vezi pr. 23)}.$$

Ne-a mai rămas de calculat valoarea lui σ . Vom ține cont de faptul că

$$\sigma^2 \stackrel{\text{not.}}{=} \text{Var}_{\text{real}} = e_{\text{real}}(1 - e_{\text{real}}), \quad (6)$$

ultima egalitate având loc fiindcă toate variabilele X_i sunt de tip Bernoulli. În relația (6) vom putea aproxima e_{real} cu e_{sample} , întrucât

$$E[e_{\text{sample}}] = e_{\text{real}} \text{ și } \text{Var}_{\text{sample}} = \frac{1}{n} \text{Var}_{\text{real}} \rightarrow 0 \text{ pentru } n \rightarrow +\infty,$$

conform raționamentelor din problema 5.ab de la capitolul *Estimarea probabilităților*.

În sfârșit, putem scrie:

$$\frac{a\sigma}{\sqrt{n}} = \frac{\sqrt{0.17(1-0.17)}}{\sqrt{100}} \cong 0.07,$$

deci relația (5) devine $e_{real} \in [0.10, 0.24]$.

Sumarizând, putem afirma cu încredere de 95% că eroarea reală a clasificatorului folosit de Chris este mai mare sau egală cu 0.1 și mai mică sau egală cu 0.24.

28.

(Variabile aleatoare: Adevărat sau Fals?)

CMU, 2006 fall, E. Xing, T. Mitchell, final exam, pr. 1.b
CMU, 2008 fall, Eric Xing, midterm exam, pr. 1.1, 1.2, 1.3

a. Dacă o variabilă aleatoare continuă X are funcția densitate de probabilitate p diferită de zero pe tot domeniul de definiție, atunci probabilitatea ca X să ia o valoare oarecare x (notație: $P(X = x)$) este egală cu $p(x)$.

b. $E[X + Y] = E[X] + E[Y]$ pentru orice două variabile aleatoare X și Y .

c. $Var[X + Y] = Var[X] + Var[Y]$ pentru orice două variabile aleatoare X și Y .

d. $E[XY] = E[X] \cdot E[Y]$ pentru orice două variabile aleatoare X și Y .

Răspuns:

a. Fals (în general). Dacă variabila aleatoare continuă X are funcția densitate de probabilitate p , atunci $P(a \leq X \leq b) = \int_a^b p(x)dx$. Prin urmare, $P(X = x) = 0$ pentru orice $x \in \mathbb{R}$. Enunțul afirmă pe de o parte că $p(x) = P(X = x) = 0$ pentru un anume $x \in \mathbb{R}$, iar pe de altă parte că p este diferită de zero pe tot domeniul de definiție, ceea ce este absurd.

b. Adevărat. Demonstrația este făcută în problema 9 punctul a.

c. Fals (în general). Se poate considera situația $Y = -X$, caz în care $Var[X + Y] = 0$, dar $Var[X] + Var[Y] = E[X^2] - (E[X])^2 + E[(-X)^2] - (E[-X])^2 = 2Var[X]$. Așadar, pentru orice variabilă aleatoare X cu $Var[X] \neq 0$, luând $Y = -X$, rezultă că $Var[X + Y] = 0$ iar $Var[X] + Var[Y] \neq 0$. Un exemplu de variabilă aleatoare cu varianța nenulă este distribuția gaussiană.

Mai *general*, se poate demonstra că $Var[X + Y] = Var[X] + Var[Y] + 2Cov[X, Y]$ astfel:

$$\begin{aligned} Var[X + Y] &= E[(X + Y)^2] - (E[X + Y])^2 \\ &= E[X^2 + 2XY + Y^2] - (E[X] + E[Y])^2 \\ &= E[X^2] + 2E[XY] + E[Y^2] - (E[X])^2 - 2E[X] \cdot E[Y] - (E[Y])^2 \\ &= (E[X^2] - (E[X])^2) + (E[Y^2] - (E[Y])^2) + (2E[XY] - 2E[X] \cdot E[Y]) \\ &= Var[X] + Var[Y] + 2Cov[X, Y] \end{aligned}$$

Prin urmare, egalitatea din enunț este adevărată pentru orice două variabile aleatoare X și Y pentru care $Cov[X, Y] = 0$ (vezi problema 9.c), dar este falsă în rest. Egalitatea $Cov[X, Y] = 0$ este adevărată de exemplu atunci când X și Y sunt variabile independente (vezi problema 10).

d. Fals, în general. Afirmatia din enunț este echivalentă cu $Cov[X, Y] = 0$. Așa cum am menționat la punctul c, ea este adevărată dacă, de exemplu X și Y sunt variabile aleatoare independente. Dacă, în schimb, vom considera de pildă cazul $Y = X$, cu X variabilă aleatoare binară care ia valoarea 1 cu probabilitatea p și valoarea 0 cu probabilitatea $1 - p$, se poate arăta imediat că $E[X^2] \neq (E[X])^2$ pentru orice $p \in (0, 1)$.

Variabile aleatoare

46. (Variabile aleatoare: independența condițională;
Formula lui Bayes)

◦ CMU, 2005 fall, T. Mitchell, A. Moore, midterm, pr. 1.1

a. Fie variabilele aleatoare H , E_1 și E_2 . Presupunem că vrem să calculăm $P(H | E_1, E_2)$, dar nu avem informații referitoare la independența condițională. Care din următoarele seturi de numere sunt suficiente pentru acest scop?

- i. $P(E_1, E_2)$, $P(H)$, $P(E_1 | H)$, $P(E_2 | H)$
- ii. $P(E_1, E_2)$, $P(H)$, $P(E_1, E_2 | H)$
- iii. $P(H)$, $P(E_1 | H)$, $P(E_2 | H)$.

b. Presupunem acum că $P(E_1 | H, E_2) = P(E_1 | H)$ pentru toate valorile posibile ale lui H , E_1 și E_2 . În acest caz, care dintre seturile de numere de la punctul a sunt suficiente pentru a calcula $P(H | E_1, E_2)$?

47. (Independența condițională a variabilelor aleatoare:
o proprietate)

* CMU, 2009 fall, Geoff Gordon, HW2, pr. 2.2

Arătați că dacă variabilele aleatoare X și Y sunt independente în raport cu Z (adică: $P(X, Y | Z) = P(X | Z) \cdot P(Y | Z)$), iar distribuția de probabilitate corelată a lui X și Y este independentă de W în raport cu Z , atunci X și W sunt independente în raport cu Z .

În notație simplificată: $X \perp Y | Z$ și $(X, Y) \perp W | Z$ implică $X \perp W | Z$ (și similar $Y \perp W | Z$).

48. (Variabile aleatoare: medii și varianțe;
exemplificări ale unor proprietăți)

CMU, 2016 fall, N. Balcan, M. Gormley, HW2, pr. 1.4

Fie X o variabilă aleatoare având media $E[X] = 1$ și varianța $Var(X) = 1$. Calculați:

- i. $E[3X]$;
- ii. $Var(3X)$;
- iii. $Var(X + 3)$.

49. (Variabila indicator pentru un eveniment aleator:
calculul mediei)

• ◦ CMU, 2015 spring, T. Mitchell, N. Balcan, HW2, pr. 1.c

Fie un eveniment aleatoriu oarecare A , iar X o variabilă aleatoare definită astfel:

$$X = \begin{cases} 1 & \text{dacă evenimentul } A \text{ se realizează} \\ 0 & \text{în caz contrar.} \end{cases}$$

Uneori, X este numită variabilă aleatoare *indicator* pentru evenimentul A . Arătați că $E[X] = P(A)$, unde $E[X]$ reprezintă *valoarea medie* a lui X .


50.

(Variabile aleatoare discrete: distribuția binomială)

CMU, 2009 spring, Ziv Bar-Joseph, HW1, pr. 1.4

Distribuția binomială: p.m.f.

Un marinar încearcă să meargă pe o punte alunecoasă, însă datorită mișcărilor navei, el poate face exact un pas la fiecare interval de timp egal cu unitatea, și anume: fie un pas înainte (cu probabilitatea p), fie un pas înapoi (cu probabilitatea $1-p$). Marinarul nu poate rămâne imobil. Poziția marinarului la momentul de timp $i \in \{0, 1, \dots\}$ va fi exprimată cu ajutorul unei variabile aleatoare $X_i \in \{-\infty, \dots, -2, -1, 0, 1, 2, \dots, +\infty\}$, astfel:



$X_0 = 0$ cu probabilitate 1;

$P(X_{t+1} = x_i + 1 \mid X_t = x_i) = p$, pentru $t \geq 0$;

$P(X_{t+1} = x_i - 1 \mid X_t = x_i) = 1 - p$, pentru $t \geq 0$.

a. Cât este $P(X_{16} = 8)$, adică probabilitatea ca marinarul să se afle în poziția +8 după exact 16 unități de timp?

b. Generalizare: Cât este $P(X_n = r)$, adică probabilitatea ca marinarul să se afle în poziția r după exact n unități de timp (considerând $n \geq r$ și $n-r$ număr par)?

c. Bazat pe formula de la punctul precedent, calculați $P(X_{32} = 16)$.

d. Este probabilitatea de la punctul c aceeași cu $P(X_{32} = 16 \mid X_{16} = 8)$, adică probabilitatea ca marinarul să se afle la poziția +16 după exact 32 de unități de timp știind că la momentul de timp 16 se afla la poziția +8?

51.

(Distribuția binomială: calculul mediei și al varianței)

■ □ * Liviu Ciortuz, 2015

Calculați media și varianța distribuției binomiale de parametri r , n și p . (Notăție: $b(r; n, p) = C_n^r p^r (1-p)^{n-r}$.)

Vă reamintim că această distribuție reprezintă numărul (r) de apariții ale feței cu stema (corespondent engl., *head*) obținute la efectuarea a n aruncări independente ale unei monede. Veți presupune că probabilitatea de apariție a stemei la o aruncare oarecare a acestei monede este p .

52. (Variabile aleatoare discrete – distribuția categorială – și evenimente independente și identic distribuite; calcul de medii)

◦ CMU, 2009 fall, Geoff Gordon, HW1, pr. 4

Presupunem că avem n coșuri și m mingi. Aruncăm mingile în coșuri în mod independent și aleatoriu, așa încât fiecare minge este la fel de probabil să cadă în oricare dintre coșuri. (Pentru simplitate, vom presupune că la orice aruncare mingea cade într-un coș oarecare.)

- Care este probabilitatea ca prima minge să cadă în primul coș?
- Care este, în medie, numărul de mingi care au căzut în primul coș?

Sugestii:

- Puteți defini o variabilă aleatoare care să reprezinte (similar unei funcții-indicator) faptul că mingea i a căzut în primul coș:

$$X_i = \begin{cases} 1 & \text{dacă mingea } i \text{ a căzut în primul coș,} \\ 0 & \text{altfel.} \end{cases}$$

- Țineți cont de liniaritatea mediei (adică, media unei combinații liniare de variabile este...).

- Care este probabilitatea ca primul coș să rămână gol după aruncarea celor m mingi?
- Care este, în medie, numărul de coșuri care rămân goale după aruncarea celor m mingi?

53. (Variabile aleatoare discrete: distribuții corelate, distribuții marginale; medii, independență)

CMU, 2009 fall, Carlos Guestrin, HW1, pr. 1.2

Fie două variabile aleatoare discrete cu distribuția (i.e., funcția masă de probabilitate) corelată dată în tabelul de mai jos (partea dreaptă).

- Calculați valorile medii ale variabilelor X și Y în funcție de α , β , γ și δ .

- Găsiți condițiile necesare și suficiente astfel încât variabilele X și Y să fie independente.

X	Y	$P(X, Y)$
0	0	α
0	1	β
1	0	γ
1	1	δ

54. (Covarianța nulă vs. independența variabilelor aleatoare binare)

* CMU, 2009 fall, Geoff Gordon, HW1, pr. 3.2

Se știe că atunci când covarianța a două variabile aleatoare este nulă nu rezultă în mod neapărat că variabilele respective sunt independente (vezi pr. 11.a). Însă, dacă X și Y sunt variabile aleatoare binare luând valori în mulțimea $\{0, 1\}$ și covarianța lor este nulă, rezultă că X și Y sunt independente (vezi pr. 11.b).

Arătați că, în cazul în care doar variabila aleatoare X este binară, nu rezultă în mod neapărat că X și Y sunt independente, deși covarianța lor este nulă.

Indicație: Folosiți ca exemplu variabilele aleatoare ale căror distribuții sunt date în tabelul alăturat.

X	Y	$P(X, Y)$
0	-1	0.1
0	0	0.4
0	1	0.1
1	-1	0
1	0	0.4
1	1	0

55. (Variabile aleatoare discrete: distribuții corelate, distribuții marginale, distribuții condiționale; independență, independență condițională)

• ★ CMU, 2016 fall, N. Balcan, M. Gormley, HW2, pr. 1.4

Fie trei variabile aleatoare X , Y și Z care iau valori în mulțimea $\{0, 1\}$. În tabelul de mai jos este dată distribuția probabilistă corelată a acestor trei variabile, $P(X, Y, Z)$.

	$Z = 0$		$Z = 1$	
	$X = 0$	$X = 1$	$X = 0$	$X = 1$
$Y = 0$	1/24	1/12	1/12	5/24
$Y = 1$	1/12	p	q	7/24

- a. Considerând că X și Y sunt independente, găsiți valorile lui p și q .

Indicație: Este util (deși nu obligatoriu) să calculați mai întâi $P(X, Y)$, distribuția corelată a variabilelor X și Y , completând tabel următor, după care veți calcula și distribuțiile (marginale) pentru X și Y , de preferință ca o linie și respectiv o coloană suplimentară la acest tabel.

	$X = 0$	$X = 1$
$Y = 0$		
$Y = 1$		

- b. Considerând valorile lui p și q determinate la punctul a, sunt X și Y independente condițional în raport cu Z ? De ce?

56.

(O mixtură de distribuții categoricale:
calculul mediei și al varianței)

■ □ ● ○ CMU, 2010 fall, Aarti Singh, HW1, pr. 2.2.1-2

Presupunem că avem două zaruri cu șase fețe. Un zar este perfect, iar celălalt zar este măsluit și are următoarea funcție masă de probabilitate (p.m.f.):

$$P_2(x) = \begin{cases} \frac{1}{2} & \text{pentru } x = 6; \\ \frac{1}{10} & \text{pentru } x \in \{1, 2, 3, 4, 5\}. \end{cases}$$

Vom folosi o monedă pentru a decide ce zar să aruncăm. Dacă la aruncarea monedei obținem stema (engl., head), vom arunca apoi zarul perfect; în caz contrar vom arunca zarul măsluit. Probabilitatea ca la aruncarea monedei să obținem stema este $p \in (0, 1)$.

a. Calculați în funcție de p media variabilei aleatoare (X) care reprezintă „mixtura” de distribuții [categorice] descrisă mai sus.

b. Calculați în funcție de p varianța variabilei aleatoare X .

57.

(Variabile aleatoare continue:
funcția densitate de probabilitate)

* CMU, 2008 spring, Eric Xing, HW1, pr. 1.1.a

Fie funcția $f(x) = ce^{-|x|}$, $-\infty < x < \infty$.

Ce valoare/valori poate avea constanta reală c în așa fel ca f să poată reprezenta o funcție densitate de probabilitate?

58.

(Variabile aleatoare continue: calculul unei probabilități,
folosind funcția densitate de probabilitate)

* CMU, 2004 fall, T. Mitchell, Z. Bar-Joseph, midterm, pr. 1.b

Presupunem că funcția densitate de probabilitate a unei variabile aleatoare continue X este definită astfel:

$$p(x) = \begin{cases} \frac{4}{3}(1 - x^3) & \text{pentru } 0 \leq x \leq 1 \\ 0 & \text{în caz contrar.} \end{cases}$$

Cât este $P(X < 0)$?

59.

(Variabile aleatoare discrete vs. variabile aleatoare continue;
distincția dintre p.m.f. și p.d.f.)

□ ● ○ CMU, 2012 spring, Ziv Bar-Joseph, HW1, pr. 1.1

Mickey nu este încă bine inițiat în teoria probabilităților și se confruntă cu chestiunea următoare, despre care el este înclinat să creadă că este un paradox:

Fie X o variabilă aleatoare cu distribuția de probabilitate uniformă, definită pe intervalul $[0, \frac{1}{2}]$, și anume $f(x) = 2$ pentru $x \in [0, \frac{1}{2}]$. Întrucât suma probabilităților care corespund unei distribuții aleatoare trebuie să fie 1, Mickey este nedumerit de ce valoarea lui $f(x)$ este mai mare decât suma totală.

Explicați acest paradox. Altfel spus, arătați ce anume nu știe Mickey.

60. (Distribuția Poisson: calculul mediei și al varianței;
distribuția Gamma: calculul mediei)

Liviu Ciortuz, 2017

a. Distribuția *Poisson* este o distribuție discretă de parametru $\lambda > 0$, a cărei funcție masă de probabilitate este dată de expresia

$$p(x | \lambda) = \frac{1}{e^\lambda} \cdot \frac{\lambda^x}{x!}, \text{ pentru orice } x \in \mathbb{N}.$$

Prin convenție, se consideră că $0! = 1$. Factorul $\frac{1}{e^\lambda}$, care nu depinde de x , este așa-numitul *factor de normalizare*.

Demonstrați că media acestei distribuții este λ , iar varianța ei este tot λ .

b. Distribuția *Gamma* este o distribuție continuă, de parametri $r > 0$ (care dă *forma* distribuției, engl., *shape*) și $\alpha > 0$ (numit *rata*, engl., *rate*), cu funcția densitate de probabilitate definită pe \mathbb{R}^+ prin expresia următoare:

$$p(x) \stackrel{\text{not.}}{=} \text{Gamma}(x|r, \alpha) = \frac{\alpha^r}{\Gamma(r)} x^{r-1} e^{-\alpha x},$$

unde *factorul de normalizare* este $\frac{\alpha^r}{\Gamma(r)}$. Funcția Γ (a lui Euler) este o generalizare în \mathbb{R}^+ a definiției numerelor factoriale din \mathbb{N} (și anume, $\Gamma(r) = (r-1)!$ pentru orice $r \in \mathbb{N}^*$).

Demonstrați că media distribuției Gamma este $\frac{r}{\alpha}$.

Sugestie: Veți ține cont de una din proprietățile funcției Γ a lui Euler: $\Gamma(r+1) = r \cdot \Gamma(r)$ pentru orice $r > 0$.

61. (Distribuția gaussiană, cazul bi-variat:
explicitarea p.d.f. într-un caz particular;
matrici de covarianță pentru vectori de variabile aleatoare:
o proprietate)

□ • ○ MIT, 2006 fall, Tommi Jaakkola, HW1, pr. 5

a. Fie X un vector de variabile aleatoare de tip gaussian, cu

$$E[X] = \begin{pmatrix} 10 \\ 5 \end{pmatrix} \quad \text{și} \quad \text{Cov}(X) = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}.$$

Scrieți expresia funcției densitate de probabilitate (p.d.f.) pentru X , fără a folosi notația matriceală. Așadar, considerând $X = (x_1, x_2)$, scrieți funcția sa de densitate de probabilitate corelată ca un $P(x_1, x_2)$.

b. Fie A, B matrice [de numere reale] de dimensiune $p \times q$, iar x un vector aleator de dimensiune $q \times 1$. Demonstrați egalitatea următoare

$$\text{Cov}(Ax, Bx) = A \text{Cov}(x) B^T,$$

unde prin $\text{Cov}(u, v) \stackrel{\text{def.}}{=} E[(u - E[u])(v - E[v])^T]$ am notat matricea de cros-covarianță pentru doi vectori aleatori oarecare u și v , iar prin $\text{Cov}(u) \stackrel{\text{def.}}{=} E[(u - E[u])(u - E[u])^T]$ am notat matricea de covarianță pentru vectorul u .

62. (Variabile aleatoare continue, variabile aleatoare discrete; independență, variabile aleatoare condiționate, medii)
- CMU, 2009 spring, Ziv Bar-Joseph, final exam, pr. 1.1

Fie $X : \Omega \rightarrow [0, 1]$ o variabilă aleatoare continuă având distribuția uniformă (notație: $X \sim \text{Uniform}(0, 1)$). Fie a și b două numere reale, astfel încât $0 < a < b < 1$. Definim (tot pe Ω) variabilele aleatoare discrete Y și Z în funcție de valorile lui X , astfel:

$$Y(\omega) = \begin{cases} 1 & \text{dacă } 0 \leq X(\omega) \leq a, \\ 0 & \text{altfel} \end{cases}$$

$$Z(\omega) = \begin{cases} 1 & \text{dacă } b \leq X(\omega) \leq 1, \\ 0 & \text{altfel.} \end{cases}$$

a. Sunt variabilele Y și Z independente? Justificați răspunsul.

Indicație: Pentru a găsi răspunsul corect vă sugerăm că ar fi util să completați tabelul de mai jos.

y	z	$P(Y = y)$	$P(Z = z)$	$P(Y = y)P(Z = z)$	$P(Y = y, Z = z)$
0	0				
0	1				
1	0				
1	1				

b. Pentru fiecare din valorile z ale variabilei Z , calculați media variabilei condiționate $Y \mid Z = z$. (Notație: $E_Y[Y \mid Z = z]$).

63.

(Distribuții probabiliste discrete și distribuții probabiliste continue)

□ • ◦ CMU, 2015 spring, T. Mitchell, N. Balcan, HW1, pr. 2.2

Faceți corespondența dintre numele de distribuții probabiliste din coloana din stânga cu funcțiile [masă, respectiv densitate] de probabilitate din coloana din dreapta.

- | | |
|----------------------------|--------------------------------------------------------------------------------------------------------------|
| a. gaussiană multi-variata | f. $p^{1-x}(1-p)^x$ cu $x \in \{0, 1\}$ |
| b. exponențială | g. $\frac{1}{b-a}$ pentru $a \leq x \leq b$; 0 în caz contrar |
| c. uniformă | h. $C_n^x p^x (1-p)^{n-x}$ pentru $x \in \{0, \dots, n\}$ |
| d. Bernoulli | i. $\lambda e^{-\lambda x}$ pentru $x \geq 0$; 0 în caz contrar |
| e. binomială | j. $\frac{1}{\sqrt{(2\pi)^d \Sigma }} \exp\left(-\frac{1}{2} - (x - \mu)^\top \Sigma^{-1} (x - \mu)\right)$ |

64.

(Variabile aleatoare: Adevărat sau Fals?)

□ • ◦ CMU, 2005 fall, T. Mitchell, A. Moore, midterm, pr. 1.2

Fie X și Y două variabile aleatoare. Care dintre următoarele afirmații sunt adevărate?

- Dacă X și Y sunt independente, atunci $E[2XY] = 2E[X]E[Y]$ și $\text{Var}[X+2Y] = \text{Var}[X] + \text{Var}[Y]$.
- Dacă X și Y sunt independente, iar $X > 1$, atunci $\text{Var}[X+2Y^2] = \text{Var}[X] + 4\text{Var}[Y^2]$ și $E[X^2 - X] \geq \text{Var}[X]$.
- Dacă X și Y nu sunt independente, atunci $\text{Var}[X+Y] = \text{Var}[X] + \text{Var}[Y]$.
- Dacă X și Y sunt independente, atunci $E[XY^2] = E[X]E[Y]^2$ și $\text{Var}[X+Y] = \text{Var}[X] + \text{Var}[Y]$.
- Dacă X și Y nu sunt independente și $f(X) = X^2$, atunci $E[f(X)E[Y]] = E[f(X)]E[Y]$ și $\text{Var}[X+2Y] = \text{Var}[X] + 4\text{Var}[Y]$.