

4.

(Algoritmul EM pentru GMM, cazul uni-variat: demonstrația formulelor de „actualizare” de la pasul M)

Se consideră algoritmul EM pentru estimarea parametrilor unui model de amestur de k distribuții gaussiene, despre care se presupune că au [toate] aceeași varianță σ^2 , iar probabilitățile a priori de selecție sunt egale ($1/k$). Prin urmare, se vor estima doar mediiile celor două distribuții gaussiene, aplicându-se formulele următoare:

Pasul E:

$$E[z_{ij}] = \frac{\sum_{i=1}^n E[z_{ij}|x_i]}{\sum_{i=1}^n E[z_{ij}]} = \frac{\sum_{i=1}^n \frac{1}{2\sigma^2} (x_i - \mu_j)^2}{\sum_{i=1}^n \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu_j)^2\right)} \text{ pentru } i = 1, \dots, n \text{ și } j = 1, \dots, k$$

Pasul M:

$$\mu_j = \frac{\sum_{i=1}^n E[z_{ij}] x_i}{\sum_{i=1}^n E[z_{ij}]}, \text{ pentru } j = 1, \dots, k$$

unde

- simbolul \exp desemnează funcția exponențială (e^x),
- n este numărul de puncte/instanțe,
- k este numărul de clustere,
- $\mu = (\mu_1, \dots, \mu_k)$,
- iar z_{ij} , cu $i \in \{1, \dots, n\}$ și $j \in \{1, \dots, k\}$, sunt variabilele-indicator neobservabile (sau „ascunse” / „latente”), luând valoarea $z_{ij} = 1$ dacă x_i a fost generat de gaussiana j și $z_{ij} = 0$ în caz contrar.

a. Demonstrați formula de la pasul M.

Sugestie:

Veți scrie mai întâi (i) log-verosimilitatea unei instanțe „complete” $y_i = (x_i, z_{i1}, \dots, z_{ik})$, apoi (ii) funcția de log-verosimilitate a datelor complete $Y = \{y_1, \dots, y_n\}$, după care veți calcula (iii) media acestei funcții și, în final, (iv) valorile μ_j pentru care se atinge valoarea optimă a mediei funcției de log-verosimilitate.

b. Demonstrați că algoritmul acesta buclează dacă se inițializează toate mediile μ_j cu o aceeași valoare.

a)

ii) fct. de verosimilitate a datelor complete:

$$P(Y|\mu) = P(y_1, \dots, y_n|\mu) = \prod_{i=1}^n P(y_i|\mu)$$

$$\Rightarrow \log P(Y|\mu) = \log \left(\prod_{i=1}^n P(y_i|\mu) \right) = \sum_{i=1}^n \ln P(y_i|\mu)$$

$$b) P(y_i) = P(x_i, z_{i1}, \dots, z_{ik}) = P(x_i|z_{i1}, \dots, z_{ik}) \cdot P(z_{i1}, \dots, z_{ik})$$

$$= \frac{1}{k} \cdot \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \quad (\mu = \text{media gaussianei candeva generat pe indreapta y_i})$$

$$\Rightarrow \log P(y_i) = \log \frac{1}{k} + \log \frac{1}{\sqrt{2\pi} \cdot \sigma} - \frac{(x_i - \mu)^2}{2\sigma^2} =$$

$$= -\log k - \frac{1}{2} \log(2\pi\sigma) - \frac{(x_i - \mu)^2}{2\sigma^2} \quad (*)$$

$$\text{Dec. } \ln(P(y_i)) \text{ e, în acest context tot una cu } P(y_i|\mu).$$

$$\Rightarrow \text{contineam în (ii)} \quad \ln P(y|\mu) = \sum_{i=1}^n \ln P(y_i|\mu) = \sum_{i=1}^n \left(-\ln k - \frac{1}{2} \ln(2\pi\sigma) - \frac{(x_i - \mu)^2}{2\sigma^2} \right) =$$

$$= -\sum_{i=1}^n \ln k - \frac{1}{2} \sum_{i=1}^n \ln(2\pi\sigma) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} =$$

$$ii) E[\ln P(y|\mu)] = E\left[-\sum_{i=1}^n \ln k - \frac{1}{2} \sum_{i=1}^n \ln(2\pi\sigma) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \right] =$$

$$\text{prop. de linieariț.} \quad = -\sum_{i=1}^n \ln k - \frac{1}{2} \sum_{i=1}^n \ln(2\pi\sigma) - \sum_{i=1}^n \frac{E[(x_i - \mu)^2]}{2\sigma^2} =$$

$$ii) \hat{\mu} = \arg \max_{\mu} E[\ln P(y|\mu)] = \arg \max_{\mu} \left[\sum_{i=1}^n \ln k - \frac{1}{2} \sum_{i=1}^n \ln(2\pi\sigma) - \sum_{i=1}^n \frac{E[(x_i - \mu)^2]}{2\sigma^2} \right]$$

$$= \arg \max_{\mu} \left[\sum_{i=1}^n \ln k - \frac{1}{2} \sum_{i=1}^n \ln(2\pi\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) \right] \quad \text{note cu Exp.}$$

$$\text{afin numărul termenilor folosind derivarea} \quad E(x\mu^2) = \sum_{i=1}^n E[x_i^2] = \sum_{i=1}^n E[z_{i1}^2] \cdot \frac{x_i^2 + \mu^2 - 2x_i\mu}{2\sigma^2}$$

$$= \arg \max_{\mu} \left[\sum_{i=1}^n \ln k - \frac{1}{2} \sum_{i=1}^n \ln(2\pi\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i^2 + \mu^2 - 2x_i\mu) \right]$$

$$\text{functia de mai sus are un maxim în punctul} \quad -\frac{\partial}{\partial \mu} \left[\sum_{i=1}^n (x_i^2 + \mu^2 - 2x_i\mu) \right] = 0$$

$$\sum_{i=1}^n x_i^2 + \sum_{i=1}^n \mu^2 - 2 \sum_{i=1}^n x_i \mu = 0 \quad \Rightarrow \sum_{i=1}^n x_i^2 + n\mu^2 - 2 \sum_{i=1}^n x_i \mu = 0$$

12.

F.B!

continuăm:

e) Conform enunțului, avem: $\mu_1 = \mu_2 = \dots = \mu_k = \mu$

rezult E:
$$E[Z_i^2] = \frac{d^2}{d\mu^2} \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu)^2\right) = \frac{d^2}{d\mu^2} \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu)^2\right)$$

de la

des. ca numerele va fi = pt toate pte
unde
des in numitorul
deci $E[Z_i^2] = \frac{1}{\sigma^2}$

rezult n:

Fie μ_j media unei gaussiene covariante din cele k.

$$\mu_j = \frac{d}{d\mu} E[Z_i^j] x_i = \frac{d}{d\mu} \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu)^2\right) x_i$$

$$= \frac{d}{d\mu} \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu)^2\right) x_i$$

$$= \frac{d}{d\mu} \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu)^2\right) x_i$$

$$= \frac{d}{d\mu} \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu)^2\right) x_i$$

de des. ca mediatele k gaussiene au numere egale intru de. \Rightarrow la urmatoarea derivata va obtine același rezultat \Rightarrow rezultatul este k inlocuind.

continuăm problema:

$$\theta_{MLE} = \frac{n}{\sum_{i=1}^n k_i + n}$$

ap. formula:

$$\theta_{MLE} = \frac{5}{5 + (0 + 21 + 23 + 8 + 9)} = \frac{5}{66} = 0,075$$

ap. toate:

$$\theta_{MLE} = \frac{15}{15 + 0 + 21 + 23 + 8 + 9 + 2 + 5 + 0 + 4 + 8 + 20 + 5 + 4 + 4 + 14} = \frac{15}{159} = 0,094$$

ap. pt formula:

$$\theta_{MLE} = \frac{10}{10 + 0 + 21 + 23 + 8 + 9 + 2 + 9 + 0 + 4 + 8} = \frac{10}{94} = 0,106$$